

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT



KHOA TOÁN KINH TẾ

Học kỳ II/2025 - 2026

DATA VISUALIZATION

TÊN ĐỀ TÀI:
**PHÂN TÍCH VÀ TRỰC QUAN HÓA
BỘ DỮ LIỆU
MOVIELENS BELIEF 2024**

GVHD : ThS. TRƯƠNG QUANG NHẬT

MÃ HỌC PHẦN : 232BMA4013

TÊN SINH VIÊN : MAI HOÀNG NGỌC HÂN

MSSV : K244131500

TP.HCM, THÁNG 4/2026

Mục lục

Danh mục các từ viết tắt	i
Danh mục bảng biểu	ii
Danh mục hình ảnh	iii
Tóm tắt	iv
Lời cảm ơn	1
1 GIỚI THIỆU VỀ DATA.	2
1.1 Tổng quan bộ dữ liệu	2
1.1.1 Bối cảnh thu thập dữ liệu	3
1.1.2 Cập nhật Data Release 2 (8/2/2025)	3
1.1.3 Thông tin trích dẫn và giấy phép	3
1.2 Quy mô và thông số kỹ thuật	3
1.2.1 Tổng quan quy mô	4
1.2.2 Thông số kỹ thuật	4
1.3 Mô tả chi tiết các file dữ liệu	5
1.3.1 File user_rating_history.csv - Lịch sử đánh giá phim	5
1.3.2 File movies.csv - Thông tin phim	5
1.3.3 File belief_data.csv - Dữ liệu niềm tin (Beliefs)	5
1.3.4 File user_recommendation_history.csv - Lịch sử gợi ý	6
1.3.5 File movie_elicitation_set.csv - Tập phim khảo sát	7
1.4 Kích thước dữ liệu	7
1.5 Mối quan hệ giữa các file	7
1.6 Thống kê mô tả	8

2	XỬ LÝ DỮ LIỆU	9
2.1	Xử lý dữ liệu rỗng (Missing Values)	9
2.2	Xử lý dữ liệu trùng lặp (Duplicates)	10
2.3	Kiểm tra tính hợp lý của dữ liệu	10
2.4	Loại bỏ dữ liệu ảo, sai - Phát hiện Outliers	10
2.5	Scale dữ liệu	10
2.6	Loại bỏ cột không hữu ích & Thêm cột mới	11
2.6.1	Các cột mới được tạo (Feature Engineering)	11
2.7	Kiểm tra tương quan giữa các biến	11
3	VẼ BIỂU ĐỒ VÀ NHẬN XÉT	13
3.1	Histogram - Phân bố điểm đánh giá	13
3.2	Histogram - Số đánh giá mỗi người dùng	15
3.3	Boxplot - Rating theo thể loại phim	16
3.4	Heatmap - Ma trận tương quan	17
3.5	Pairplot (Seaborn)	18
3.6	Bar chart - Top 10 thể loại phổ biến	20
3.7	Bar chart - Rating TB theo thể loại	21
3.8	Pie chart - Phân bố trạng thái isSeen	22
3.9	Violin plot - Phân bố Rating theo nhóm	24
3.10	Line chart - Xu hướng Rating theo năm	25
3.11	Scatter plot - User Predict vs System Predict	27
3.12	KDE plot - Rating thực vs Beliefs	28
3.13	Countplot - Mức độ chắc chắn (Certainty)	29
3.14	Grouped Bar - Rating theo thập kỷ	31
3.15	Heatmap - Ma trận User-Item (Sparsity)	32
3.16	Horizontal Bar - Top 15 phim phổ biến nhất	33
3.17	Boxplot - Phát hiện Outliers	35
3.18	Dashboard tổng hợp	36

4	KẾT LUẬN CHUNG	37
4.1	Câu chuyện MovieLens qua 18 biểu đồ	37
4.2	Bảng tổng hợp: Từ Insight đến Action.	38
4.3	Hạn chế	38
	Tài liệu tham khảo	39

Danh mục các từ viết tắt

Từ viết tắt	Ý nghĩa
CF	Collaborative Filtering - Lọc cộng tác
CSV	Comma-Separated Values - Giá trị phân tách bằng dấu phẩy
EDA	Exploratory Data Analysis - Phân tích dữ liệu khám phá
IQR	Interquartile Range - Khoảng tứ phân vị
KDE	Kernel Density Estimation - Ước lượng mật độ hạt nhân
Q1/Q3	Quartile 1/3 - Tứ phân vị thứ 1/3
TB	Trung bình

Danh mục bảng biểu

Bảng 1.1	Quy mô tổng quan của bộ dữ liệu	4
Bảng 1.2	Mô tả biến - user_rating_history.csv	5
Bảng 1.3	Mô tả biến - movies.csv	5
Bảng 1.4	Mô tả biến - belief_data.csv	6
Bảng 1.5	Mô tả biến - user_recommendation_history.csv	6
Bảng 1.6	Mô tả biến - movie_elicitation_set.csv	7
Bảng 1.7	5 nguồn chọn phim cho Elicitation Set	7
Bảng 1.8	Kích thước và dung lượng từng file	7
Bảng 1.9	Thống kê mô tả biến rating (user_rating_history)	8
Bảng 2.1	Feature Engineering - Các cột mới	11
Bảng 4.1	Cinema Logic → Engineering Action	38

Danh mục hình ảnh

Hình 2.1	Ma trận tương quan giữa các biến	12
Hình 3.1	Histogram: Phân bố điểm đánh giá (Ratings)	14
Hình 3.2	Histogram: Phân bố số đánh giá mỗi người dùng	15
Hình 3.3	Boxplot: Rating theo 10 thể loại phổ biến nhất	17
Hình 3.4	Pairplot: rating / year / num_genres / avg_rating	19
Hình 3.5	Top 10 thể loại phim phổ biến nhất	20
Hình 3.6	Rating TB theo thể loại (≥ 1000 đánh giá)	21
Hình 3.7	Phân bố trạng thái isSeen trong Belief Data	23
Hình 3.8	Violin Plot: Phân bố Rating theo nhóm phân loại	25
Hình 3.9	Xu hướng Rating TB theo năm phát hành	26
Hình 3.10	Dự đoán hệ thống vs Dự đoán người dùng	27
Hình 3.11	So sánh: Rating thực tế vs User Beliefs (KDE)	28
Hình 3.12	Phân bố mức độ chắc chắn (userCertainty)	30
Hình 3.13	Rating TB theo thập kỷ phát hành	31
Hình 3.14	Ma trận User-Item (50×50) - Ô trắng = Chưa đánh giá	32
Hình 3.15	Top 15 phim phổ biến nhất (màu theo rating)	34
Hình 3.16	Boxplot: Rating / Ratings per User / Ratings per Movie	35
Hình 3.17	Dashboard tổng quan - MovieLens Belief 2024	36

Tóm tắt

Báo cáo này thực hiện **phân tích khám phá dữ liệu (EDA)** và **trực quan hóa (Data Visualization)** trên bộ dữ liệu **MovieLens Belief 2024** - một bộ dữ liệu đặc biệt của GroupLens Research, chứa cả dữ liệu đánh giá phim truyền thống lẫn “beliefs” (dự đoán chủ quan của người dùng về phim chưa xem), nhằm bóc tách mối liên hệ giữa hành vi đánh giá thực tế và kỳ vọng chủ quan (beliefs) của người dùng.

Bộ dữ liệu gồm 5 file CSV với tổng cộng hàng trăm nghìn bản ghi, bao gồm thông tin đánh giá phim, thể loại, niềm tin dự đoán (beliefs), và lịch sử gợi ý. Quy trình phân tích bao gồm: giới thiệu và mô tả dữ liệu, xử lý dữ liệu (kiểm tra missing values, duplicates, tính hợp lý, outliers, feature engineering, scale dữ liệu, phân tích tương quan), vẽ 18 biểu đồ đa dạng (histogram, boxplot, heatmap, pairplot, bar chart, pie chart, violin plot, KDE plot, line chart, scatter plot, dashboard tổng hợp) với nhận xét insight sau mỗi biểu đồ.

Kết quả trực quan hóa cho thấy: (1) Phân bố rating lệch trái với 4.0 là phổ biến nhất, (2) Drama/Comedy/Action chiếm đa số, (3) Phim cũ có rating cao hơn do survivorship bias, (4) Người dùng có xu hướng dự đoán lạc quan hơn thực tế, (5) Ma trận user-item rất thưa (>99%), và (6) Phân bố long-tail rõ rệt.

Lời cảm ơn

Đầu tiên, em xin gửi lời cảm ơn chân thành đến **Quý Thầy/Cô** trong Khoa Toán Kinh tế, Trường Đại học Kinh tế - Luật đã tận tình giảng dạy và truyền đạt những kiến thức quý báu về Data Visualization trong suốt học kỳ vừa qua.

Đặc biệt, em xin cảm ơn **Thầy Trương Quang Nhật** - Giảng viên hướng dẫn - đã luôn nhiệt tình hỗ trợ, giải đáp thắc mắc và định hướng cho em trong quá trình thực hiện đề tài này.

Em cũng xin gửi lời cảm ơn đến nhóm nghiên cứu **GroupLens Research** tại Đại học Minnesota đã công bố bộ dữ liệu MovieLens Belief 2024, tạo điều kiện thuận lợi cho việc nghiên cứu và thực hành phân tích dữ liệu.

Trong quá trình thực hiện, báo cáo không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý từ Thầy/Cô để hoàn thiện hơn.

Em xin trân trọng cảm ơn!

Chương 1

GIỚI THIỆU VỀ DATA

“Without data, you’re just another person with an opinion.”

- W. Edwards Deming

Có một sự thật rằng: trực giác, dù nó có sắc bén đến đâu, thì vẫn chỉ là niềm tin cá nhân cho đến khi dữ liệu lên tiếng. Bước vào MovieLens Belief 2024, ta không đối diện với những con số vô tri, mà là dấu vết của kỳ vọng, thiên kiến và chính sự lựa chọn của con người.

1.1 Tổng quan bộ dữ liệu

Bộ dữ liệu **MovieLens Belief 2024 (Data Release 2)** được phát hành bởi **GroupLens Research** - nhóm nghiên cứu thuộc Khoa Khoa học Máy tính & Kỹ thuật, Đại học Minnesota. GroupLens hoạt động từ năm 1992, nghiên cứu các lĩnh vực: hệ thống gợi ý (recommender systems), cộng đồng trực tuyến, công nghệ di động, thư viện số, và hệ thống thông tin địa lý. Họ vận hành **MovieLens** (<https://movielens.org>) - một dịch vụ gợi ý phim dựa trên collaborative filtering.

Điểm đặc biệt

Đây **không chỉ** là một bộ dữ liệu rating phim thông thường. Lần đầu tiên, MovieLens thu thập **“beliefs”** - dự đoán chủ quan của người dùng về phim họ *chưa xem* (pre-choice data). Điều này cho phép so sánh định lượng giữa **nhận thức chủ quan** của con người và **dự đoán** của hệ thống gợi ý - một bước đột phá trong nghiên cứu recommender systems.

1.1.1 Bối cảnh thu thập dữ liệu

Từ ngày **1 tháng 3 năm 2023** đến **1 tháng 5 năm 2024** (14 tháng), hàng thứ hai trên trang chủ MovieLens hiển thị giao diện yêu cầu người dùng cung cấp thông tin: “*Bạn nghĩ bạn sẽ đánh giá bộ phim này bao nhiêu sao?*” - đối với những phim họ chưa xem. Dữ liệu được thu thập từ tất cả người dùng đã trả lời **ít nhất một** câu hỏi belief elicitation.

- **Không có thông tin nhân khẩu học** - mỗi user chỉ được biểu diễn bằng một `userId` ẩn danh.
- Các `userId` nhất quán xuyên suốt tất cả file dữ liệu.
- Các `movieId` nhất quán với ID trên trang web MovieLens (ví dụ: id 1 ↔ <https://movielens.org/movies/1>).

1.1.2 Cập nhật Data Release 2 (8/2/2025)

Ngày 8 tháng 2 năm 2025, GroupLens cập nhật bộ dữ liệu với 2 thay đổi quan trọng:

1. **Bổ sung phim:** Cập nhật file `movies.csv` để mọi phim trong belief dataset đều có thông tin tương ứng.
2. **Bổ sung ratings:** Thêm dữ liệu rating cho một nhóm users mới - bao gồm cả những users *đã thấy* giao diện belief elicitation nhưng *không trả lời*.

1.1.3 Thông tin trích dẫn và giấy phép

Nguồn dữ liệu: https://grouplens.org/datasets/movielens/ml_belief_2024/

Trích dẫn: Aridor, G., Goncalves, D., Kong, R., Culver, D., & Konstan, J.A. (2024). *The MovieLens Beliefs Dataset: Collecting Pre-Choice Data for Online Recommender Systems*. Proceedings of the 18th ACM Conference on Recommender Systems (RecSys 2024).

Giấy phép: Dữ liệu được phép sử dụng cho **mục đích nghiên cứu** với điều kiện ghi nguồn. Không được sử dụng cho mục đích thương mại mà chưa được phép của GroupLens.

Liên hệ: guy.aridor@kellogg.northwestern.edu và grouplens-info@umn.edu

1.2 Quy mô và thông số kỹ thuật

1.2.1 Tổng quan quy mô

Bảng 1.1: Quy mô tổng quan của bộ dữ liệu

Thông số	Giá trị
Thời gian thu thập beliefs	03/2023 – 05/2024 (14 tháng)
Tổng số người dùng (users)	~4,400+
Tổng số phim (movies)	~105,000+
Tổng số lượt đánh giá (ratings)	~2,000,000+
Tổng số records belief elicitation	~3,000,000+
Số lượng phim trong elicitation set	~84,000+
Số lượng gợi ý (recommendations)	~1,285,000+
Số file dữ liệu	5 file CSV
Tổng dung lượng (nén)	~480 MB
Encoding	UTF-8, comma-separated

1.2.2 Thông số kỹ thuật

- **Định dạng:** Comma-Separated Values (CSV) với header row. Cột chứa dấu phẩy được escape bằng double-quotes. Encoding UTF-8 (quan trọng cho ký tự đặc biệt trong tên phim, ví dụ: *Misérables*, *Les*).
- **Thang đo rating:** 5 sao, bước 0.5 (0.5 – 5.0) cho cả rating, userPredictRating, userElicitRating, và systemPredictRating.
- **Thang đo certainty:** 5 điểm, bước 1.0 (1 – 5) cho userCertainty.
- **Timestamp:** Số giây kể từ nửa đêm UTC ngày 1/1/1970 (Unix epoch).
- **Thể loại phim:** 19 genres phân tách bằng pipe (|): Action, Adventure, Animation, Children’s, Comedy, Crime, Documentary, Drama, Fantasy, Film-Noir, Horror, Musical, Mystery, Romance, Sci-Fi, Thriller, War, Western, (no genres listed).
- **Nguồn belief elicitation (source):** 3 nhóm trong belief_data: (1) Broad sampling, (2) Elicitation with possible recommendation, (3) Sample new movies.
- **Nguồn elicitation set (source):** 5 nhóm trong movie_elicitation_set: (1) Popularity, (2) Rating, (3) Popular recent releases, (4) Trendy releases, (5) Serendipity.

1.3 Mô tả chi tiết các file dữ liệu

Bộ dữ liệu gồm **5 file CSV** chính, mỗi file phục vụ một mục đích riêng trong hệ sinh thái MovieLens:

1.3.1 File `user_rating_history.csv` - Lịch sử đánh giá phim

Chứa **toàn bộ lịch sử đánh giá** của mọi user đã trả lời ít nhất một câu hỏi belief. Mỗi dòng = một lượt đánh giá (userId, movieId, rating, timestamp). Dữ liệu sắp xếp theo userId, sau đó theo movieId.

Bảng 1.2: Mô tả biến - `user_rating_history.csv`

Biến	Kiểu	Ý nghĩa	Khoảng
userId	int64	Mã định danh người dùng (ẩn danh)	ID duy nhất
movieId	int64	Mã phim (nhất quán với movielens.org)	1 – 300,000+
rating	float64	Điểm đánh giá (5, bước 0.5)	0.5 – 5.0
tstamp	int64/object	Thời gian đánh giá (Unix timestamp)	1997 – 2024

1.3.2 File `movies.csv` - Thông tin phim

Tên phim nhập thủ công hoặc import từ **TheMovieDB** (<https://www.themoviedb.org/>), có thể bao gồm năm phát hành trong ngoặc. Có thể tồn tại lỗi/không nhất quán trong tên phim.

Bảng 1.3: Mô tả biến - `movies.csv`

Biến	Kiểu	Ý nghĩa	Ví dụ
movieId	int64	Mã phim duy nhất	1, 2, 3, ...
title	object	Tên phim (kèm năm phát hành)	Toy Story (1995)
genres	object	Thể loại, pipe-separated ()	Animation Children Comedy

1.3.3 File `belief_data.csv` - Dữ liệu niềm tin (Beliefs)

Đây là file **đặc biệt nhất và quan trọng nhất** - chứa dự đoán chủ quan của người dùng, kết quả của quá trình “belief elicitation”. Mỗi dòng = một lần hệ thống hỏi user về một bộ phim.

Bảng 1.4: Mô tả biến - belief_data.csv

Biến	Kiểu	Ý nghĩa	Khoảng
userId	int64	Mã người dùng	–
movieId	int64	Mã phim	–
isSeen	int64	Trạng thái: -1=Không trả lời, 0=Chưa xem, 1=Đã xem	{-1, 0, 1}
watchDate	object	Thời gian xem (chỉ khi isSeen=1)	Date / null
userElicitRating	float64	Rating user tự cho (khi isSeen=1)	0.5 – 5.0
userPredictRating	float64	User dự đoán rating (khi isSeen=0)	0.5 – 5.0
userCertainty	float64	Mức chắc chắn khi dự đoán (khi isSeen=0)	1 – 5
tstamp	object	Thời gian elicitation (Unix)	–
month_idx	int64	Tháng phim nằm trong elicitation set	–
source	int64	Nhóm chọn phim: 1=Broad, 2=Rec, 3=New	{1, 2, 3}
systemPredictRating	float64	Dự đoán rating của hệ thống MovieLens	0.0 – 5.0

Logic của giá trị null trong belief_data

Các giá trị rỗng trong file này là **do thiết kế** (by design), không phải lỗi dữ liệu:

- Khi `isSeen = -1`: User bỏ qua → tất cả trường belief đều null
- Khi `isSeen = 0`: User *chưa xem* phim → có `userPredictRating` + `userCertainty`, nhưng `userElicitRating` và `watchDate` null
- Khi `isSeen = 1`: User *đã xem* phim → có `userElicitRating` + `watchDate`, nhưng `userPredictRating` và `userCertainty` null

1.3.4 File user_recommendation_history.csv - Lịch sử gợi ý

Chứa toàn bộ danh sách phim được hệ thống gợi ý cho mỗi user, kèm `predictedRating` - rating mà hệ thống dự đoán cho cặp (user, movie). Mỗi dòng = một lượt gợi ý.

Bảng 1.5: Mô tả biến - user_recommendation_history.csv

Biến	Kiểu	Ý nghĩa
userId	int64	Mã người dùng
tstamp	object	Thời gian gợi ý
movieId	int64	Mã phim được gợi ý
predictedRating	float64	Rating dự đoán của hệ thống cho user-movie

1.3.5 File movie_elicitation_set.csv - Tập phim khảo sát

Chứa **danh sách phim** được chọn để hỏi beliefs trong từng tháng, cùng với **nguồn chọn phim** (source) - phản ánh chiến lược đa dạng hóa câu hỏi:

Bảng 1.6: Mô tả biến - movie_elicitation_set.csv

Biến	Kiểu	Ý nghĩa
movieId	int64	Mã phim
month_idx	int64	Tháng phim nằm trong elicitation set
source	int64	Nhóm chọn phim (xem bảng dưới)
tstamp	object	Thời gian cập nhật set

Bảng 1.7: 5 nguồn chọn phim cho Elicitation Set

Source	Tên	Mô tả
1	Popularity	Phim phổ biến nhất trên MovieLens
2	Rating	Phim có rating trung bình cao nhất
3	Popular recent releases	Phim mới ra phổ biến
4	Trendy releases	Phim mới đang “trending”
5	Serendipity	Phim “bất ngờ” - đa dạng hóa trải nghiệm

1.4 Kích thước dữ liệu

Bảng 1.8: Kích thước và dung lượng từng file

File	Số dòng	Số cột	Dung lượng
user_rating_history.csv	~2,046,000	4	73.6 MB
movies.csv	~105,000	3	4.7 MB
belief_data.csv	~3,004,000	11	203.1 MB
user_recommendation_history.csv	~1,285,000	4	48.2 MB
movie_elicitation_set.csv	~84,000	4	2.6 MB
Tổng	~6,524,000	–	~332 MB

1.5 Mối quan hệ giữa các file

Năm file dữ liệu được liên kết với nhau thông qua hai khóa chính:

- **userId** - nhất quán xuyên suốt: `user_rating_history`, `belief_data`, `user_recommendation_history`. Một user có thể xuất hiện trong cả 3 file.
- **movieId** - nhất quán xuyên suốt tất cả 5 file. Mã phim tương ứng 1:1 với URL trên `movielens.org`.

Kiến trúc dữ liệu

Bộ dữ liệu có thể được hiểu như một **hệ sinh thái 3 lớp**:

1. **Lớp nền tảng**: `movies.csv` - catalog phim (metadata)
2. **Lớp hành vi**: `user_rating_history` + `user_recommendation_history` - tương tác thực tế
3. **Lớp nhận thức**: `belief_data` + `movie_elicitation_set` - dự đoán chủ quan (“pre-choice data”)

Sự kết hợp lớp hành vi và lớp nhận thức tạo nên giá trị độc đáo của bộ dữ liệu này - cho phép nghiên cứu *khoảng cách* giữa kỳ vọng và thực tế.

1.6 Thống kê mô tả

Bảng 1.9: Thống kê mô tả biến rating (`user_rating_history`)

Biến	Count	Mean	Std	Min	Q1	Median	Max
rating	~1.5M	~3.53	~1.06	0.5	3.0	3.5	5.0

Nhận xét

Giá trị trung bình rating ≈ 3.53 cao hơn đáng kể so với điểm giữa thang đo (2.75), cho thấy **xu hướng đánh giá tích cực** (positive bias) rõ rệt - một đặc trưng phổ biến trong dữ liệu hành vi người dùng trên các nền tảng giải trí.

Chương 2

XỬ LÝ DỮ LIỆU

“Garbage in, garbage out.”

- *George Fuechsel*

Làm sạch dữ liệu là công đoạn cô độc và ít hào nhoáng nhất nhưng lại mang tính quyết định cho toàn bộ hệ thống. Trực tiếp đưa dữ liệu thô chưa qua xử lý vào mô hình chẳng khác nào việc dung nạp rác rưởi để rồi nhận lại toàn phế phẩm. Chương này sẽ phác họa chi tiết quy trình thanh lọc khắt khe, từ đó trả lại cho tập dữ liệu sự trong trẻo nguyên bản trước khi nó thực sự sẵn sàng kể lại những thước phim của riêng mình.

2.1 Xử lý dữ liệu rỗng (Missing Values)

Kiểm tra từng file:

- **user_rating_history**: Không có giá trị rỗng
- **movies**: Không có giá trị rỗng
- **belief_data**: Có giá trị rỗng ở `userPredictRating`, `userCertainty`, `systemPredictRating`, `userElicitRating`

Lưu ý quan trọng

Giá trị rỗng trong `belief_data` là **do thiết kế** (by design), không phải lỗi:

- `userPredictRating` chỉ có khi `isSeen=0` (phim chưa xem)
- `userElicitRating` chỉ có khi `isSeen=1` (phim đã xem)

Do đó, **không cần xử lý** các giá trị rỗng này - chúng mang ý nghĩa logic.

2.2 Xử lý dữ liệu trùng lặp (Duplicates)

Kiểm tra trùng lặp trên cặp (`userId`, `movieId`) trong file rating:

Kết quả

Số dòng trùng lặp: **0** → Không có dữ liệu trùng lặp

2.3 Kiểm tra tính hợp lệ của dữ liệu

- **Rating:** Kiểm tra tất cả giá trị thuộc tập hợp lệ $\{0.5, 1.0, 1.5, \dots, 5.0\}$ (bước 0.5)
→ **Tất cả hợp lệ**
- **`userId` > 0:** Đúng
- **`movieId` > 0:** Đúng
- **`isSeen` $\in \{-1, 0, 1\}$:** Đúng

2.4 Loại bỏ dữ liệu ảo, sai - Phát hiện Outliers

- **Rating:** Thang cố định 0.5–5.0, không có outlier theo nghĩa truyền thống.
- **Ratings per user:** Phân bố long-tail, một số “power users” đánh giá hàng nghìn phim. Đây không phải lỗi - phản ánh hành vi thực tế.
- **Ratings per movie:** Phim kinh điển có lượt đánh giá lớn hơn nhiều so với phim ít người biết.

Quyết định

Không loại bỏ outliers vì chúng phản ánh hành vi thực tế hợp lý. Thay vào đó, lưu ý khi diễn giải biểu đồ (ví dụ: sử dụng ngưỡng “ít nhất 1000 đánh giá” khi so sánh thể loại).

2.5 Scale dữ liệu

Áp dụng **MinMaxScaler** để chuẩn hóa rating về khoảng $[0, 1]$:

```
Rating gốc: [0.5, 5.0]
Rating scaled: [0.00, 1.00]
```

Scale dùng cho pairplot và heatmap; giữ nguyên rating gốc cho các biểu đồ phân tích chính.

2.6 Loại bỏ cột không hữu ích & Thêm cột mới


2.6.1 Các cột mới được tạo (Feature Engineering)

Bảng 2.1: Feature Engineering - Các cột mới

Cột	Kiểu	Mô tả
year	float	Năm phát hành (trích từ title)
num_genres	int	Số thể loại của phim
decade	int	Thập kỷ phát hành (1920s, 1930s, ...)
avg_rating	float	Rating trung bình của phim
num_ratings	int	Tổng số lượt đánh giá của phim
std_rating	float	Độ lệch chuẩn rating
rating_category	object	Phân loại: Thấp (≤ 2) / TB (2.5-3.5) / Cao (≥ 4)

2.7 Kiểm tra tương quan giữa các biến

Sử dụng hệ số tương quan Pearson giữa các biến: rating, year, num_genres, avg_rating.



Hình 2.1: Ma trận tương quan giữa các biến

Nhận xét

- **rating** và **avg_rating** có tương quan mạnh nhất (hiển nhiên - rating cá nhân liên quan đến rating trung bình phim).
- **year** và **num_genres** gần như không tương quan với rating → năm phát hành và số thể loại không ảnh hưởng đáng kể đến đánh giá.

Chương 3

VẼ BIỂU ĐỒ VÀ NHẬN XÉT

“The greatest value of a picture is when it forces us to notice what we never expected to see.”

- John Tukey

Trực quan hóa không phải là việc tô màu cho những con số. Đó là lúc ta ép dữ liệu phải thú nhận những góc khuất mà bảng biểu truyền thống đã che giấu. Qua 18 nhát cắt đồ họa, từ dải phân phối đơn giản đến những ma trận thưa thớt (Sparsity) phức tạp, chúng ta không vẽ để chứng minh điều mình đã biết. Chúng ta vẽ để nhận một cú tát trực diện từ thực tế - nhận ra con người đôi khi lại lạc quan mù quáng và thiên vị quá khứ đến nhường nào.


Mỗi biểu đồ được phân tích qua các lớp:

- **The Insight** - Cái nhìn thống kê: con số “biết nói”
- **The Cinema Logic** - Lý giải một phim: tại sao khán giả lại hành xử như vậy?
- **The Data-Driven Action** - So what: xử lý dữ liệu thế nào cho hệ thống gợi ý?

3.1 Histogram - Phân bố điểm đánh giá

Câu hỏi

Người dùng MovieLens có xu hướng cho điểm đánh giá bao nhiêu? Phân bố rating có đối xứng không?



Hình 3.1: Histogram: Phân bố điểm đánh giá (Ratings)

The Insight - Cái nhìn thống kê

Phân bố **lệch trái rõ rệt**: Mean ≈ 3.53 , Median = 3.5, Mode = 4.0. Hơn 67% ratings ≥ 3.0 . IQR = [3.0, 4.0] - dải cực hẹp cho thang 0.5–5.0. Hệ số skewness âm xác nhận: phân phối **positive bias**, không phải phân phối chuẩn.

The Cinema Logic - Lý giải một phim

Khán giả trên MovieLens là **self-selected cinephiles** - họ chủ động chọn phim dựa trên trailer, review, và gợi ý. Đây là *selection bias*: “Tôi chỉ chấm phim tôi đã chọn xem, và tôi chỉ chọn xem phim tôi nghĩ mình sẽ thích.” Rating 4.0 là “vùng an toàn” - đủ cao để thể hiện hài lòng, nhưng giữ lại 5 sao cho những kiệt tác.

The Data-Driven Action - So what?

Normalize trước khi dùng. Rating 3.0 trên MovieLens thực chất là “dưới trung bình”. Hệ thống gợi ý cần **trừ đi mean rating của từng user** (user-mean normalization). Không dùng ngưỡng cố định “4+ = tốt” mà phải dùng ngưỡng tương đối theo hành vi từng người.

Phát hiện: “Hiệu ứng số nguyên” (Integer Effect)

Các thanh bar tại **3.0, 4.0, 5.0** (số nguyên) cao hơn đáng kể so với các thanh 2.5, 3.5, 4.5 (nửa sao). Đây là **cognitive anchoring** - con người có xu hướng mặc định chọn số tròn trước, chỉ dùng nửa sao khi cân nhắc kỹ. Hệ quả: rating 4.0 bao gồm cả “3.7 làm tròn lên” lẫn “4.0 thực sự” → **nhiều đo lường** (measurement noise) ẩn trong dữ liệu rời rạc. Mô hình nên coi rating là *ordinal*, không phải *interval*.

3.2 Histogram - Số đánh giá mỗi người dùng

Câu hỏi

Mức độ tham gia của người dùng phân bố như thế nào? Có “power users” không?



Hình 3.2: Histogram: Phân bố số đánh giá mỗi người dùng

The Insight - Cái nhìn thống kê

Phân phối **long-tail** tuân theo power law. Median $\ll$ Mean. Top 10% users đóng góp phần lớn dữ liệu. Max ratings/user > 9,000 - trong khi đa số user chỉ đánh giá vài chục phim.

The Cinema Logic - Lý giải một phim

Sự phân hóa giữa **Casual viewers** - người chỉ rate blockbuster cuối tuần, và **Letterboxd completionists** - những một phim log mọi thứ từ phim Hàn đến Tarkovsky. Power users giống “Roger Ebert thu nhỏ” - tạo ra phần lớn tín hiệu, nhưng sở thích có thể *không đại diện* cho đám đông.

The Data-Driven Action - So what?

Cân bằng tiếng nói. Mô hình CF sẽ bị “chi phối” bởi power users. Giải pháp: (1) **User-weighting** - giảm trọng số users quá nhiều ratings, (2) **Capping** ≤ 500 ratings/user khi train, (3) **Gamification** khuyến khích casual viewers rate thêm.


Phát hiện: Bất bình đẳng Pareto trong dữ liệu hành vi

Phân phối này tuân theo **nguyên lý Pareto cực đoan**: ước tính top 10% users đóng góp >50% tổng ratings. Hệ số **Gini** (thường dùng đo bất bình đẳng thu nhập) nếu áp dụng cho ratings/user sẽ rất cao (>0.7). Đây không phải anomaly - đây là **quy luật phổ quát** của mọi nền tảng UGC (User-Generated Content): Wikipedia, StackOverflow, Amazon Reviews đều có cùng hình dạng. Nhận ra quy luật này giúp ta ngừng cố “sửa” phân bố mà thay vào đó **thiết kế hệ thống thích nghi** với nó.

3.3 Boxplot - Rating theo thể loại phim

Câu hỏi

Thể loại nào được “yêu” nhất? Thể loại nào gây “chia rẽ” nhất?



Hình 3.3: Boxplot: Rating theo 10 thể loại phổ biến nhất

The Insight - Cái nhìn tổng kê

Film-Noir và War: **median cao nhất** ($\sim 3.8-4.0$), IQR hẹp $\rightarrow$ đồng thuận cao.
 Horror: **median thấp nhất, IQR rộng nhất** $\rightarrow$ phân cực mạnh. Drama/Action ổn định quanh 3.0–4.0.

The Cinema Logic - Lý giải một phim

Film-Noir (*The Godfather*, *Casablanca*) và War (*Schindler's List*) = “prestige cinema”. Người xem là cinephiles kỹ tính, biết mình tìm kiếm gì. Horror? Thể loại phân cực nhất: từ *The Shining* (cult classic) đến slasher phim B. Fan cuồng cho 5, casual viewer cho 1 - spread rộng là tất yếu.

The Data-Driven Action - So what?

Thể loại = taste profile proxy. Horror cần **niche targeting** - chỉ gợi ý cho fans đã chứng minh bằng lịch sử xem. Film-Noir/War nên gợi ý cho users có pattern “thích phim chất lượng, không quan tâm phổ biến”.

3.4 Heatmap - Ma trận tương quan

(Đã trình bày trong Chương 2, mục 2.7 - xem Hình 2.1)

The Insight - Cái nhìn tổng kê

rating $\leftrightarrow$ avg_rating: tương quan Pearson mạnh nhất ($r > 0.3$). year và num_genres có $r \approx 0$ - gần như **không tương quan tuyến tính** với rating.

The Cinema Logic - Lý giải một phim

“A great film is a great film” - năm sản xuất không quyết định khán giả có thích hay không. *Parasite* (2019) và *Citizen Kane* (1941) đều được yêu thích, cách nhau 80 năm. Điều quyết định là **chất lượng nội tại** - wisdom of the crowd.


The Data-Driven Action - So what?

Feature selection: avg_rating hữu ích nhất. year/num_genres có thể loại bỏ. Cẩn thận **data leakage** - avg_rating chứa thông tin từ target variable, chỉ dùng trong EDA.

3.5 Pairplot (Seaborn)

Câu hỏi

Tổng quan mối quan hệ giữa các biến liên tục?



Hình 3.4: Pairplot: rating / year / num_genres / avg_rating

The Insight - Cái nhìn thống kê

Rating: multi-modal ở 3.0, 3.5, 4.0. **avg_rating** hội tụ 3.5–4.0. **year** rộng 1900–2024, tập trung sau 1990. **num_genres:** mode = 2–3.

The Cinema Logic - Lý giải một phim


Ba đỉnh 3.0/3.5/4.0 = **tâm lý “half-star”**: không ai cho 3.7 - họ hoặc 3.5 (“ờ, được”) hoặc 4.0 (“thích đấy!”). Vùng 3.5–4.0 là “landing zone” mặc định - nơi phim mainstream cần đạt để không bị coi là thất bại.

The Data-Driven Action - So what?

Multi-modal $\Rightarrow$ **Gaussian đơn không phù hợp**. Dùng **Gaussian Mixture Model** hoặc **ordinal regression**. Vùng 3.5–4.0 là baseline - chỉ phim ngoài vùng này mới thực sự informative.

3.6 Bar chart - Top 10 thể loại phổ biến**Câu hỏi**

Thể loại nào thống trị MovieLens?



Hình 3.5: Top 10 thể loại phim phổ biến nhất

The Insight - Cái nhìn tổng kê

Drama, Comedy, Action - “The Big Three” - chiếm top 3. Drama gấp $\sim 4\times$ thể loại thứ 10. Genre ratings cũng tuân theo long-tail.

The Cinema Logic - Lý giải một phim

DNA của Hollywood: Drama = “mẹ đẻ” mọi câu chuyện, Comedy = “thức ăn nhanh” giải trí, Action = “cỗ máy blockbuster”. Chúng là những gì Netflix, Disney+ sản xuất nhiều nhất. Documentary hay Animation phục vụ *niche audience*.

The Data-Driven Action - So what?

Genre bias alert! Mô hình sẽ “giỏi” Drama/Comedy/Action nhưng “mù” với niche genres. Giải pháp: **genre-aware stratified sampling** đảm bảo mỗi thể loại có representation tối thiểu khi train.


Phát hiện: Định luật Zipf trong Thể loại phim

Phân bố genre tuân theo **Zipf’s Law**: thể loại hạng k có lượt đánh giá tỉ lệ $\sim 1/k$ so với hạng 1. Drama (hạng 1) $\approx 4 \times$ hạng 10 - khớp chính xác. Đây cũng quy luật chi phối phân bố từ vựng trong ngôn ngữ tự nhiên, phân bố dân số thành phố, và traffic website. Hệ quả: **long-tail không bao giờ biến mất** - bạn không thể “san phẳng” nó bằng marketing. Chiến lược đúng: embrace long-tail bằng **niche recommendation** cho users có sở thích đặc biệt.

3.7 Bar chart - Rating TB theo thể loại

Câu hỏi

Phổ biến nhất có phải là hay nhất? Thể loại nào là “darling” của giới mộ phim?



Hình 3.6: Rating TB theo thể loại (≥ 1000 đánh giá)

The Insight - Cái nhìn tổng kê

Film-Noir, Documentary, War dẫn đầu. Horror xếp cuối. Drama - phổ biến nhất - chỉ giữa bảng. **Popularity $\neq$ Quality.**

The Cinema Logic - Lý giải một phim

Film-Noir (*Double Indemnity*, *Sunset Boulevard*) thu hút “cinophile kén chọn” - người *chủ động tìm* chất lượng. Horror? Từ kiệt tác A24 (*Hereditary*) đến slasher rẻ tiền. Fan cuồng 5, casual 1 $\rightarrow$ trung bình bị “kéo xuống”.

The Data-Driven Action - So what?

Cần 2 metrics riêng. (1) “Popular picks” - optimize engagement, (2) “Hidden gems” - optimize satisfaction. Dùng **genre-specific baseline**: Horror 3.0 = “khá tốt”, Film-Noir 3.0 = “dưới kỳ vọng”.


Cảnh báo: Nguy cơ Simpson's Paradox

Film-Noir rating cao nhất, nhưng **sample size nhỏ nhất**. Khi một thể loại chỉ có vài nghìn ratings từ nhóm cinephile kén chọn, rating TB bị **inflated** bởi selection effect. Nếu bắt tất cả users MovieLens xem Film-Noir, rating TB có thể *giảm đáng kể*. Đây là **Simpson's Paradox** tiềm tàng: xu hướng đảo ngược khi thay đổi phạm vi quan sát. Luôn kiểm tra n (sample size) trước khi kết luận “thể loại X tốt hơn thể loại Y”.

3.8 Pie chart - Phân bố trạng thái isSeen

Câu hỏi

Trong Belief Data, bao nhiêu phim user đã xem / chưa xem / bỏ qua? Tỷ lệ phản hồi thực sự là bao nhiêu?



Hình 3.7: Phân bố trạng thái isSeen trong Belief Data

The Insight - Góc nhìn Thống kê

Trạng thái phân phối thể hiện sự **mất cân bằng cực đoan (Extreme Class Imbalance)**. Khối lượng dữ liệu “không phản hồi” ($isSeen=-1$) chiếm lĩnh tuyệt đối ở mức **98.8%**, trong khi **tín hiệu thu thập thực tế (Signal)** chỉ giới hạn ở mức **1.2%** - chia thành “Chưa xem” ($\sim 0.9\%$) và “Đã xem” ($\sim 0.3\%$). Tỷ lệ *signal-to-noise* cực thấp: cứ 100 lần hiển thị câu hỏi, chỉ thu được ~ 1.2 phản hồi.

The Domain Logic - Bản chất Hệ thống

Cần nhớ lại đặc tả kỹ thuật của bản cập nhật **MovieLens Belief Release 2**: nhóm nghiên cứu *chủ động ghi nhận* cả những trường hợp hệ thống hiển thị câu hỏi khảo sát niềm tin nhưng **người dùng bỏ qua** ($isSeen = -1$). Trong môi trường thương mại điện tử hoặc hệ thống gợi ý thực tế, tỷ lệ chuyển đổi (**Conversion Rate**) cho các tương tác chủ động ở mức 1%–2% là một chỉ số **hoàn toàn bình thường**. Nhìn chung, người tiêu dùng có xu hướng *bỏ qua* các yêu cầu cung cấp thông tin tốn thời gian - đây là quy luật hành vi phổ quát, không phải lỗi thiết kế.

The Data-Driven Action - Giải pháp Kỹ thuật

Đây là lúc vai trò của kỹ sư dữ liệu thể hiện rõ nhất:

Về mặt Mô hình hóa (Modeling): Đưa trực tiếp cấu trúc dữ liệu này vào huấn luyện sẽ kích hoạt **bẫy độ chính xác ảo (Accuracy Paradox)**. Một mô hình phân loại chỉ cần dự báo toàn bộ là “Không trả lời” cũng sẽ đạt accuracy 98.8%. Kiến trúc sư dữ liệu bắt buộc phải can thiệp bằng **tái lấy mẫu** (Oversampling/Undersampling) hoặc tinh chỉnh **hàm mất mát** (Loss function) bằng tham số **class weights**.

Phê bình Trực quan hóa - Visualization Critique


Lựa chọn **biểu đồ tròn (Pie chart)** cho phân phối tỷ lệ 99:1 là một **quyết định sai lầm về mặt nghiệp vụ trình bày**. Các phân lớp siêu nhỏ (“Chưa xem”, “Đã xem”) bị ép thành những đường kẻ gần như vô hình, **triệt tiêu hoàn toàn khả năng so sánh trực quan**. Biểu đồ tròn chỉ hiệu quả khi các phân lớp có kích thước *cùng bậc độ lớn* (ví dụ: 40%/35%/25%).

Giải pháp kỹ thuật chuẩn xác: Thay thế bằng **Bar chart kết hợp thang đo logarit** (log scale) ở trục tung để khuếch đại các nhóm thiểu số. Hoặc dùng **waffle chart** (biểu đồ ô vuông) nơi mỗi ô đại diện 1% - khán giả sẽ thấy rõ 1 ô màu giữa 99 ô xám. Đây là bài học quan trọng: *biểu đồ đúng loại quan trọng hơn biểu đồ đẹp*.

3.9 Violin plot - Phân bố Rating theo nhóm

Câu hỏi

Phân bố chi tiết rating trong 3 nhóm Thấp / Trung bình / Cao?



Hình 3.8: Violin Plot: Phân bố Rating theo nhóm phân loại

The Insight - Cái nhìn tổng kê

“Cao” (≥ 4) chiếm $\sim 45\%$, “Thấp” (≤ 2) chỉ $\sim 12\%$. Class imbalance $\sim 4:1$. Violin “Cao” phình to ở 4.0 = điểm attractor.

The Cinema Logic - Lý giải một phim


Hiệu ứng “I only finish what I like”: khán giả tự chọn lọc phim. Rating thấp hiếm vì: (1) Tắt phim dở trước khi kết thúc (không rate), (2) “sunk cost” - đã xem hết thì cho 3 thay vì 1 để không cảm thấy phí thời gian. Violin mỏng ở vùng Thấp = vùng “ghosting”.

The Data-Driven Action - So what?

Class imbalance $\Rightarrow$ **stratified sampling**. Dùng **SMOTE** hoặc **class weighting**. Segment users: “khó tính”, “trung dung”, “dễ tính” - mỗi nhóm cần strategy gợi ý riêng.

3.10 Line chart - Xu hướng Rating theo năm**Câu hỏi**

Phim cũ hay phim mới được yêu thích hơn?



Hình 3.9: Xu hướng Rating TB theo năm phát hành

The Insight - Cái nhìn thống kê

Phim trước 1960: rating ~ 3.8 – 4.0 , n nhỏ. Phim 1990–2020: rating ~ 3.3 – 3.5 , volume lớn. **Survivorship bias** rõ rệt.

The Cinema Logic - Lý giải một phim

Không phải “phim xưa hay hơn” - mà **chỉ kiệt tác sống sót**. Không ai rate phim B-movie tệ từ 1953. Những gì còn lại: *Casablanca*, *Citizen Kane*, *12 Angry Men* - toàn masterpieces. Survivorship bias kinh điển: ta chỉ thấy “người sống sót”, không thấy hàng nghìn phim bị lãng quên.

The Data-Driven Action - So what?

Dùng **Bayesian average** (pha trộn rating phim với global mean, trọng số theo n). Cho time-aware recommendation: phim cũ rating cao nhưng có thể “lỗi thời” $\rightarrow$ cần **recency factor**.


Phát hiện: Dual-axis chart - Tiết lộ Confounding Variable

Biểu đồ trục kép (rating TB + volume) tiết lộ điều mà single-axis không thể: **biến nhiễu ẩn (confounding variable)** là *lượng data*. Vùng rating cao nhất (>3.8) trùng chính xác với vùng volume thấp nhất ($<1,000$ ratings). Đây là dấu hiệu kinh điển của **small-sample inflation**: khi n nhỏ, variance cao $\rightarrow$ mean bị kéo lệch bởi vài ratings cực đoan. Dual-axis chart ở đây không chỉ “đẹp hơn” - nó **ngăn chặn kết luận sai** (“phim cũ hay hơn phim mới”) bằng cách buộc người đọc nhìn cả hai chiều cùng lúc.

3.11 Scatter plot - User Predict vs System Predict

Câu hỏi

Dự đoán của người dùng có khớp với hệ thống MovieLens?



Hình 3.10: Dự đoán hệ thống vs Dự đoán người dùng

The Insight - Cái nhìn thống kê

Đa số điểm **phía trên** $y = x$: mean gap $\approx +0.3$. Hơn 60% user dự đoán cao hơn system. Hệ thống bảo thủ hơn con người.

The Cinema Logic - Lý giải một phim

“**Trailer Effect**”: mỗi phim đều có trailer hấp dẫn, poster đẹp, tagline gợi cảm xúc. Con người bị cuốn vào *sự hứa hẹn* - “phim này chắc hay lắm!” Hệ thống, ngược lại, dựa trên cold data: biết rằng phần lớn phim chỉ “ổn”. Đây là *trái tim lạc quan* vs *bộ não tỉnh táo*.

The Data-Driven Action - So what?

Dùng gap (user – system) để dự đoán *mức độ thất vọng*. Nếu user: 4.5, system: 3.0 $\Rightarrow$ disappointment risk cao. Hệ thống có thể “manage expectations” - hiển thị system prediction kèm user belief.


Phát hiện: Bất đối xứng một chiều (One-Sided Asymmetry)

Đám mây điểm không chỉ nằm trên đường $y = x$ - nó còn **bất đối xứng**: phần “user dự đoán cao hơn system” dày đặc hơn *rất nhiều* so với phần “user dự đoán thấp hơn”. Gần như **không có ai tự nguyện dự đoán mình sẽ ghét phim**. Điều này cho thấy belief data bị **censored (cắt cụt) ở đuôi trái**: người dùng *không trả lời* cho phim họ nghĩ sẽ tệ, thay vì cho 1-2. Hệ quả: toàn bộ belief distribution là **biased sample** - chỉ capture nửa lạc quan của phổ dự đoán.

3.12 KDE plot - Rating thực vs Beliefs

Câu hỏi

Phân bố dự đoán khác rating thực tế không?



Hình 3.11: So sánh: Rating thực tế vs User Beliefs (KDE)

The Insight - Cái nhìn tổng kê

Belief dịch phải $\sim 0.3-0.5$. Mật độ đuôi trái (≤ 2.0) thấp hơn **rất nhiều** ở beliefs. Hai phân bố *cùng hình dạng, khác vị trí trung tâm*.

The Cinema Logic - Lý giải một phim

“Nobody goes into a movie expecting to hate it” - **optimism bias có hệ thống**. Khán giả gần như không bao giờ dự đoán 1–2. Nếu nghĩ phim tệ, *họ đã không xem rồi*. Belief chỉ capture sự lạc quan - vùng bí quan là “terra incognita”.

The Data-Driven Action - So what?

Debiasing bắt buộc khi dùng belief data. Dùng **quantile mapping** calibrate belief $\rightarrow$ rating distribution. Hoặc beliefs làm **prior** trong Bayesian framework, update bằng actual ratings.


Phát hiện: Phân phối bị cắt cụt trái (Left-Censored Distribution)

So sánh hai đường KDE cho thấy belief distribution không chỉ “dịch phải” - nó còn bị **cắt cụt (censored) ở đuôi trái**. Rating thực có mật độ rõ ràng ở vùng 0.5–2.0, nhưng belief gần như **bằng 0** ở vùng này. Đây là hiện tượng **left-censoring** trong thống kê: không phải người dùng không có dự đoán tiêu cực - mà họ *từ chối bày tỏ* nó (chọn “bỏ qua” thay vì cho 1). Belief data do đó là **truncated sample** - bất kỳ mô hình nào dùng nó đều cần **Tobit regression** hoặc tương đương để handle censoring.

3.13 Countplot - Mức độ chắc chắn (Certainty)

Câu hỏi

Người dùng tự tin đến mức nào khi dự đoán?



Hình 3.12: Phân bố mức độ chắc chắn (userCertainty)

The Insight - Cái nhìn thống kê

Mode = 3. Certainty 3-4 chiếm >70%. Rất ít chọn 5 hoặc 1. Phân bố **unimodal**, gần đối xứng quanh 3.

The Cinema Logic - Lý giải một phim

Certainty 3 = “I’ve seen the trailer, read reviews, I *think* I’ll like it but who knows.”
Mức “honest uncertainty” - khán giả biết giới hạn của mình. Ngay cả đạo diễn yêu thích cũng có thể ra phim dở (Ridley Scott sau *Gladiator*). Certainty thấp thường rơi vào phim ngoại quốc/indie - “terra incognita” của khán giả.

The Data-Driven Action - So what?

Certainty = confidence weight trong ensemble model. Dự đoán từ user chắc chắn (4-5) đáng tin hơn user đoán bừa (1-2). Research: “user tự tin” có đúng hơn không? Nếu có → certainty là gold feature.


Phát hiện: Metacognition và câu hỏi Dunning-Kruger

Phân bố certainty hội tụ ở 3 gợi lên câu hỏi nghiên cứu thú vị: **user “tự tin” (certainty 5) có dự đoán chính xác hơn user “khiêm tốn” (certainty 2–3) không?** Nếu câu trả lời là *không* → đây là hiệu ứng **Dunning-Kruger** trong điện ảnh: người biết ít về phim lại quá tự tin. Nếu *có* → certainty là một dạng **metacognitive signal** quý giá. Validation thực nghiệm: so sánh $|\text{userPredict} - \text{actualRating}|$ chia theo certainty level. Đây là **research contribution tiềm năng** chưa ai khai thác trong paper gốc.

3.14 Grouped Bar - Rating theo thập kỷ

Câu hỏi

Thập kỷ vàng của điện ảnh là khi nào (theo con số)?



Hình 3.13: Rating TB theo thập kỷ phát hành

The Insight - Cái nhìn tổng kê

1920s–1940s: rating TB >3.8 nhưng n nhỏ. 2000s–2010s: volume lớn nhất, rating ~3.4–3.5.

The Cinema Logic - Lý giải một phim

1920s–1940s trên MovieLens chỉ còn “crème de la crème”: *Metropolis*, *Casablanca*, *The Wizard of Oz*. “Thập kỷ vàng” cũng sản xuất vô số phim tệ - nhưng thời gian đã xóa sổ. 2010s rating thấp hơn không phải vì phim kém - mà vì ta nhìn thấy *mọi thứ*, kể cả phim sẽ bị lãng quên sau 20 năm.


The Data-Driven Action - So what?

Dùng **decade-adjusted baseline**: tính z-score *trong từng thập kỷ* thay vì so sánh trực tiếp. **Time-decay weighting**: rating gần đây trọng số cao hơn. Cold-start cho phim mới 2020s là thách thức lớn.

3.15 Heatmap - Ma trận User-Item (Sparsity)

Câu hỏi

Ma trận đánh giá “thưa” đến mức nào?



Hình 3.14: Ma trận User-Item (50×50) - Ô trắng = Chưa đánh giá

The Insight - Cái nhìn tổng kê

Sparsity > 99%. Heatmap gần như toàn trắng. “Sa mạc dữ liệu” - mỗi user chỉ xem phần cực nhỏ.

The Cinema Logic - Lý giải một phim

85,000+ phim - ngay cả cinephile “cày” nhất (3 phim/ngày) cũng cần ~78 năm xem hết. Ma trận trắng = **information overload**: catalog phim toàn cầu phình nhanh hơn khả năng tiêu thụ. Mỗi ô trắng = một phim khán giả *chưa bao giờ biết đến*.

The Data-Driven Action - So what?

User-based CF thuần túy sẽ thất bại. Bắt buộc: **Matrix Factorization** (SVD, NMF) hoặc **Deep Learning** (NCF, Autoencoders). Kết hợp **content-based filtering** → **hybrid recommender**.


Phát hiện: Định lượng Cold-Start - “Vùng chết” của hệ thống

Sparsity >99% nghe trừu tượng. Hãy cụ thể hóa: với ~4,400 users và ~56,000 movies (sau lọc), ma trận có ~246 triệu ô, nhưng chỉ ~1.5 triệu ô có data. Trung bình mỗi user chỉ đánh giá ~340 phim / $56,000 = 0.6\%$ **catalog**. Nghĩa là 99.4% phim là “vùng chết” đối với mỗi user - hệ thống phải *đoán* toàn bộ. Đây không phải “thách thức” - đây là **bản chất cốt lõi** khiến recommender systems tồn tại. Nếu users đã xem hết mọi phim, ta không cần gợi ý nữa.

3.16 Horizontal Bar - Top 15 phim phổ biến nhất

Câu hỏi

Phim nào được đánh giá nhiều nhất và chất lượng ra sao?



Hình 3.15: Top 15 phim phổ biến nhất (màu theo rating)

The Insight - Cái nhìn tổng kê

Top 15 đều > 3.5 . Phim phổ biến = chất lượng cao. Màu xanh thống trị. Không có “phim tệ nhưng nổi tiếng”.

The Cinema Logic - Lý giải một phim

“**The Shawshank Effect**”: *Forrest Gump*, *Pulp Fiction*, *The Matrix* - không chỉ “phim hay” mà là “phim ai cũng đã xem”. Chúng là *cultural touchstones* - “common ground” của mọi thị hiếu. Cả casual lẫn cinephile đều rate, đều rate cao.

The Data-Driven Action - So what?

“**Rich get richer**” = **popularity bias**. Cần **exploration**: (1) Epsilon-greedy hoặc Thompson Sampling inject phim ít biết, (2) **Min-ratings threshold** (≥ 30) khi tính avg_rating - tránh phim “5.0 từ 2 users”.


Phát hiện: Hiệu ứng “Thời kỳ Vàng 1994” (Temporal Clustering)

Quan sát kỹ top 15: đa số tập trung trong giai đoạn **1993–1999** (*Shawshank 1994*, *Pulp Fiction 1994*, *Forrest Gump 1994*, *The Matrix 1999*, *Fight Club 1999*). Đây là **cohort effect**: thế hệ users MovieLens ban đầu (gia nhập khoảng 2000) lớn lên với những phim này - chúng trở thành “phim nền tảng” được rate đầu tiên khi tạo tài khoản. Hệ quả: top movies không chỉ phản ánh chất lượng phim mà còn phản ánh **demographics của user base**. Nếu MovieLens ra đời năm 2015, top list có thể hoàn toàn khác.

3.17 Boxplot - Phát hiện Outliers

Câu hỏi

Có outlier đáng lo ngại không?



Hình 3.16: Boxplot: Rating / Ratings per User / Ratings per Movie

The Insight - Cái nhìn tổng kê

Rating: thang cố định, no outlier. **Ratings/User:** power users >5,000. **Ratings/Movie:** blockbusters >2,000. Outliers = hành vi thực, không phải lỗi.


The Cinema Logic - Lý giải một phim

Power users = “**Letterboxd completionists**”: 9,000+ ratings $\approx$ 3 phim/ngày, 8 năm. Movie outliers = blockbusters: *The Dark Knight*, *Inception*. Bản chất entertainment: *a few giants, millions of mice*.

The Data-Driven Action - So what?

Không loại bỏ, nhưng kiểm soát. Power users: **capping** (≤ 500 gần nhất). Blockbusters: **popularity penalty** để phim ít biết có cơ hội. Outliers phản ánh hành vi thực - ta quản lý, không xóa.

3.18 Dashboard tổng hợp



Hình 3.17: Dashboard tổng quan - MovieLens Belief 2024

The Insight - Cái nhìn tổng kê

Dashboard 6 panel: (1) Rating lệch trái, (2) Drama/Comedy thống trị, (3) Trend giảm theo năm, (4) Belief data cực thừa, (5) User lạc quan hơn system, (6) Certainty mode 3–4.

The Cinema Logic - Lý giải một phim

Nếu 18 biểu đồ là 18 chương phim, dashboard là “**movie trailer**” - nén câu chuyện vào 30 giây. Mỗi panel = một plot point: positive bias, genre dominance, survivorship, data scarcity, optimism, moderate confidence. “Elevator pitch” của toàn bộ phân tích.

The Data-Driven Action - So what?

Deploy interactive version (Plotly/Streamlit). Tích hợp **MLOps pipeline**: tự cập nhật + alert khi distribution shift. Dashboard = **monitoring tool**, không chỉ báo cáo tĩnh.

Chương 4

KẾT LUẬN CHUNG

“Data are just summaries of thousands of stories - tell a few of those stories to help make the data meaningful.”

- Chip & Dan Heath

Phân tích định lượng chưa bao giờ là điểm kết thúc. Đích đến cuối cùng của chúng ta là con người. Ở chương khép lại này, những con số khô khan sẽ lùi bước, nhường chỗ cho những Insight chân thực nhất về tâm lý hành vi. Chúng ta gom nhặt từng mảnh ghép của sự thiên vị, của niềm tin, để dệt nên một câu chuyện có sức nặng, có khả năng định hướng hành động (*Actionable*) - bởi dữ liệu chỉ thực sự sống khi nó giúp ta đưa ra được một quyết định tốt hơn ngày hôm qua.

4.1 Câu chuyện MovieLens qua 18 biểu đồ

Qua 18 biểu đồ, MovieLens Belief 2024 kể câu chuyện hoàn chỉnh về *hành trình khám phá qua các con số*. Mỗi biểu đồ phân tích 3 lớp - thống kê, điện ảnh, kỹ thuật:

1. **Positive bias (Hình 1, 9)**: 67%+ ratings ≥ 3.0 . Self-selected cinephiles chỉ xem phim mình thích. $\rightarrow$ *Normalize per-user*.
2. **Power-law users (Hình 2, 17)**: “Letterboxd completionists” vs casual viewers. $\rightarrow$ *Capping + weighting*.
3. **Genre as identity (Hình 3, 6, 7)**: Prestige darlings vs polarizing wild cards. Popular $\neq$ Beloved. $\rightarrow$ *Genre-specific baselines*.
4. **Timeless quality (Hình 4, 5)**: Year ≈ 0 correlation. Multi-modal ratings. $\rightarrow$ *Mixture models*.

5. **Survivorship bias (Hình 10, 14):** Chỉ classics sống sót. “Golden Age” = ảo giác thống kê. → *Bayesian average*.
6. **Optimism bias (Hình 11, 12):** +0.3 gap. “Trailer effect”. → *Debiasing + calibrate*.
7. **Precious belief data (Hình 8, 13):** <1% hữu ích. Certainty mode 3–4. → *Semi-supervised + confidence weighting*.
8. **The Sparse Desert (Hình 15):** 99%+ trống. → *Hybrid recommender*.
9. **Rich-get-richer (Hình 16):** “Shawshank Effect”. → *Exploration mechanism*.

4.2 Bảng tổng hợp: Từ Insight đến Action

Bảng 4.1: Cinema Logic → Engineering Action

Phát hiện	Cinema Logic	Engineering Action
Positive bias	Selection bias: chỉ xem phim mình thích	Normalize per-user
Long-tail	Completionists vs casuals	Capping + weighting
Genre polarity	Prestige vs polarizing	Genre-specific baseline
Survivorship	Chỉ classics sống sót	Bayesian average
Optimism	“Trailer effect”	Calibrate + debiasing
Sparsity 99%	Quá nhiều phim, quá ít thời gian	Hybrid recommender
Popularity bias	“Shawshank Effect”	Exploration mechanism

4.3 Hạn chế

- MovieLens users = *self-selected cinephiles*, không phải random sample.
- Belief data cực thừa (<1% hữu ích) - kết luận optimism bias dựa trên mẫu nhỏ.
- Survivorship bias không thể loại bỏ hoàn toàn khi phân tích phim cũ.
- Chỉ dựa trên explicit ratings - bỏ qua implicit signals (click, watch time).

Tài liệu tham khảo

1. Aridor, G., Goncalves, D., Kong, R., Culver, D., & Konstan, J.A. (2024). *The MovieLens Beliefs Dataset: Collecting Pre-Choice Data for Online Recommender Systems*. Proceedings of the 18th ACM Conference on Recommender Systems (RecSys 2024).
2. Chawla, N.V., Bowyer, K.W., Hall, L.O., & Kegelmeyer, W.P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
3. Cleveland, W.S. (1993). *Visualizing Data*. Hobart Press. ISBN: 978-0963488404.
4. Deming, W.E. (1986). *Out of the Crisis*. MIT Press. ISBN: 978-0262541152.
5. Few, S. (2012). *Show Me the Numbers: Designing Tables and Graphs to Enlighten* (2nd ed.). Analytics Press. ISBN: 978-0970601971.
6. GroupLens Research. (2024). *MovieLens Belief 2024 Dataset*. https://grouplens.org/datasets/movielens/ml_belief_2024/
7. Heath, C. & Heath, D. (2007). *Made to Stick: Why Some Ideas Survive and Others Die*. Random House. ISBN: 978-1400064281.
8. Hunter, J.D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95. DOI: 10.1109/MCSE.2007.55.
9. Kruger, J. & Dunning, D. (1999). Unskilled and Unaware of It: How Difficulties in Recognizing One’s Own Incompetence Lead to Inflated Self-Assessments. *Journal of Personality and Social Psychology*, 77(6), 1121–1134.
10. McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.
11. Newman, M.E.J. (2005). Power laws, Pareto distributions and Zipf’s law. *Contemporary Physics*, 46(5), 323–351. DOI: 10.1080/00107510500052444.
12. Simpson, E.H. (1951). The Interpretation of Interaction in Contingency Tables. *Journal of the Royal Statistical Society, Series B*, 13(2), 238–241.

13. Tobin, J. (1958). Estimation of Relationships for Limited Dependent Variables. *Econometrica*, 26(1), 24–36.
14. Tufte, E.R. (2001). *The Visual Display of Quantitative Information* (2nd ed.). Graphics Press. ISBN: 978-0961392147.
15. Tukey, J.W. (1977). *Exploratory Data Analysis*. Addison-Wesley. ISBN: 978-0201076165.
16. Tversky, A. & Kahneman, D. (1974). Judgment under Uncertainty: Heuristics and Biases. *Science*, 185(4157), 1124–1131. DOI: 10.1126/science.185.4157.1124.
17. Waskom, M.L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. DOI: 10.21105/joss.03021.
18. Wickham, H. (2010). A Layered Grammar of Graphics. *Journal of Computational and Graphical Statistics*, 19(1), 3–28. DOI: 10.1198/jcgs.2009.07098.
19. Wilke, C.O. (2019). *Fundamentals of Data Visualization*. O'Reilly Media. ISBN: 978-1492031086.
20. Zipf, G.K. (1949). *Human Behavior and the Principle of Least Effort*. Addison-Wesley.

– HẾT BÁO CÁO –