ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT

KHOA TOÁN KINH TẾ

Học kỳ II/2025 - 2026

GIỚI THIỆU VỀ MÁY HỌC

TÊN ĐỀ TÀI:

SO SÁNH CÁC THUẬT TOÁN COLLABORATIVE FILTERING TRONG DỰ ĐOÁN ĐÁNH GIÁ PHIM TRÊN BỘ DỮ LIỆU MOVIELENS BELIEF 2024

GVHD : ThS. TRƯƠNG QUANG NHẬT

MÃ HỌC PHẦN : 252BMA4006

TÊN SINH VIÊN : MAI HOÀNG NGỌC HÂN

MSSV : K244131500

TP.HCM, THÁNG 3/2026

Mục lục

Tóm tắt **5**

Lời cảm ơn **6**

1 GIỚI THIỆU **7**

1.1 Động lực nghiên cứu 7

1.2 Các nghiên cứu liên quan 7

1.3 Mục tiêu nghiên cứu 8

1.4 Câu hỏi nghiên cứu 8

1.5 Phát biểu bài toán 9

1.6 Các model được chọn 9

1.7 Cấu trúc bài báo cáo 10

2 CƠ SỞ LÝ THUYẾT VÀ MÔ HÌNH **12**

2.1 Tổng quan Collaborative Filtering 12

2.2 SVD - Singular Value Decomposition (Model chính) 13

2.2.1 Ý tưởng của SVD trong Recommender Systems 13

2.2.2 Công thức toán học - Step by Step 14

2.3 KNN User-Based Collaborative Filtering 20

2.3.1 Tổng quan 20

2.3.2 Công thức toán học 20

2.4 SVD++ (SVD mở rộng với Implicit Feedback) 22

2.4.1 Tổng quan 22

2.4.2 Công thức toán học 23

2.5 KNN Item-Based Collaborative Filtering 23

2.5.1 Tổng quan: Từ User-Based sang Item-Based 23
2.5.2 Công thức toán học 24
2.6 NMF - Non-negative Matrix Factorization 25
2.6.1 Tổng quan 25
2.6.2 Công thức toán học 26
2.6.3 Công thức toán học 27
2.7 BaselineOnly - Mô hình tham chiếu 28
2.7.1 Tổng quan 28
2.7.2 Công thức toán học 29
2.7.3 Tối ưu bias bằng ALS (Alternating Least Squares): 29
2.8 NCF - Neural Collaborative Filtering (Deep Learning) 30
2.8.1 Tổng quan 30
2.8.2 Từ dot product đến neural network 31
2.8.3 Công thức so sánh 31
2.8.4 Kiến trúc NCF 31
2.8.5 Tối ưu hóa 32
2.8.6 Câu hỏi nghiên cứu 33
2.9 Phương pháp đánh giá: Cross-Validation và Time-Series CV 33
2.9.1 Tại sao cần Cross-Validation? 33
2.9.2 K-Fold Cross-Validation 33
2.9.3 Time-Series Cross-Validation (Expanding Window) 34

3 DỮ LIỆU VÀ KẾT QUẢ 36

3.1 Nguồn dữ liệu 36
3.2 Mô tả các file dữ liệu 37
3.2.1 File user_rating_history.csv - Lịch sử đánh giá phim 37
3.2.2 File movies.csv - Thông tin phim 37
3.2.3 File belief_data.csv - Dữ liệu niềm tin (Beliefs) - ĐẶC BIỆT . . . 38
3.2.4 File user_recommendation_history.csv - Lịch sử gợi ý 38
3.2.5 File movie_elicitation_set.csv - Tập phim dùng để hỏi beliefs . . . 39
3.3 Thống kê mô tả 39

3.3.1 Hình minh họa: Phân bố dữ liệu 40
3.4 Xử lý dữ liệu 44
3.4.1 Kiểm tra dữ liệu rỗng (Missing Values) 44
3.4.2 Kiểm tra dữ liệu trùng lặp (Duplicates) 45
3.4.3 Kiểm tra tính hợp lý của dữ liệu 45
3.4.4 Loại bỏ outliers 46
3.4.5 Feature Engineering - Thêm cột thông tin 47
3.4.6 Phân tích tương quan 48
3.4.7 Tách dữ liệu Train/Test 49
3.5 Kết quả huấn luyện (Single Split 80/20) 50
3.5.1 Hình minh họa kết quả 51
3.6 So sánh Model ML với Beliefs của người dùng 54
3.7 Cross-Validation 5-Fold - Tất cả Models 55
3.8 Time-Series Cross-Validation 57
3.8.1 Precision@K và Recall@K 59
3.8.2 Ảnh hưởng của n_factors 60
3.9 Kết quả NCF (Neural Collaborative Filtering) 61
3.9.1 Định nghĩa model NCF (PyTorch) 61
3.9.2 Huấn luyện NCF 62
3.9.3 Biểu đồ kết quả NCF 64
3.10 Nhận xét tổng hợp kết quả 66
3.11 Phân tích so sánh chuyên sâu giữa các model 66
3.11.1 Phân tích theo họ model (Model Families) 66
3.11.2 Bảng tổng hợp 3 phương pháp đánh giá 68
3.12 Nhận xét cuối 70

4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 71
4.1 Tóm tắt kết quả 71
4.1.1 Kết luận về bộ dữ liệu 72
4.1.2 Kết luận về mô hình 72
4.2 Hạn chế 73

4.3 Hướng phát triển 74

Tài liệu tham khảo **76**

Tóm tắt

Hệ thống gợi ý phim (Recommender Systems) giúp dự đoán sở thích người dùng và đề xuất nội dung phù hợp. Báo cáo này nghiên cứu bài toán dự đoán đánh giá phim trên bộ dữ liệu **MovieLens Belief 2024** - bộ dữ liệu đặc biệt của GroupLens Research, chứa cả dữ liệu đánh giá truyền thống lẫn "beliefs" (dự đoán chủ quan của người dùng về phim chưa xem).

Bảy mô hình được xây dựng và so sánh: SVD, KNN User-Based, KNN Item-Based, SVD++, NMF, BaselineOnly và NCF (Neural Collaborative Filtering). Các mô hình được đánh giá bằng ba phương pháp: train/test split (80/20), Cross-Validation 5-Fold và Time-Series CV, với các chỉ số RMSE, MAE, Precision@K và Recall@K.

Kết quả cho thấy **SVD** đạt cân bằng tốt nhất giữa độ chính xác và tốc độ. BaselineOnly xác nhận rằng bias người dùng/phim đã giải thích phần lớn phương sai trong ratings. Time-Series CV phản ánh hiệu suất thực tế chính xác hơn Random CV. Nghiên cứu cũng cho thấy tiềm năng của máy học trong việc dự đoán tốt hơn trực giác con người ở bài toán rating phim.

Lời cảm ơn

Đầu tiên, em xin gửi lời cảm ơn chân thành đến **Quý Thầy/Cô** trong Khoa Toán Kinh tế, Trường Đại học Kinh tế - Luật đã tận tình giảng dạy và truyền đạt những kiến thức quý báu về Machine Learning trong suốt học kỳ vừa qua.

Đặc biệt, em xin cảm ơn **Thầy Trương Quang Nhật** - Giảng viên hướng dẫn - đã luôn nhiệt tình hỗ trợ, giải đáp thắc mắc và định hướng cho em trong quá trình thực hiện đề tài này.

Em cũng xin gửi lời cảm ơn đến nhóm nghiên cứu **GroupLens Research** tại Đại học Minnesota, **Northwestern University** và **University College London** đã công bố bộ dữ liệu MovieLens Belief 2024, tạo điều kiện thuận lợi cho việc nghiên cứu và thực hành các thuật toán Machine Learning trong lĩnh vực Hệ thống gợi ý (Recommender Systems).

Trong quá trình thực hiện, báo cáo không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý từ Thầy/Cô để hoàn thiện hơn.

Trân trọng cảm ơn!

Chương 1

GIỚI THIỆU

1.1 Động lực nghiên cứu

Mỗi tối, hàng triệu người ngồi trước màn hình, lướt qua hàng nghìn bộ phim và tự hỏi: "Mình nên xem gì?" Nếu có thể đọc được suy nghĩ của họ - biết trước họ sẽ thích bộ phim nào trước khi họ nhấn "Play" - thì hệ thống gợi ý sẽ hoàn hảo đến mức nào? Câu hỏi tưởng chừng viển vông ấy lại chính là điểm khởi đầu của nghiên cứu này.

Hệ thống gợi ý phim (Recommender Systems) là một trong những ứng dụng hấp dẫn nhất của Machine Learning, đang vận hành âm thầm đằng sau Netflix, Amazon Prime, Disney+ và hàng loạt nền tảng giải trí khác. Bài toán cốt lõi nghe thì đơn giản: **dự đoán điểm đánh giá (rating) mà một người dùng sẽ cho một bộ phim chưa xem**. Nhưng càng đào sâu, bài toán càng mở ra những tầng phức tạp đầy cuốn hút - từ việc phân rã ma trận hàng triệu ô trống, đến việc mô hình hóa sở thích ẩn sâu trong hành vi xem phim của mỗi người.

Điều thực sự khiến nghiên cứu này trở nên đặc biệt là bộ dữ liệu **MovieLens Belief 2024** (GroupLens Research, Đại học Minnesota). Khác với mọi bộ dữ liệu rating thông thường, MovieLens Belief 2024 còn thu thập một thứ chưa từng có trước đây: **"beliefs"** - tức là dự đoán chủ quan của chính người dùng về mức rating họ *nghĩ* mình sẽ cho một bộ phim chưa xem. Đây là lần đầu tiên có thể đặt câu hỏi một cách định lượng: *Máy học dự đoán sở thích con người chính xác hơn, hay chính con người hiểu bản thân mình tốt hơn?* Khoảng cách giữa hai câu trả lời đó - giữa trí tuệ nhân tạo và trực giác con người - chính là vùng đất mà nghiên cứu này muốn khám phá.

1.2 Các nghiên cứu liên quan

Lĩnh vực Collaborative Filtering đã có lịch sử phát triển phong phú:

- **Memory-based CF**: Herlocker et al. (1999) đề xuất framework KNN cho Collaborative Filtering, tìm K neighbors tương tự nhất để dự đoán. Sarwar et al. (2001) mở rộng sang Item-Based CF, cho thấy tính ổn định cao hơn khi số users tăng nhanh.
- **Model-based CF (Matrix Factorization)**: Koren, Bell & Volinsky (2009) trình bày SVD biased cho recommender systems, trở thành nền tảng cho nhiều hệ thống thực tế. Koren (2008) mở rộng thành SVD++ với implicit feedback. Lee & Seung (1999) đề xuất NMF với ràng buộc không âm, tạo parts-based representation.
- **Deep Learning cho CF**: He et al. (2017) đề xuất Neural Collaborative Filtering (NCF), thay dot product bằng MLP để học tương tác phi tuyến. Tuy nhiên, nghiên cứu gần đây cho thấy deep learning không luôn vượt trội hơn MF truyền thống khi dữ liệu hạn chế.
- **Đánh giá mô hình**: Hastie, Tibshirani & Friedman (2009) hệ thống hóa lý thuyết cross-validation và bias-variance tradeoff, là nền tảng cho việc đánh giá model trong machine learning.

1.3 Mục tiêu nghiên cứu

- **Mục tiêu chính**: Xây dựng mô hình dự đoán rating phim với sai số thấp nhất
- **Mục tiêu phụ**: So sánh hiệu quả giữa các thuật toán; so sánh model ML với "beliefs" của người dùng

1.4 Câu hỏi nghiên cứu

1. Thuật toán SVD (Singular Value Decomposition) có hiệu quả trong việc dự đoán rating phim không?
2. So sánh SVD với các thuật toán khác (KNN, SVD++, NMF), thuật toán nào cho kết quả tốt nhất?
3. Mô hình ML có dự đoán chính xác hơn dự đoán chủ quan (beliefs) của người dùng không?
4. Kết quả có ổn định qua các phương pháp đánh giá khác nhau (single split, cross-validation, time-series CV) không?

1.5 Phát biểu bài toán

Bài toán: Dự đoán điểm đánh giá (rating) mà một người dùng sẽ cho một bộ phim mà họ chưa xem.

- **Loại bài toán**: **Hồi quy** (Regression) - vì biến mục tiêu `rating` là biến liên tục (0.5 -> 5.0)
- **Ứng dụng thực tiễn**: Hệ thống gợi ý phim (Recommender System)
- **Đặc biệt**: Với dữ liệu Belief 2024, ta có thể so sánh dự đoán của mô hình ML với dự đoán chủ quan của chính người dùng.

1.6 Các model được chọn

Bảng 1.1: Các model được chọn và lý do

Model	Vai trò	Lý do chọn
SVD	Model chính	Thuật toán Matrix Factorization kinh điển, hiệu quả cao cho Collaborative Filtering, được sử dụng rộng rãi trong thực tế (Koren et al., 2009)
KNN (User-based)	Model phụ 1	Thuật toán Memory-based trực quan, dễ hiểu, là baseline tốt để so sánh (Herlocker et al., 1999)
SVD++	Model phụ 2	Mở rộng của SVD, tích hợp thêm thông tin implicit feedback (Koren, 2008)
KNN (Item-based)	Model phụ 3	Memory-based từ góc nhìn item - ổn định hơn khi user profile thay đổi (Sarwar et al., 2001)
NMF	Model phụ 4	Non-negative Matrix Factorization - ràng buộc không âm tạo tính diễn giải cho latent factors (Lee & Seung, 1999)
BaselineOnly	Mô hình tham chiếu	Chỉ dùng bias - baseline tối thiểu để đánh giá giá trị gia tăng của latent factors (Koren, 2010)
NCF (Neural CF)	Model mở rộng	Thuật toán Deep Learning, thay dot product bằng neural network để học tương tác phi tuyến (He et al., 2017)

1.7 Cấu trúc bài báo cáo

Bài báo cáo được tổ chức thành 4 chương chính:

- **Chương 1 - Giới thiệu**: Trình bày động lực, các nghiên cứu liên quan, mục tiêu, câu hỏi nghiên cứu, phát biểu bài toán và các model được chọn.

- **Chương 2 - Cơ sở lý thuyết và mô hình**: Trình bày chi tiết nền tảng toán học của từng thuật toán (SVD, KNN, SVD++, NMF, BaselineOnly, NCF), phương pháp cross-validation và các thang đo đánh giá.

- **Chương 3 - Dữ liệu và kết quả**: Mô tả bộ dữ liệu MovieLens Belief 2024, quy trình xử lý dữ liệu, kết quả huấn luyện và đánh giá các model bằng 3 phương pháp (single split, 5-Fold CV, Time-Series CV), phân tích so sánh chuyên sâu.

- **Chương 4 - Kết luận và hướng phát triển**: Tóm tắt kết quả, thảo luận hạn chế và đề xuất hướng nghiên cứu tiếp theo.

Sơ đồ quy trình thực hiện:

```
+-------------------------------------------------------------------+
|                    QUY TRÌNH THỰC HIỆN                            |
+-------------------------------------------------------------------+


    +---------------+
    |  Thu thập dữ  |
    |  liệu (Data   |   MovieLens Belief 2024
    |  Collection)  |   (GroupLens Research)
    +-------+-------+
            |
            v
    +---------------+
    |  Khám phá dữ  | --> Thống kê mô tả, Visualization
    |  liệu (EDA)   |   Phân tích Belief Data
    +-------+-------+
            |
            v
    +---------------+
    |  Xử lý dữ     | --> Missing values, Duplicates, Outliers
    |  liệu (Data   |
    |  Preprocessing)|
    +-------+-------+
            |
```

```
        v
+---------------+
|  Tách dữ liệu | --> Train (80%) / Test (20%)
|  (Split Data) |
+-------+-------+
        |
        v
+-----------------------------------------------------+
|              Huấn luyện mô hình                     |
|  +-----+  +---------+  +------+  +---------+        |
|  | SVD |  |KNN User |  |SVD++ |  |KNN Item |        |
|  +--+--+  +----+----+  +--+---+  +----+----+        |
|  +-----+  +---------+  +---------+                  |
|  | NMF |  |Baseline |  |  NCF    |                  |
|  |     |  |  Only   |  |(PyTorch)|                  |
|  +--+--+  +----+----+  +----+----+                  |
+-----+----------+------------+----------------------+
      |          |            |
      v          v            v
+-------------------------------------------+
|       Đánh giá & So sánh Model            |
|  RMSE | MAE | 5-Fold CV | Time-Series CV  |
|  Precision@K | Recall@K | vs Beliefs      |
+-------------------+----------------------+
                    |
                    v
            +---------------+
            |   Kết luận &  |
            |  Gợi ý phim   |
            +---------------+
```

—

Chương 2

CƠ SỞ LÝ THUYẾT VÀ MÔ HÌNH

Hành trình xây dựng mô hình giống như leo núi: ta bắt đầu từ chân núi với phương pháp đơn giản nhất (trung bình toàn cục), rồi từng bước thêm "công cụ" - user bias, item bias, latent factors, implicit feedback - và cuối cùng thử sức với deep learning. Mỗi bước là một câu hỏi: "Liệu ta có thể đi xa hơn không?" Phần này trình bày lý thuyết của từng bước trong hành trình đó.

2.1 Tổng quan Collaborative Filtering

Collaborative Filtering (CF) - Lọc cộng tác - là một trong những phương pháp phổ biến nhất trong lĩnh vực Recommender Systems. Ý tưởng cốt lõi của CF dựa trên giả định rằng người dùng có sở thích tương tự trong quá khứ sẽ tiếp tục có sở thích tương tự trong tương lai. Khác với Content-Based Filtering (dựa trên đặc trưng nội dung của item), CF chỉ sử dụng thông tin tương tác giữa user và item (ma trận rating) mà không cần biết nội dung cụ thể của phim.

Về mặt hình thức, bài toán CF có thể được phát biểu như sau: cho ma trận rating $R \in \mathbb{R}^{m \times n}$ với m users và n items, trong đó phần lớn các phần tử là missing (chưa đánh giá), mục tiêu là **dự đoán giá trị của các ô trống** dựa trên các ô đã biết. Đây thực chất là bài toán **matrix completion** - một bài toán kinh điển trong đại số tuyến tính và thống kê (Candès & Recht, 2009).

CF được chia thành hai họ phương pháp chính, mỗi họ có ưu và nhược điểm riêng:

1. **Memory-based CF**: Tính toán trực tiếp từ ma trận rating bằng cách đo độ tương tự giữa users (User-Based) hoặc giữa items (Item-Based). Phương pháp này đơn giản, dễ hiểu, dễ giải thích, nhưng gặp khó khăn với dữ liệu thưa (sparse) và không mở rộng tốt (scalability) khi số lượng user/item tăng lớn (Herlocker et al., 1999; Sarwar et al., 2001).

2. **Model-based CF**: Xây dựng mô hình tham số từ dữ liệu, phổ biến nhất là Matrix Factorization - phân rã ma trận rating thành tích của hai ma trận nhỏ hơn chứa latent factors. Phương pháp này tổng quát hóa tốt hơn, xử lý được dữ liệu thưa, và thường cho kết quả chính xác hơn Memory-based (Koren et al., 2009).

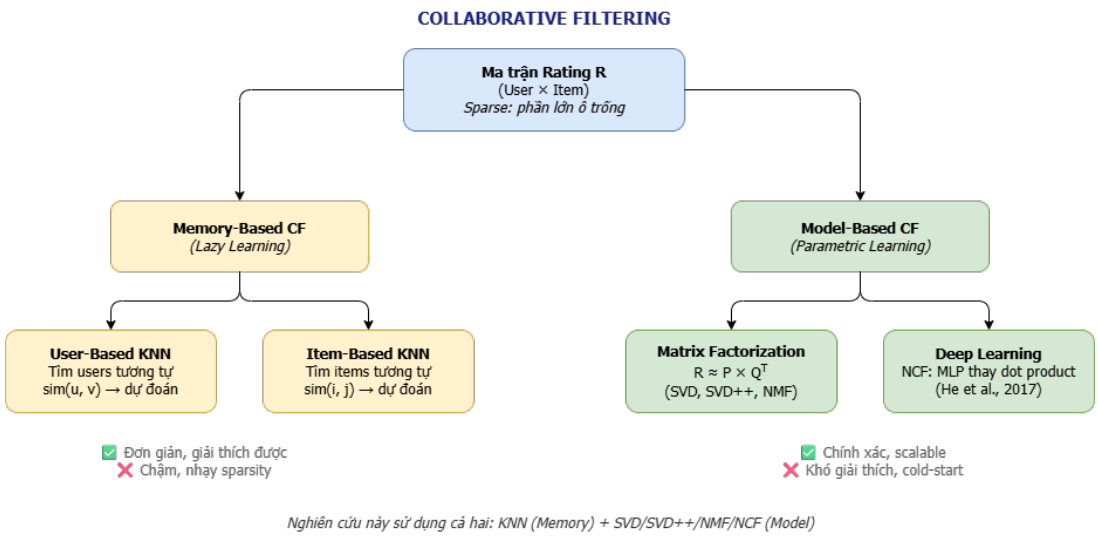

Hình 2.1: Tổng quan Collaborative Filtering - Memory-based vs Model-based

2.2 SVD - Singular Value Decomposition (Model chính)

Singular Value Decomposition (SVD) - Phân rã giá trị kỳ dị - là một trong những thuật toán Matrix Factorization phổ biến nhất trong Collaborative Filtering. Trong đại số tuyến tính cổ điển, SVD phân rã một ma trận bất kỳ A thành tích $U\Sigma V^T$ (Eckart & Young, 1936). Tuy nhiên, trong recommender systems, "SVD" thường chỉ phiên bản **biased SVD** do Koren et al. (2009) phát triển - một biến thể được tối ưu hóa cho dữ liệu thưa bằng SGD, không yêu cầu ma trận đầy đủ như SVD cổ điển.

Biased SVD đã trở thành nền tảng của nhiều hệ thống gợi ý thực tế và đóng vai trò quan trọng trong cuộc thi Netflix Prize ($1 triệu),các đội đã sử dụng SVD và các mô hình phân rã ma trận khác kết hợp với ensemble để cải thiện RMSE đáng kể so với hệ thống Netflix gốc (Bell & Koren, 2007).

2.2.1 Ý tưởng của SVD trong Recommender Systems

Ma trận đánh giá **R** (User × Item) thường rất thưa (sparse) - phần lớn người dùng chỉ đánh giá một số ít phim. SVD giúp **phân rã** ma trận này thành các thành phần nhỏ hơn để:

1. **Tìm các yếu tố ẩn (latent factors)**: Các đặc trưng ẩn giải thích sở thích người dùng (ví dụ: thích phim hành động, thích đạo diễn nổi tiếng, ...)

2. **Lấp đầy ma trận thưa**: Dự đoán rating cho các ô trống

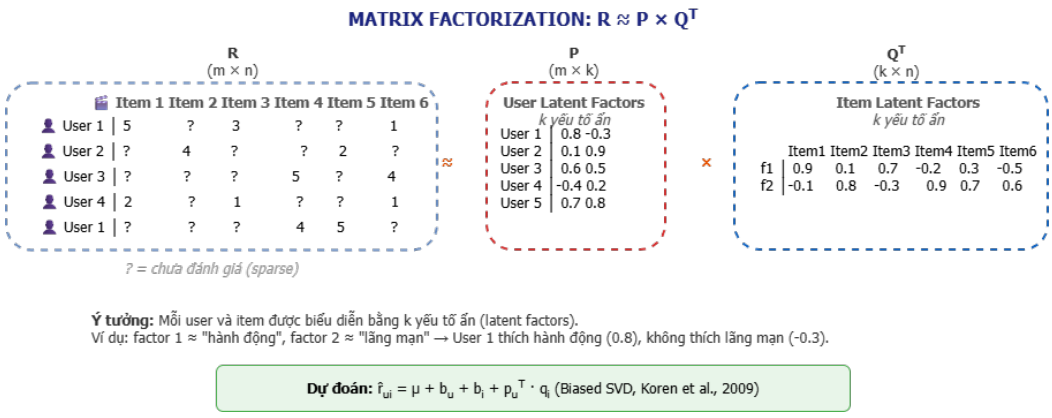

Hình 2.2: Minh họa Matrix Factorization - phân rã ma trận R thành P × Q

Mô hình SVD trong hệ thống gợi ý thường được viết dưới dạng $R \approx P\Sigma Q^T$ hoặc $R \approx PQ^T$, với P, Q là các ma trận yếu tố ẩn của người dùng và vật phẩm.

```
Ma trận Rating R (m users x n items):

         Movie1  Movie2  Movie3  Movie4  Movie5
User1  [  5       3       ?       1       ?    ]
User2  [  4       ?       ?       1       ?    ]
User3  [  ?       1       ?       5       4    ]
User4  [  ?       ?       5       4       ?    ]
User5  [  ?       ?       4       ?       5    ]

"?" = chưa đánh giá --> cần DỰ ĐOÁN

        +---------+       +---------+      +----------+T
  R  ~  |  P      |   x   |  Sigma  |  x   |   Q      |
(mxn)   |(mxk)    |       |(kxk)    |      |(nxk)     |
        |User     |       |Singular |      |Item      |
        |Factors  |       |Values   |      |Factors   |
        +---------+       +---------+      +----------+
```

2.2.2 Công thức toán học - Step by Step

STEP 1: Xây dựng ma trận User-Item

Cho tập dữ liệu đánh giá, xây dựng ma trận **R** kích thước **m** × **n**:

```
R  in  Rmxn

Trong đó:
  m = số lượng users
  n = số lượng items (phim)
  R[u][i] = rating của user u cho item i
            (= NaN nếu chưa đánh giá)
```

STEP 2: Định nghĩa mô hình dự đoán

Thay vì phân rã trực tiếp ma trận R (SVD truyền thống), trong Recommender Systems ta sử dụng **biased SVD**:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \cdot \mathbf{q}_i \tag{2.1}$$

Trong đó:

Ký hiệu	Ý nghĩa	Kích thước
$\hat{r}_{ui}$	Rating dự đoán của user u cho item i	scalar
μ	Rating trung bình toàn cục (global mean)	scalar
b_u	Bias của user u (xu hướng cho điểm cao/thấp)	scalar
b_i	Bias của item i (phim được đánh giá cao/thấp)	scalar
p_u	Vector yếu tố ẩn của user u	$k \times 1$
q_i	Vector yếu tố ẩn của item i	$k \times 1$
k	Số lượng yếu tố ẩn (latent factors)	hyperparameter

Giải thích trực quan:

$$\hat{r}_{ui} = \underbrace{\mu}_{\text{global mean}} + \underbrace{b_u}_{\text{user bias}} + \underbrace{b_i}_{\text{item bias}} + \underbrace{\mathbf{p}_u^\top \cdot \mathbf{q}_i}_{\text{tương tác latent factors}} \tag{2.2}$$

Trong đó mỗi thành phần có ý nghĩa rõ ràng: μ là rating trung bình toàn cục, b_u phản ánh xu hướng cho điểm cao/thấp của user, b_i phản ánh danh tiếng phim, và $\mathbf{p}_u^\top \cdot \mathbf{q}_i$ là tương tác giữa sở thích user và đặc trưng phim.

Ví dụ minh họa: Ví dụ minh họa:

$$\begin{aligned}
\mu &= 3.5 \quad \text{(rating trung bình toàn cục)} \\
b_u &= +0.3 \quad \text{(user này thường cho điểm cao hơn TB 0.3)} \\
b_i &= +0.5 \quad \text{(phim này thường được đánh giá cao hơn TB 0.5)} \\
\mathbf{p}_u^\top \cdot \mathbf{q}_i &= +0.2 \quad \text{(sở thích user phù hợp với đặc trưng phim)} \\
\Rightarrow \hat{r}_{ui} &= 3.5 + 0.3 + 0.5 + 0.2 = \mathbf{4.5}
\end{aligned}$$

STEP 3: Định nghĩa hàm mất mát (Loss Function)

Mục tiêu: Tối thiểu hóa sai số giữa rating thực tế và rating dự đoán, có thêm **regularization** để tránh overfitting:

$$\mathcal{L} = \min \sum_{(u,i)\in\mathcal{K}} (r_{ui} - \hat{r}_{ui})^2 + \lambda \left(\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2 + b_u^2 + b_i^2 \right) \tag{2.3}$$

Trong đó:

- $\mathcal{K}$ = tập hợp các cặp (user, item) đã biết rating
- r_{ui} = rating thực tế
- $\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \cdot \mathbf{q}_i$ = rating dự đoán
- λ = hệ số regularization (kiểm soát overfitting)

Giải thích:

- $\mathbf{(r_{ui} - \hat{r}_{ui})^2}$: Sai số bình phương - muốn dự đoán càng gần thực tế càng tốt
- $\mathbf{\cdot\ (||p_u||^2 + ||q_i||^2 + b_u{}^2 + b_i{}^2)}$: Regularization L2 - phạt các giá trị quá lớn, giúp model tổng quát hóa tốt hơn

STEP 4: Tối ưu hóa bằng SGD (Stochastic Gradient Descent)

Tính đạo hàm riêng của L theo từng tham số:

Với mỗi cặp (u, i) đã biết rating, tính sai số và cập nhật:

$$e_{ui} = r_{ui} - \hat{r}_{ui} \tag{2.4}$$

Cập nhật tham số (SGD):

$$
\begin{aligned}
b_u &\leftarrow b_u + \alpha \cdot (e_{ui} - \lambda \cdot b_u) \\
b_i &\leftarrow b_i + \alpha \cdot (e_{ui} - \lambda \cdot b_i) \\
\mathbf{p}_u &\leftarrow \mathbf{p}_u + \alpha \cdot (e_{ui} \cdot \mathbf{q}_i - \lambda \cdot \mathbf{p}_u) \\
\mathbf{q}_i &\leftarrow \mathbf{q}_i + \alpha \cdot (e_{ui} \cdot \mathbf{p}_u - \lambda \cdot \mathbf{q}_i)
\end{aligned}
$$

Giải thích trực quan quá trình cập nhật:

Giải thích trực quan:

- Nếu $e_{ui} > 0$ (dự đoán **thấp** hơn thực tế): tăng b_u, b_i và điều chỉnh $\mathbf{p}_u$, $\mathbf{q}_i$ để tích $\mathbf{p}_u^\top \cdot \mathbf{q}_i$ tăng lên
- Nếu $e_{ui} < 0$ (dự đoán **cao** hơn thực tế): giảm b_u, b_i và điều chỉnh $\mathbf{p}_u$, $\mathbf{q}_i$ để tích giảm xuống
- Thành phần λ luôn "kéo" các tham số về gần 0, ngăn model quá phức tạp (overfitting)

STEP 5: Thuật toán hoàn chỉnh (Pseudocode)

```
+==========================================================+
|         THUẬT TOÁN SVD CHO RECOMMENDER SYSTEMS           |
+==========================================================+
|                                                          |
|  INPUT:                                                  |
|    - Tập dữ liệu đánh giá K = {(u, i, rui)}              |
|    - Số yếu tố ẩn k, Learning rate alpha                 |
|    - Regularization lambda, Số epochs n_epochs           |
|                                                          |
|  INITIALIZE:                                             |
|    mu <- mean(all ratings)                               |
|    bu <- 0 for all users                                 |
|    bi <- 0 for all items                                 |
|    pu <- random Normal(0, 0.1)  (vector kx1)             |
|    qi <- random Normal(0, 0.1)  (vector kx1)             |
|                                                          |
|  FOR epoch = 1 TO n_epochs:                              |
|    FOR each (u, i, rui) in K (shuffled):                 |
|      // Bước 1: Tính dự đoán                             |
|      r_hat = mu + bu + bi + puT . qi                     |
|      // Bước 2: Tính sai số                              |
|      eui = rui - r_hat                                   |
|      // Bước 3: Cập nhật tham số                         |
|      bu <- bu + alpha*(eui - lambda*bu)                  |
|      bi <- bi + alpha*(eui - lambda*bi)                  |
|      pu <- pu + alpha*(eui*qi - lambda*pu)               |
```

```
|       qi <- qi + alpha*(eui*pu - lambda*qi)                |
|     END FOR                                                |
|   END FOR                                                  |
|                                                            |
|   OUTPUT: mu, {bu}, {bi}, {pu}, {qi}                       |
|   PREDICT: r_hat = mu + bu + bi + puT . qi                 |
+==========================================================+
```

STEP 6: Chọn siêu tham số (Hyperparameters)

Siêu tham số	Giá trị	Ý nghĩa
`n_factors` (k)	100	Số yếu tố ẩn. Càng lớn → model phức tạp hơn, nhưng dễ overfit
`n_epochs`	20	Số vòng lặp huấn luyện
`lr_all` (α)	0.005	Learning rate. Quá lớn → không hội tụ. Quá nhỏ → hội tụ chậm
`reg_all` (λ)	0.02	Regularization. Quá lớn → underfitting. Quá nhỏ → overfitting

Bảng 2.1: Siêu tham số SVD và ý nghĩa

STEP 7: Triển khai code SVD

```python
from surprise import SVD
from surprise import accuracy

svd_model = SVD(
    n_factors=100,     # Số yếu tố ẩn
    n_epochs=20,       # Số vòng lặp
    lr_all=0.005,      # Learning rate
    reg_all=0.02,      # Regularization
    random_state=42
)

print(" Đang huấn luyện model SVD...")
svd_model.fit(trainset)
print(" Hoàn tất huấn luyện!")

predictions_svd = svd_model.test(testset)
rmse_svd = accuracy.rmse(predictions_svd)
mae_svd = accuracy.mae(predictions_svd)
```

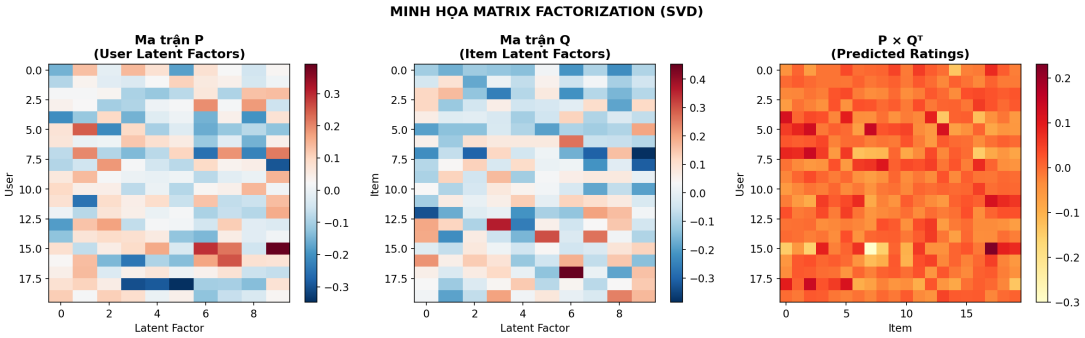

Hình 2.3: Minh họa quá trình Matrix Factorization

```
fig, axes = plt.subplots(1, 3, figsize=(16, 5))

user_factors = svd_model.pu[:20, :10]
im1 = axes[0].imshow(user_factors, cmap='RdBu_r', aspect='auto')
axes[0].set_title('Ma trận P\n(User Latent Factors)', fontweight='bold')
axes[0].set_xlabel('Latent Factor')
axes[0].set_ylabel('User')
plt.colorbar(im1, ax=axes[0])

item_factors = svd_model.qi[:20, :10]
im2 = axes[1].imshow(item_factors, cmap='RdBu_r', aspect='auto')
axes[1].set_title('Ma trận Q\n(Item Latent Factors)', fontweight='bold')
axes[1].set_xlabel('Latent Factor')
axes[1].set_ylabel('Item')
plt.colorbar(im2, ax=axes[1])

reconstructed = user_factors @ item_factors.T
im3 = axes[2].imshow(reconstructed, cmap='YlOrRd', aspect='auto')
axes[2].set_title('P x Q\n(Predicted Ratings)', fontweight='bold')
axes[2].set_xlabel('Item')
axes[2].set_ylabel('User')
plt.colorbar(im3, ax=axes[2])

plt.suptitle('MINH HỌA MATRIX FACTORIZATION (SVD)', fontsize=14,
↪  fontweight='bold')
plt.tight_layout()
plt.savefig('hinh7_matrix_factorization.png', dpi=150, bbox_inches='tight')
plt.show()
```

2.3 KNN User-Based Collaborative Filtering

2.3.1 Tổng quan

K-Nearest Neighbors (KNN) là một trong những thuật toán lâu đời và trực quan nhất trong Collaborative Filtering, thuộc họ **Memory-based** (còn gọi là Neighborhood-based). Ý tưởng cốt lõi của KNN User-Based đơn giản nhưng mạnh mẽ: để dự đoán rating mà user u sẽ cho item i, ta tìm K người dùng "hàng xóm" (neighbors) tương tự nhất với u đã đánh giá item i, rồi tính trung bình có trọng số từ rating của họ.

Thuật toán này được Herlocker et al. (1999) hệ thống hóa trong framework Collaborative Filtering, và nhanh chóng trở thành baseline tiêu chuẩn cho các hệ thống gợi ý. KNN User-Based thuộc loại **non-parametric** - không học tham số cố định từ dữ liệu mà tính toán trực tiếp tại thời điểm dự đoán (lazy learning). Điều này có ưu điểm là đơn giản, không cần huấn luyện, nhưng nhược điểm là chậm khi dữ liệu lớn vì mỗi lần dự đoán đều phải tính toán lại độ tương tự.

Quy trình dự đoán gồm 3 bước chính:

1. **Tính độ tương tự** (similarity) giữa user mục tiêu và tất cả users khác
2. **Chọn K neighbors** có độ tương tự cao nhất đã đánh giá item cần dự đoán
3. **Tính rating dự đoán** bằng trung bình có trọng số

(Nguồn gợi ý: vẽ bằng draw.io theo sơ đồ bên dưới, hoặc tham khảo Ricci et al., 2015, Fig. 2.1)

(Chèn hình tại đây)

Hình 2.4: Minh họa cơ chế KNN User-Based Collaborative Filtering

2.3.2 Công thức toán học

Công thức dự đoán:

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_k(u)} \text{sim}(u,v) \cdot (r_{vi} - \bar{r}_v)}{\sum_{v \in N_k(u)} |\text{sim}(u,v)|} \tag{2.5}$$

Độ tương tự Cosine:

$$\text{sim}(u,v) = \frac{\sum_{j \in I_{uv}} r_{uj} \cdot r_{vj}}{\sqrt{\sum_{j \in I_{uv}} r_{uj}^2} \cdot \sqrt{\sum_{j \in I_{uv}} r_{vj}^2}} \tag{2.6}$$

Minh họa cơ chế KNN User-Based:

```
+=========================================================+
|        KNN USER-BASED COLLABORATIVE FILTERING           |
+=========================================================+
|                                                         |
|  Bước 1: Tìm K users tương tự nhất với User A           |
|                                                         |
|    User A <--- sim=0.92 ---> User B (Neighbor 1)        |
|      |    <--- sim=0.85 ---> User C (Neighbor 2)        |
|      |    <--- sim=0.78 ---> User D (Neighbor 3)        |
|      |    <--- sim=0.31 ---> User E (Bỏ qua)            |
|                                                         |
|  Bước 2: Dùng rating của neighbors để dự đoán           |
|                                                         |
|    Movie X:  User B -> 4.5                              |
|              User C -> 4.0                              |
|              User D -> 5.0                              |
|                                                         |
|  Bước 3: Tính weighted average                          |
|                                                         |
|    r_hat(A,X) = (0.92*4.5 + 0.85*4.0 + 0.78*5.0)        |
|               / (0.92 + 0.85 + 0.78)                    |
|               = 4.46                                    |
|                                                         |
+=========================================================+
```

Code triển khai:

```python
from surprise import KNNWithMeans

sim_options = {
```

```
    'name': 'cosine',
    'user_based': True
}

knn_model = KNNWithMeans(k=40, sim_options=sim_options)
knn_model.fit(trainset)
predictions_knn = knn_model.test(testset)
rmse_knn = accuracy.rmse(predictions_knn)
mae_knn = accuracy.mae(predictions_knn)
```

2.4 SVD++ (SVD mở rộng với Implicit Feedback)

2.4.1 Tổng quan

SVD++ là phiên bản mở rộng của SVD do Koren (2008) đề xuất trong bài báo "Factorization Meets the Neighborhood" tại hội nghị ACM SIGKDD. Ý tưởng cốt lõi của SVD++ là bổ sung thêm **implicit feedback** vào mô hình SVD - tức là tận dụng thông tin rằng user đã đánh giá (tương tác với) một item, bất kể rating cụ thể là bao nhiêu.

Trong thực tế, hành vi "đã xem phim" bản thân nó đã chứa thông tin về sở thích: một người chọn xem phim kinh dị (dù sau đó cho 2 sao) vẫn khác với người hoàn toàn không quan tâm đến thể loại này. SVD++ mô hình hóa thông tin implicit này bằng cách thêm một tập vector y_j cho mỗi item j mà user đã tương tác, giúp biểu diễn user phong phú hơn so với chỉ dùng vector latent p_u đơn thuần.

Koren (2008) đã chứng minh rằng SVD++ cải thiện đáng kể so với SVD thuần trên bộ dữ liệu Netflix Prize, đặc biệt hiệu quả cho **cold-start users** - những users có rất ít explicit ratings nhưng có lịch sử tương tác (implicit) phong phú.

(Nguồn gợi ý: vẽ bằng draw.io, tham khảo Koren, 2008, Figure 1)

(Chèn hình tại đây)

Hình 2.5: So sánh kiến trúc SVD vs SVD++ - thành phần implicit feedback

2.4.2 Công thức toán học

Công thức dự đoán SVD++:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{q}_i^\top \left(\mathbf{p}_u + \frac{1}{\sqrt{|I_u|}} \sum_{j \in I_u} \mathbf{y}_j \right) \tag{2.7}$$

Trong đó I_u là tập các item mà user u đã đánh giá, và $\mathbf{y}_j$ là vector implicit factor của item j (kích thước $k \times 1$).

Ý nghĩa: Ngay cả khi user đánh giá 1, việc user đã xem phim đó cũng cho thông tin về sở thích.

Code triển khai:

```
from surprise import SVDpp

svdpp_model = SVDpp(
    n_factors=20,
    n_epochs=20,
    lr_all=0.007,
    reg_all=0.02,
    random_state=42
)
svdpp_model.fit(trainset)
predictions_svdpp = svdpp_model.test(testset)
rmse_svdpp = accuracy.rmse(predictions_svdpp)
mae_svdpp = accuracy.mae(predictions_svdpp)
```

2.5 KNN Item-Based Collaborative Filtering

2.5.1 Tổng quan: Từ User-Based sang Item-Based

Trong khi User-Based CF tìm users tương tự, **Item-Based CF** đảo ngược góc nhìn: tìm các items tương tự nhất với item cần dự đoán, dựa trên hành vi đánh giá của cộng đồng người dùng. Phương pháp này được Sarwar et al. (2001) đề xuất tại hội nghị WWW và nhanh chóng được áp dụng tại Amazon.com nhờ tính ổn định và khả năng mở rộng vượt trội.

Trong thực tế, hồ sơ người dùng (user profile) thay đổi liên tục - mỗi lần xem phim mới, sở thích có thể "dịch chuyển". Ngược lại, đặc trưng của item (phim) tương đối ổn

định. Sarwar et al. (2001) đã chỉ ra rằng **Item-Based CF ổn định hơn User-Based CF** khi số lượng user tăng nhanh, vì ma trận tương tự item-item ít biến động hơn.

> *"Trong hệ thống lớn như Amazon, số user tăng nhanh hơn nhiều so với số item. Item-Based CF cho phép tính trước (precompute) ma trận tương tự item-item, giúp việc gợi ý thời gian thực (real-time) trở nên khả thi."* - Sarwar et al., 2001*

2.5.2 Công thức toán học

Bước 1: Tính độ tương tự giữa hai items

Sử dụng **Adjusted Cosine Similarity** (hiệu chỉnh theo user bias):

$$\text{sim}_{\text{adj}}(i,j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)(r_{uj} - \bar{r}_u)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)^2} \cdot \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \bar{r}_u)^2}} \tag{2.8}$$

Khác biệt với Cosine thông thường: Adjusted Cosine trừ đi $\bar{r}_u$ để loại bỏ hiệu ứng "user cho điểm cao/thấp" (user bias), giúp so sánh items chính xác hơn. Đây là cải tiến quan trọng do Sarwar et al. (2001) đề xuất.

Bước 2: Dự đoán rating

$$\hat{r}_{ui} = \bar{r}_i + \frac{\sum_{j \in N_k(i)} \text{sim}(i,j) \cdot (r_{uj} - \bar{r}_j)}{\sum_{j \in N_k(i)} |\text{sim}(i,j)|} \tag{2.9}$$

So sánh User-Based vs Item-Based:

Tiêu chí	**User-Based**	**Item-Based**
Tương tự	Giữa users	Giữa items
Ổn định	Thay đổi khi user mới thêm	Ổn định (item ít thay đổi)
Scalability	Kém khi user nhiều	Tốt hơn (precompute được)
Serendipity	Cao hơn (khám phá mới)	Thấp hơn (gợi ý tương tự)
Giải thích	"Người giống bạn thích X"	"Bạn thích Y tương tự X"

(Nguồn gợi ý: vẽ bằng draw.io minh họa hai chiều tương tự, tham khảo Sarwar et al., 2001, Figure 1)

(Chèn hình tại đây)

Hình 2.6: So sánh User-Based CF vs Item-Based CF

Code triển khai:

```
from surprise import KNNWithMeans

sim_options_item = {
    'name': 'cosine',
    'user_based': False  # Item-based
}

knn_item_model = KNNWithMeans(k=40, sim_options=sim_options_item)
knn_item_model.fit(trainset)
predictions_knn_item = knn_item_model.test(testset)
rmse_knn_item = accuracy.rmse(predictions_knn_item)
mae_knn_item = accuracy.mae(predictions_knn_item)
```

2.6 NMF - Non-negative Matrix Factorization

2.6.1 Tổng quan

Non-negative Matrix Factorization (NMF) là một kỹ thuật phân rã ma trận được Lee & Seung công bố lần đầu trên tạp chí Nature năm 1999. Khác với SVD cho phép các latent factors nhận giá trị âm, NMF áp đặt ràng buộc **tất cả các thành phần phải không âm** ($W \geq 0, H \geq 0$). Ràng buộc này mang lại một tính chất quan trọng: kết quả phân rã có tính **parts-based representation** - mỗi latent factor đại diện cho một "phần" tích cực, và kết quả cuối cùng là tổ hợp cộng (additive combination) của các phần đó.

Trong ngữ cảnh recommender systems, NMF phân rã ma trận rating R thành tích $W \cdot H$ trong đó mỗi cột của W có thể diễn giải như "mức độ user thuộc về nhóm sở thích k", và mỗi hàng của H như "mức độ item thuộc về thể loại ẩn k". Đây là ưu điểm lớn về **interpretability** (tính diễn giải) so với SVD.

Tuy nhiên, ràng buộc không âm cũng **hạn chế không gian biểu diễn**: SVD có thể biểu diễn bất kỳ tổ hợp tuyến tính nào trong $\mathbb{R}^k$, trong khi NMF chỉ biểu diễn được conic combinations (tổ hợp không âm). Điều này có thể dẫn đến xấp xỉ kém chính xác hơn và RMSE cao hơn SVD. Lee & Seung (2001) đã phát triển thuật toán multiplicative update rules đảm bảo tính hội tụ, được chứng minh bằng kỹ thuật auxiliary function.

(Nguồn gợi ý: tham khảo Lee & Seung, 1999, Figure 1 - so sánh NMF vs PCA trên dữ liệu khuôn mặt)

(Chèn hình tại đây)

Hình 2.7: Minh họa NMF - phân rã thành parts-based representation

2.6.2 Công thức toán học

Trong SVD truyền thống, các latent factors p_u và q_i có thể nhận giá trị **âm** - điều này về mặt toán học hợp lệ, nhưng khó diễn giải. Ví dụ: "user u có hệ số -0.3 cho yếu tố ẩn thứ 5" - ý nghĩa thực tế là gì?

NMF (Lee & Seung, 1999) áp đặt ràng buộc:

```
R ~ W . H,    W >= 0,   H >= 0

Trong đó:
  R  in  R+mxn  = Ma trận rating (m users x n items)
  W  in  R+mxk  = Ma trận user factors (không âm)
  H  in  R+kxn  = Ma trận item factors (không âm)
  k          = số yếu tố ẩn (latent factors)
```

Ưu điểm của ràng buộc không âm:

- Mỗi latent factor có thể diễn giải như "mức độ thuộc về" một nhóm/thể loại
- Ví dụ: `W[user_A] = [0.8, 0.1, 0.5]` → "User u có 80% sở thích thuộc yếu tố ẩn thứ 3 (có thể liên quan đến phim hành động)"
- Phân rã mang tính **additive** (cộng dồn) - tự nhiên hơn so với phép trừ

> *"NMF learns a parts-based representation - each part contributes additively to the whole, analogous to how objects are composed of parts."* - Lee & Seung, 1999, Nature*

2.6.3 Công thức toán học

Hàm mất mát (Frobenius norm):

$$\mathcal{L}(W, H) = \sum_{(u,i)\in\mathcal{K}} (R_{ui} - [WH]_{ui})^2 + \lambda_W \|W\|_F^2 + \lambda_H \|H\|_F^2 \tag{2.10}$$

Trong đó: $R \in \mathbb{R}_+^{m\times n}$ là ma trận rating, $W \in \mathbb{R}_+^{m\times k}$ là ma trận user factors, $H \in \mathbb{R}_+^{k\times n}$ là ma trận item factors, và ràng buộc $W \geq 0$, $H \geq 0$.

Quy tắc cập nhật nhân (Multiplicative Update Rules):

Thay vì SGD (có thể tạo giá trị âm), NMF dùng **multiplicative updates** để đảm bảo tính không âm:

Quy tắc cập nhật nhân (Multiplicative Update Rules):

$$W_{uk} \leftarrow W_{uk} \cdot \frac{[RH^\top]_{uk}}{[WHH^\top + \lambda_W W]_{uk}}$$

$$H_{ki} \leftarrow H_{ki} \cdot \frac{[W^\top R]_{ki}}{[W^\top WH + \lambda_H H]_{ki}}$$

Chứng minh tính hội tụ: Lee & Seung (2001) đã chứng minh rằng multiplicative updates đảm bảo hàm mất mát **không tăng** sau mỗi bước cập nhật (monotonic decrease), sử dụng kỹ thuật auxiliary function tương tự thuật toán EM.

Giải thích trực quan:

```
SVD:  R ~ P . QT   (P, Q có thể âm -> khó giải thích)
NMF:  R ~ W . H    (W, H >= 0 -> mỗi factor là "mức độ thuộc về")

Ví dụ NMF với k=3 factors:
  Factor 1: Phim hành động/phiêu lưu
  Factor 2: Phim tình cảm/drama
```

```
  Factor 3: Phim hài/gia đình

  W[user_A] = [0.8, 0.1, 0.5]  -> Thích hành động, ít drama
  H[movie_X] = [0.9, 0.2, 0.0] -> Phim hành động thuần túy

  r_hat(A, X) = 0.8*0.9 + 0.1*0.2 + 0.5*0.0 = 0.74
```

Code triển khai:

```python
from surprise import NMF

nmf_model = NMF(
    n_factors=15,     # Số yếu tố ẩn
    n_epochs=50,      # Số vòng lặp
    random_state=42
)
nmf_model.fit(trainset)
predictions_nmf = nmf_model.test(testset)
rmse_nmf = accuracy.rmse(predictions_nmf)
mae_nmf = accuracy.mae(predictions_nmf)
```

2.7 BaselineOnly - Mô hình tham chiếu

2.7.1 Tổng quan

Trong bất kỳ nghiên cứu Machine Learning nghiêm túc nào, việc thiết lập **baseline** (mô hình tham chiếu) là bước không thể thiếu. Baseline cho biết hiệu suất tối thiểu mà bất kỳ model phức tạp nào cũng phải vượt qua - nếu không, sự phức tạp thêm vào là không có giá trị. Nguyên tắc này phản ánh Occam's Razor trong triết học khoa học: "giữa các mô hình có hiệu suất tương đương, nên chọn mô hình đơn giản nhất" (Hastie et al., 2009).

BaselineOnly là mô hình đơn giản nhất có ý nghĩa trong Collaborative Filtering: nó chỉ sử dụng **bias terms** (xu hướng) của user và item để dự đoán, không sử dụng latent factors hay bất kỳ tương tác phức tạp nào. Koren et al. (2009) chỉ ra rằng trên các bộ dữ liệu MovieLens và Netflix, bias terms đã giải thích khoảng 70-80% variance trong ratings, cho thấy "xu hướng cá nhân" (user cho điểm cao/thấp) và "danh tiếng phim" (phim hay/dở) là hai yếu tố chi phối lớn nhất.

Bằng cách so sánh RMSE của BaselineOnly với các model phức tạp hơn (SVD, SVD++), ta có thể định lượng chính xác **giá trị gia tăng** của từng thành phần bổ

sung (latent factors, implicit feedback, v.v.).

2.7.2 Công thức toán học

BaselineOnly dự đoán rating chỉ bằng **bias terms**:

$$\hat{r}_{ui} = \mu + b_u + b_i \tag{2.11}$$

Trong đó: μ là rating trung bình toàn cục, b_u là bias của user u, b_i là bias của item i.

So sánh với SVD: SVD = BaselineOnly + Latent Factors interaction:

So sánh BaselineOnly với SVD:

$$\begin{aligned} \text{BaselineOnly:} \quad & \hat{r} = \mu + b_u + b_i \quad \text{(chỉ bias)} \\ \text{SVD:} \quad & \hat{r} = \mu + b_u + b_i + \mathbf{p}_u^\top \cdot \mathbf{q}_i \quad \text{(bias + interaction)} \end{aligned}$$

Chênh lệch RMSE giữa BaselineOnly và SVD chính là giá trị gia tăng ("added value") của latent factors.

2.7.3 Tối ưu bias bằng ALS (Alternating Least Squares):

Koren (2010) đề xuất phương pháp ALS để ước lượng bias:

Ước lượng bias bằng ALS (Alternating Least Squares):

Bước 1: Cố định b_u, cập nhật b_i:

$$b_i = \frac{\sum_{u \in U_i} (r_{ui} - \mu - b_u)}{\lambda_i + |U_i|} \tag{2.12}$$

Bước 2: Cố định b_i, cập nhật b_u:

$$b_u = \frac{\sum_{i \in I_u} (r_{ui} - \mu - b_i)}{\lambda_u + |I_u|} \tag{2.13}$$

Lặp lại đến khi hội tụ (λ_u, λ_i là hệ số regularization).

Ý nghĩa thực tế: BaselineOnly cho biết **user bias chiếm bao nhiêu phần trăm** trong việc dự đoán. Nghiên cứu trên MovieLens thường cho thấy bias đã giải thích 70-80% variance, nghĩa là "xu hướng cá nhân" là yếu tố chi phối lớn nhất.

Code triển khai:

```python
from surprise import BaselineOnly

bsl_options = {
    'method': 'als',       # Alternating Least Squares
    'n_epochs': 10,        # Số vòng lặp ALS
    'reg_u': 15,           # Regularization cho user bias
    'reg_i': 10            # Regularization cho item bias
}

baseline_model = BaselineOnly(bsl_options=bsl_options)
baseline_model.fit(trainset)
predictions_baseline = baseline_model.test(testset)
rmse_baseline = accuracy.rmse(predictions_baseline)
mae_baseline = accuracy.mae(predictions_baseline)
```

2.8 NCF - Neural Collaborative Filtering (Deep Learning)

2.8.1 Tổng quan

Neural Collaborative Filtering (NCF) là framework do He et al. (2017) đề xuất tại hội nghị WWW, đánh dấu bước chuyển quan trọng từ các phương pháp Collaborative Filtering truyền thống sang Deep Learning. Động lực chính của NCF xuất phát từ một quan sát lý thuyết: tất cả các phương pháp Matrix Factorization (SVD, SVD++, NMF) đều mô hình hóa tương tác user-item bằng **dot product** - một phép tính tuyến tính. Điều này hạn chế khả năng nắm bắt các mối quan hệ phi tuyến phức tạp giữa user và item.

NCF giải quyết vấn đề này bằng cách thay thế dot product bằng **Multi-Layer Perceptron (MLP)** - mạng thần kinh nhiều lớp có khả năng xấp xỉ bất kỳ hàm liên tục nào (Universal Approximation Theorem, Hornik et al., 1989). Cụ thể, thay vì tính $p_u^T \cdot q_i$ (tuyến tính), NCF tính $MLP(concat(e_u, e_i))$ (phi tuyến), trong đó e_u và e_i là embedding vectors của user và item.

Tuy nhiên, cần lưu ý rằng NCF và các deep learning models không phải lúc nào cũng vượt trội hơn Matrix Factorization truyền thống, đặc biệt khi dữ liệu hạn chế. Dacrema et al. (2019) đã chỉ ra rằng nhiều deep learning recommender models không thực sự cải thiện đáng kể so với các baselines được tinh chỉnh kỹ lưỡng.

(Nguồn gợi ý: He et al., 2017, Figure 2 - hoặc vẽ lại bằng draw.io)

(Chèn hình tại đây)

Hình 2.8: Kiến trúc Neural Collaborative Filtering

2.8.2 Từ dot product đến neural network

Qua các level L0-L4, ta đã đi từ trung bình đơn giản đến Matrix Factorization (BiasedMF, SVD++). Tất cả đều có chung một giới hạn: tương tác user-item được mô hình bằng **dot product** - một phép tính **tuyến tính**.

> *"Nếu user thích thể loại A và item thuộc thể loại A, dot product sẽ cho điểm cao. Nhưng nếu mối quan hệ phức tạp hơn - ví dụ user thích A kết hợp B nhưng không thích A đơn lẻ - dot product không thể nắm bắt được."*

Neural Collaborative Filtering (He et al., 2017) giải quyết giới hạn này bằng cách thay thế dot product bằng **neural network** (MLP), cho phép học các tương tác **phi tuyến** bất kỳ.

2.8.3 Công thức so sánh

So sánh BiasedMF và NCF:

$$\begin{aligned} \text{BiasedMF:} \quad & \hat{r} = \mu + b_u + b_i + \mathbf{p}_u^\top \cdot \mathbf{q}_i \quad \text{(tuyến tính)} \\ \text{NCF:} \quad & \hat{r} = \mu + b_u + b_i + \text{MLP}(\text{concat}(\mathbf{e}_u, \mathbf{e}_i)) \quad \text{(phi tuyến)} \end{aligned}$$

Trong đó $\mathbf{e}_u$, $\mathbf{e}_i$ là embedding vectors (32 chiều), và MLP là mạng $[64 \to 32 \to 16 \to 1]$ với ReLU + Dropout.

2.8.4 Kiến trúc NCF

```
+=====================================================+
```

```
|          NEURAL COLLABORATIVE FILTERING            |
+=====================================================+
|                                                     |
|  Input Layer:                                       |
|    User ID --> Embedding(32d) --+                   |
|                                 +--> Concat (64d)   |
|    Item ID --> Embedding(32d) --+                   |
|                                                     |
|  MLP Tower:                                         |
|    Concat(64d) -> Linear(64->32) + ReLU + Drop(0.3)|
|                -> Linear(32->16) + ReLU + Drop(0.3)|
|                -> Linear(16->1)                     |
|                                                     |
|  Output:                                            |
|    r_hat = mu + bu + bi + MLP_output                |
|                                                     |
|  Tổng tham số ~ 350K (vs BiasedMF ~ 150K)          |
+=====================================================+
```

Giải thích từng thành phần:

Thành phần	Vai trò	So sánh BiasedMF
`Embedding(32d)`	Chuyển user/item ID thành vector đặc trưng	Giống p_u, q_i
`Concat`	Nối vector user + item	BiasedMF dùng dot product
`ReLU`	Hàm kích hoạt phi tuyến - cho phép học quan hệ phức tạp	Không có trong MF
`Dropout(0.3)`	Tắt ngẫu nhiên 30% neurons → chống overfitting	MF dùng L2 regularization
$\mu + b_u + b_i$	Bias terms - giữ lại thành phần tuyến tính	Giống hệt BiasedMF

2.8.5 Tối ưu hóa

NCF sử dụng **Adam optimizer** (thay vì SGD thủ công) - một biến thể cải tiến của SGD có **adaptive learning rate**:

```
Vòng huấn luyện:
  1. Forward:  r_hat = model(user_ids, item_ids)
  2. Loss:     L = MSE(r_hat, r_actual)
  3. Backward: Tự động tính dL/dtheta       <- PyTorch Autograd
  4. Update:   theta <- theta - alpha*m/(sqrt(v)+eps)  <- Adam

Kỹ thuật chống overfitting:
```

```
  - Dropout(0.3): tắt 30% neurons mỗi batch
  - Weight decay (L2): lambda = 0.001
  - Early stopping: dừng khi val RMSE không cải thiện
  - LR scheduler: giảm lr khi val RMSE bão hòa
```

2.8.6 Câu hỏi nghiên cứu

> *"Liệu khả năng phi tuyến của neural network có giúp dự đoán belief rating tốt hơn matrix factorization truyền thống, khi chỉ có 26,020 mẫu dữ liệu?"*

2.9 Phương pháp đánh giá: Cross-Validation và Time-Series CV

2.9.1 Tại sao cần Cross-Validation?

Khi đánh giá model chỉ bằng **một lần tách train/test** (single split), kết quả có thể phụ thuộc vào cách chia dữ liệu - một "may mắn" ngẫu nhiên có thể làm model trông tốt hơn (hoặc kém hơn) thực tế. **Cross-Validation** giải quyết vấn đề này bằng cách đánh giá model trên **nhiều lần chia** khác nhau.

Về mặt lý thuyết thống kê, cross-validation giúp ước lượng **expected prediction error** (lỗi dự đoán kỳ vọng) - một khái niệm trung tâm trong bias-variance tradeoff (Hastie, Tibshirani & Friedman, 2009):

```
Expected Error = Bias2 + Variance + Irreducible Noise


Trong đó:
  Bias2    = Sai lệch hệ thống (model quá đơn giản)
  Variance = Độ nhạy với tập train cụ thể (model quá phức tạp)
  Noise    = Nhiễu tự nhiên trong dữ liệu (không giảm được)
```

Cross-Validation cho phép ước lượng cả **mean** (trung bình hiệu suất) lẫn **variance** (độ ổn định) của model.

2.9.2 K-Fold Cross-Validation

Phương pháp: Chia dữ liệu thành K phần (folds) bằng nhau. Lặp K lần, mỗi lần dùng 1 fold làm test, (K-1) folds còn lại làm train.

```
+==========================================================+
|              K-FOLD CROSS-VALIDATION (K=5)               |
+==========================================================+
|                                                          |
|  Fold 1: [TEST] [Train] [Train] [Train] [Train]          |
|  Fold 2: [Train] [TEST] [Train] [Train] [Train]          |
|  Fold 3: [Train] [Train] [TEST] [Train] [Train]          |
|  Fold 4: [Train] [Train] [Train] [TEST] [Train]          |
|  Fold 5: [Train] [Train] [Train] [Train] [TEST]          |
|                                                          |
|  Mỗi fold -> 1 giá trị RMSE                              |
|  Kết quả = Mean(RMSE_1,...,RMSE_5) +- Std                |
+==========================================================+
```

Công thức tính kết quả trung bình:

$$\text{CV(RMSE)} = \frac{1}{K}\sum_{k=1}^{K}\text{RMSE}_k \tag{2.14}$$

$$\text{CV(Std)} = \sqrt{\frac{1}{K}\sum_{k=1}^{K}\left(\text{RMSE}_k - \text{CV(RMSE)}\right)^2} \tag{2.15}$$

Chọn K = 5: Theo Hastie et al. (2009), K=5 hoặc K=10 là phổ biến nhất, cân bằng giữa bias (K nhỏ → bias cao) và variance (K lớn → variance cao). K=5 cũng tiết kiệm thời gian tính toán.

2.9.3 Time-Series Cross-Validation (Expanding Window)

Vấn đề: Random K-Fold CV chia ngẫu nhiên → có thể dùng rating **tương lai** để dự đoán rating **quá khứ** (temporal data leakage). Với dữ liệu có yếu tố thời gian (timestamp), điều này **không thực tế**.

Giải pháp: Sắp xếp theo thời gian, dùng **expanding window** - train luôn trên dữ liệu quá khứ, test trên "tương lai".

```
+=====================================================+
|    TIME-SERIES CV (EXPANDING WINDOW, 5 folds)       |
+=====================================================+
|                                                     |
```

```
|  Thời gian -->  ---------------------------->      |
|                                                    |
|  Fold 1: [Train--] [Test]                          |
|  Fold 2: [Train--------] [Test]                    |
|  Fold 3: [Train--------------] [Test]              |
|  Fold 4: [Train--------------------] [Test]        |
|  Fold 5: [Train--------------------------] [Test]  |
|                                                    |
|  Đặc điểm:                                         |
|  * Train luôn NHỎ HƠN Test về thời gian            |
|  * Không có data leakage từ tương lai              |
|  * RMSE thường CAO HƠN Random CV (khó hơn)         |
|  * Phản ánh CHÍNH XÁC hiệu suất thực tế            |
+====================================================+
```

> *"Time-series CV phản ánh đúng bài toán thực tế: ta chỉ có thể dùng dữ liệu quá khứ để dự đoán tương lai, không bao giờ ngược lại."* - Đây là nguyên tắc cơ bản trong predictive modeling (Hyndman & Athanasopoulos, 2018).*

Code triển khai:

```python
# Sắp xếp theo tstamp
ratings_sorted = ratings_sample.sort_values('tstamp')
n_total = len(ratings_sorted)
fold_size = n_total // 6  # 5 folds expanding

for fold_i in range(1, 6):
    train_end = fold_size * (fold_i + 1)
    test_start = train_end
    test_end = min(train_end + fold_size, n_total)

    train_df = ratings_sorted.iloc[:train_end]
    test_df = ratings_sorted.iloc[test_start:test_end]

    # Chỉ test trên user/item đã biết
    known_users = set(train_df['userId'].unique())
    known_items = set(train_df['movieId'].unique())
    test_df = test_df[test_df['userId'].isin(known_users) &
                      test_df['movieId'].isin(known_items)]

    # Train model, predict, compute RMSE...
```

Chương 3

DỮ LIỆU VÀ KẾT QUẢ

Mỗi tối, hàng triệu người ngồi trước màn hình, lướt qua hàng nghìn bộ phim và tự hỏi: "Mình nên xem gì?" Nếu ta có thể đọc được suy nghĩ của họ - biết trước họ sẽ thích bộ phim nào trước khi họ nhấn "Play" - thì hệ thống gợi ý sẽ hoàn hảo đến mức nào? Bộ dữ liệu MovieLens Belief 2024 cho ta cơ hội hiếm hoi để nhìn vào chính xác điều đó: ***kỳ vọng của con người trước khi xem phim****.*

3.1 Nguồn dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là **MovieLens Belief 2024 Dataset** (Data Release 2, cập nhật 08/02/2025), được phát hành bởi nhóm nghiên cứu **GroupLens Research** (Đại học Minnesota) phối hợp cùng Northwestern University và University College London.

- **Website**: https://grouplens.org/datasets/movielens/ml_belief_2024/
- **Phiên bản**: Data Release 2 (cập nhật 02/2025)
- **Bài báo gốc**: Aridor, G., Goncalves, D., Kong, R., Culver, D., & Konstan, J.A. (2024). *The MovieLens Beliefs Dataset: Collecting Pre-Choice Data for Online Recommender Systems.*
- **Giấy phép**: Dữ liệu cung cấp miễn phí cho mục đích nghiên cứu và giáo dục

Điểm đặc biệt: Ngoài dữ liệu đánh giá truyền thống, bộ dữ liệu này còn chứa **"beliefs"** - tức là dự đoán của người dùng về mức đánh giá mà họ nghĩ mình sẽ cho những bộ phim chưa xem. Đây là loại dữ liệu rất hiếm và có giá trị cao cho nghiên cứu hệ thống gợi ý.

3.2 Mô tả các file dữ liệu

Bộ dữ liệu gồm **5 file CSV** chính:

3.2.1 File user_rating_history.csv - Lịch sử đánh giá phim

Biến	Kiểu dữ liệu	Mô tả	Khoảng giá trị
`userId`	int64	Mã định danh người dùng (đã ẩn danh)	ID duy nhất
`movieId`	int64	Mã định danh bộ phim	Tương thích movielens.org
`rating`	float64	Điểm đánh giá của người dùng	0.5 → 5.0 (bước nhảy 0.5)
`tstamp`	object	Thời gian đánh giá (datetime string)	VD: 1998-06-18 16:31:37

- **Ý nghĩa thực tiễn**: Đây là dữ liệu cốt lõi, phản ánh sở thích thực sự của người dùng đối với phim đã xem. Đây là file được sử dụng chính để huấn luyện mô hình.

3.2.2 File movies.csv - Thông tin phim

Biến	Kiểu dữ liệu	Mô tả	Ví dụ
`movieId`	int64	Mã định danh bộ phim	1, 2, 3, ...
`title`	object (string)	Tên phim (kèm năm phát hành)	"Toy Story (1995)"

- **Ý nghĩa thực tiễn**: Cung cấp metadata về phim, hỗ trợ phân tích theo thể loại.

3.2.3 File belief_data.csv - Dữ liệu niềm tin (Beliefs) - ĐẶC BIỆT

Bảng 3.1: Cấu trúc file belief_data.csv

Biến	Kiểu dữ liệu	Mô tả
`userId`	int64	Mã người dùng
`movieId`	int64	Mã bộ phim
`isSeen`	int64	Đã xem chưa: −1=không trả lời, 0=chưa xem, 1=đã xem
`watchDate`	object	Ngày xem (nếu isSeen=1)
`userElicitRating`	float64	Rating thực tế (nếu isSeen=1)
`userPredictRating`	float64	Rating dự đoán của user (nếu isSeen=0) - **"Belief"**
`userCertainty`	float64	Mức độ chắc chắn của dự đoán (1–5, nếu isSeen=0)
`tstamp`	object	Thời gian (datetime string)
`month_idx`	int64	Tháng trong giai đoạn thu thập
`source`	int64	Nguồn chọn phim (1=broad, 2=recommendation, 3=new)
`systemPredictRating`	float64	Rating dự đoán bởi hệ thống gợi ý

- **Ý nghĩa thực tiễn**: File đặc biệt nhất - chứa dự đoán chủ quan ("beliefs") của người dùng về phim chưa xem, cùng với dự đoán của hệ thống. Cho phép so sánh accuracy giữa model ML và trực giác con người.

3.2.4 File user_recommendation_history.csv - Lịch sử gợi ý

Biến	Kiểu dữ liệu	Mô tả
`userId`	int64	Mã người dùng
`tstamp`	int64	Thời gian gợi ý
`movieId`	int64	Mã bộ phim được gợi ý
`predictedRating`	float64	Rating dự đoán bởi hệ thống gợi ý

- **Ý nghĩa thực tiễn**: Lịch sử các phim đã được hệ thống MovieLens gợi ý cho từng user.

3.2.5 File movie_elicitation_set.csv - Tập phim dùng để hỏi beliefs

Biến	Kiểu dữ liệu	Mô tả
movieId	int64	Mã bộ phim
month_idx	int64	Tháng phim nằm trong tập hỏi
source	int64	Nguồn chọn (1=Popularity, 2=Rating, 3=Popular recent, 4=Trendy, 5=Serendipity)
tstamp	int64	Thời gian cập nhật

3.3 Thống kê mô tả

```
Thống kê mô tả sẽ được tính tự động bởi code Python
(xem file code_movielens.py)
```

Code thống kê mô tả:

```python
import pandas as pd

# Đọc dữ liệu
ratings = pd.read_csv('ml_belief_2024/user_rating_history.csv')
movies = pd.read_csv('ml_belief_2024/movies.csv')
beliefs = pd.read_csv('ml_belief_2024/belief_data.csv')
recommendations = pd.read_csv('ml_belief_2024/user_recommendation_history.csv')
elicitation = pd.read_csv('ml_belief_2024/movie_elicitation_set.csv')

print("="*50)
print("THỐNG KÊ MÔ TẢ BỘ DỮ LIỆU MOVIELENS BELIEF 2024")
print("="*50)

print(f"\n Kích thước dữ liệu:")
print(f"  - Ratings:         {ratings.shape[0]:,} dòng x {ratings.shape[1]} cột")
print(f"  - Movies:          {movies.shape[0]:,} dòng x {movies.shape[1]} cột")
print(f"  - Beliefs:         {beliefs.shape[0]:,} dòng x {beliefs.shape[1]} cột")
```

```
print(f"  - Recommendations: {recommendations.shape[0]:,} dòng x
↪  {recommendations.shape[1]} cột")
print(f"  - Elicitation Set: {elicitation.shape[0]:,} dòng x
↪  {elicitation.shape[1]} cột")

print(f"\n Số lượng người dùng (ratings): {ratings['userId'].nunique():,}")
print(f" Số lượng phim (ratings):        {ratings['movieId'].nunique():,}")
print(f" Tổng số đánh giá:               {len(ratings):,}")

print(f"\n Thống kê mô tả biến rating:")
print(ratings['rating'].describe())
```

3.3.1 Hình minh họa: Phân bố dữ liệu

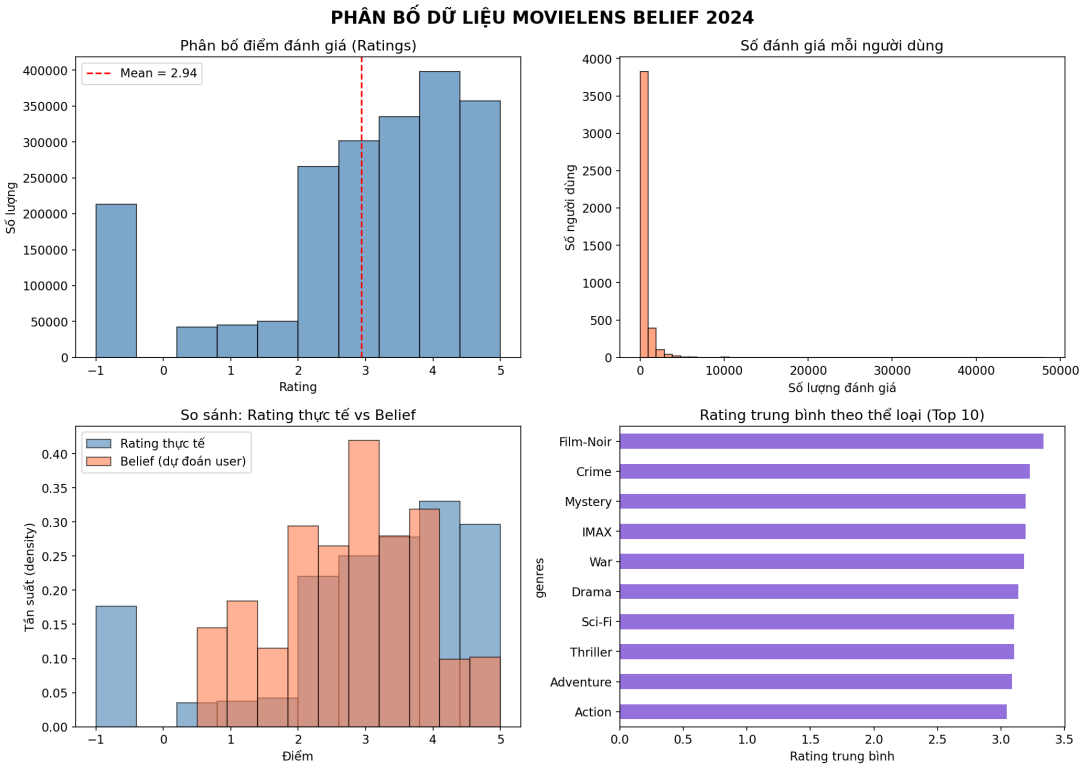

Hình 3.1: Phân bố dữ liệu tổng quan

```
import matplotlib.pyplot as plt
import seaborn as sns

fig, axes = plt.subplots(2, 2, figsize=(14, 10))
fig.suptitle('PHÂN BỐ DỮ LIỆU MOVIELENS BELIEF 2024', fontsize=16,
↪  fontweight='bold')
```

```python

# 1. Phân bố rating
axes[0,0].hist(ratings['rating'], bins=10, color='steelblue', edgecolor='black', alpha=0.7)
axes[0,0].set_title('Phân bố điểm đánh giá (Ratings)')
axes[0,0].set_xlabel('Rating')
axes[0,0].set_ylabel('Số lượng')
axes[0,0].axvline(ratings['rating'].mean(), color='red', linestyle='--',
                  label=f'Mean = {ratings["rating"].mean():.2f}')
axes[0,0].legend()

# 2. Số đánh giá mỗi người dùng
ratings_per_user = ratings.groupby('userId').size()
axes[0,1].hist(ratings_per_user, bins=50, color='coral', edgecolor='black', alpha=0.7)
axes[0,1].set_title('Số đánh giá mỗi người dùng')
axes[0,1].set_xlabel('Số lượng đánh giá')
axes[0,1].set_ylabel('Số người dùng')

# 3. So sánh Beliefs vs Ratings (điểm đặc biệt của dataset)
belief_unseen = beliefs[beliefs['isSeen'] == 0]['userPredictRating'].dropna()
axes[1,0].hist(ratings['rating'], bins=10, alpha=0.6, color='steelblue',
               edgecolor='black', density=True, label='Rating thực tế')
axes[1,0].hist(belief_unseen, bins=10, alpha=0.6, color='coral',
               edgecolor='black', density=True, label='Belief (dự đoán user)')
axes[1,0].set_title('So sánh: Rating thực tế vs Belief')
axes[1,0].set_xlabel('Điểm')
axes[1,0].set_ylabel('Tần suất (density)')
axes[1,0].legend()

# 4. Rating trung bình theo thể loại (top 10)
movies_expanded = movies.copy()
movies_expanded['genres'] = movies_expanded['genres'].str.split('|')
movies_expanded = movies_expanded.explode('genres')
genre_ratings = (movies_expanded.merge(ratings, on='movieId')
                 .groupby('genres')['rating'].mean()
                 .sort_values(ascending=True))
genre_ratings.tail(10).plot(kind='barh', ax=axes[1,1], color='mediumpurple')
axes[1,1].set_title('Rating trung bình theo thể loại (Top 10)')
```

```
axes[1,1].set_xlabel('Rating trung bình')

plt.tight_layout()
plt.savefig('hinh1_phan_bo_du_lieu.png', dpi=150, bbox_inches='tight')
plt.show()
```

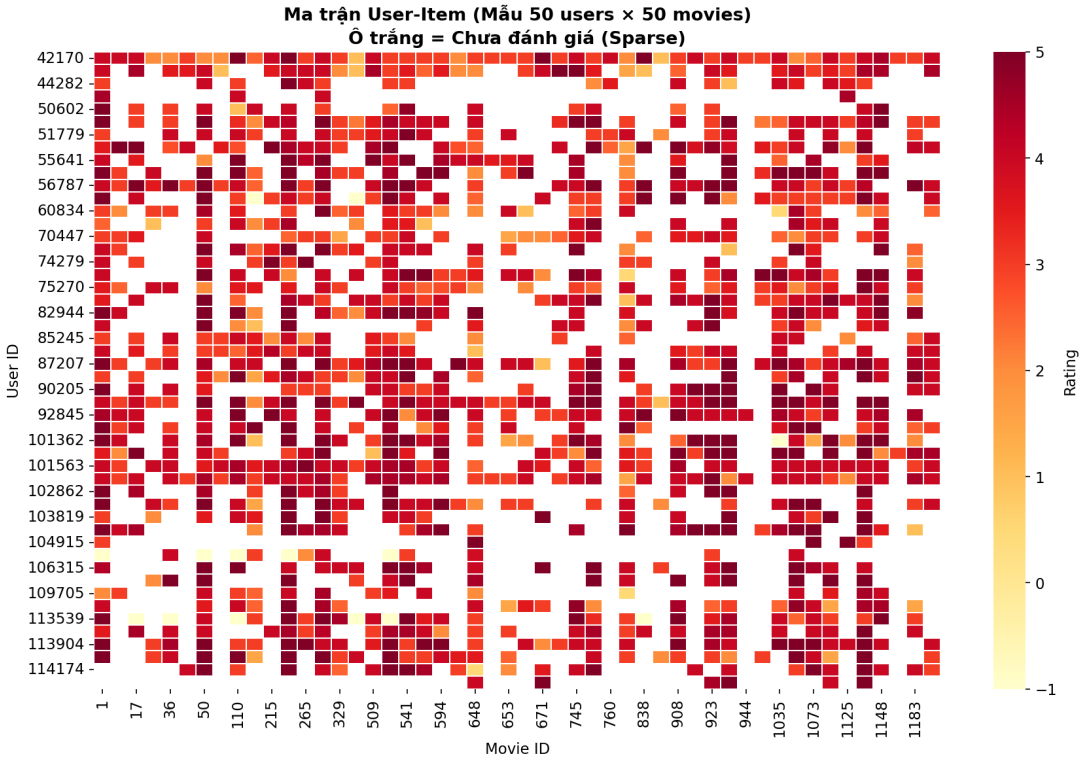

Hình 3.2: Ma trận tương tác User-Item (Sparsity Visualization)

```
import numpy as np

sample_users = sorted(ratings['userId'].unique()[:50])
sample_movies = sorted(ratings['movieId'].unique()[:50])
sample = ratings[ratings['userId'].isin(sample_users) &
↪  ratings['movieId'].isin(sample_movies)]
pivot = sample.pivot_table(index='userId', columns='movieId',
↪  values='rating')

plt.figure(figsize=(12, 8))
sns.heatmap(pivot, cmap='YlOrRd', mask=pivot.isnull(),
            cbar_kws={'label': 'Rating'}, linewidths=0.1)
plt.title('Ma trận User-Item (Mẫu 50 users x 50 movies)\nÔ trắng = Chưa
↪  đánh giá (Sparse)',
          fontsize=13, fontweight='bold')
```

```
plt.xlabel('Movie ID')
plt.ylabel('User ID')
plt.savefig('hinh2_user_item_matrix.png', dpi=150, bbox_inches='tight')
plt.show()

total_possible = ratings['userId'].nunique() * ratings['movieId'].nunique()
sparsity = 1 - len(ratings) / total_possible
print(f" Sparsity (tỉ lệ ô trống): {sparsity:.4%}")
```

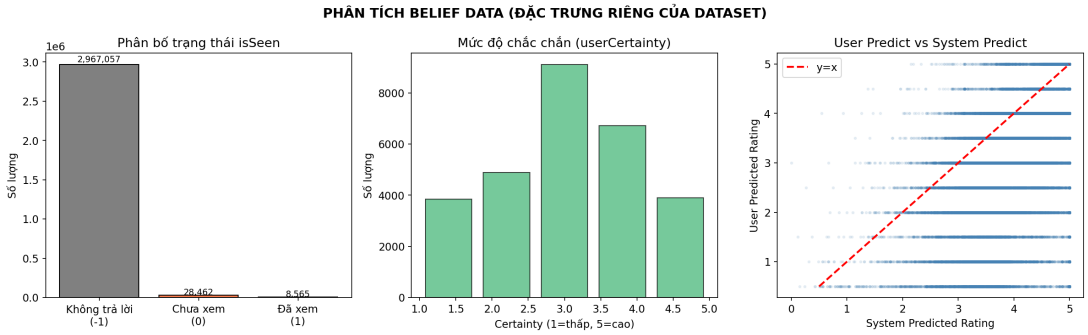

Hình 3.3: Phân tích Belief Data - Đặc trưng riêng của dataset

```
fig, axes = plt.subplots(1, 3, figsize=(16, 5))
fig.suptitle('PHÂN TÍCH BELIEF DATA (ĐẶC TRƯNG RIÊNG CỦA DATASET)',
↪  fontsize=14, fontweight='bold')

# 1. Phân bố isSeen
seen_counts = beliefs['isSeen'].value_counts().sort_index()
labels = {-1: 'Không trả lời\n(isSeen=-1)', 0: 'Chưa xem\n(isSeen=0)', 1:
↪  'Đã xem\n(isSeen=1)'}
axes[0].bar([labels[k] for k in seen_counts.index], seen_counts.values,
            color=['gray', 'coral', 'steelblue'], edgecolor='black')
axes[0].set_title('Phân bố trạng thái isSeen')
axes[0].set_ylabel('Số lượng')

# 2. Phân bố userCertainty
certainty = beliefs[beliefs['isSeen'] == 0]['userCertainty'].dropna()
axes[1].hist(certainty, bins=5, color='mediumseagreen', edgecolor='black',
↪  alpha=0.7)
axes[1].set_title('Mức độ chắc chắn (userCertainty)')
axes[1].set_xlabel('Certainty (1=thấp, 5=cao)')
axes[1].set_ylabel('Số lượng')

# 3. User Predict vs System Predict
```

```
belief_compare = beliefs[(beliefs['isSeen'] == 0) &
                         beliefs['userPredictRating'].notna() &
                         beliefs['systemPredictRating'].notna()]
axes[2].scatter(belief_compare['systemPredictRating'],
               belief_compare['userPredictRating'],
               alpha=0.1, s=5, color='steelblue')
axes[2].plot([0.5, 5], [0.5, 5], 'r--', linewidth=2, label='y=x')
axes[2].set_title('User Predict vs System Predict')
axes[2].set_xlabel('System Predicted Rating')
axes[2].set_ylabel('User Predicted Rating')
axes[2].legend()

plt.tight_layout()
plt.savefig('hinh3_belief_analysis.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.4 Xử lý dữ liệu

3.4.1 Kiểm tra dữ liệu rỗng (Missing Values)

```
print("="*50)
print("KIỂM TRA DỮ LIỆU RỖNG")
print("="*50)

for name, df in [('user_rating_history', ratings), ('movies', movies),
                 ('belief_data', beliefs), ('recommendations',
                 ↪  recommendations),
                 ('elicitation_set', elicitation)]:
    print(f"\n File {name}.csv:")
    missing = df.isnull().sum()
    total = missing.sum()
    if total > 0:
        print(f"   Tổng giá trị rỗng: {total:,}")
        print(missing[missing > 0])
    else:
        print("   Không có giá trị rỗng")
```

Kết quả:

- `user_rating_history.csv`: Không có giá trị rỗng

- `movies.csv`: Không có giá trị rỗng
- `belief_data.csv`: Có giá trị rỗng (do thiết kế - `userPredictRating` chỉ có khi `isSeen=0`, `userElicitRating` chỉ có khi `isSeen=1`)
- **Xử lý**: Giá trị rỗng trong `belief_data` là hợp lý theo cấu trúc dữ liệu, không cần loại bỏ. Dữ liệu `user_rating_history.csv` (dùng để huấn luyện model) không có giá trị rỗng.

3.4.2 Kiểm tra dữ liệu trùng lặp (Duplicates)

```
print("\n" + "="*50)
print("KIỂM TRA DỮ LIỆU TRÙNG LẶP")
print("="*50)

duplicates = ratings.duplicated(subset=['userId', 'movieId'])
print(f"Số dòng trùng lặp trong ratings: {duplicates.sum()}")

if duplicates.sum() > 0:
    ratings = ratings.sort_values('tstamp').drop_duplicates(
        subset=['userId', 'movieId'], keep='last'
    )
    print(" Đã loại bỏ trùng lặp, giữ đánh giá mới nhất")
else:
    print(" Không có dữ liệu trùng lặp")
```

3.4.3 Kiểm tra tính hợp lý của dữ liệu

```
print("\n" + "="*50)
print("KIỂM TRA TÍNH HỢP LÝ")
print("="*50)

# Kiểm tra rating nằm trong khoảng hợp lệ [0.5, 5.0]
valid_ratings = [0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 3.5, 4.0, 4.5, 5.0]
invalid_ratings = ratings[~ratings['rating'].isin(valid_ratings)]
print(f"Số rating không hợp lệ: {len(invalid_ratings)}")

assert (ratings['userId'] > 0).all(), "Có userId không hợp lệ"
assert (ratings['movieId'] > 0).all(), "Có movieId không hợp lệ"
print(" Tất cả userId và movieId đều hợp lệ (> 0)")
```

```python

# Kiểm tra belief data
belief_seen = beliefs[beliefs['isSeen'] == 1]
belief_unseen = beliefs[beliefs['isSeen'] == 0]
print(f"\nBelief data: {len(belief_seen):,} đã xem, {len(belief_unseen):,} chưa xem, "
      f"{(beliefs['isSeen'] == -1).sum():,} không trả lời")
```

3.4.4 Loại bỏ outliers

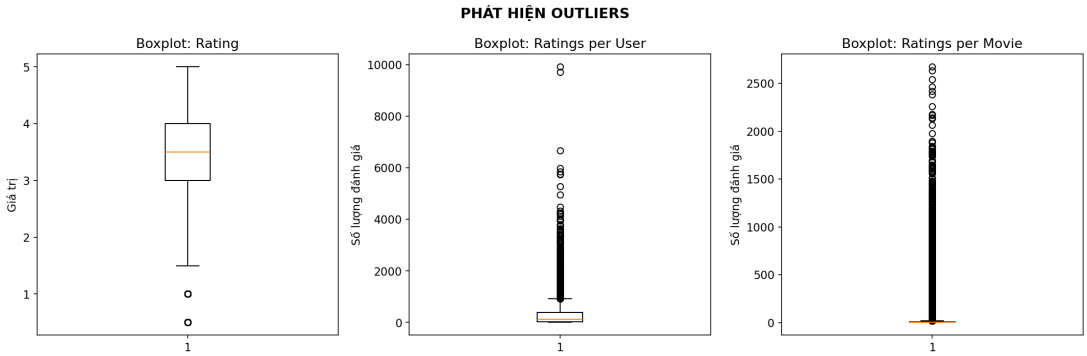

Hình 3.4: Boxplot phát hiện outliers

```python
fig, axes = plt.subplots(1, 3, figsize=(15, 5))

axes[0].boxplot(ratings['rating'])
axes[0].set_title('Boxplot: Rating')
axes[0].set_ylabel('Giá trị')

user_counts = ratings.groupby('userId').size()
axes[1].boxplot(user_counts.values)
axes[1].set_title('Boxplot: Ratings per User')
axes[1].set_ylabel('Số lượng đánh giá')

movie_counts = ratings.groupby('movieId').size()
axes[2].boxplot(movie_counts.values)
axes[2].set_title('Boxplot: Ratings per Movie')
axes[2].set_ylabel('Số lượng đánh giá')

plt.suptitle('PHÁT HIỆN OUTLIERS', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.savefig('hinh4_boxplot_outliers.png', dpi=150, bbox_inches='tight')
```

```
plt.show()
```

3.4.5 Feature Engineering - Thêm cột thông tin

```
# Trích xuất năm phát hành từ tên phim
movies['year'] = movies['title'].str.extract(r'\((\d{4})\)').astype(float)

# Đếm số thể loại mỗi phim
movies['num_genres'] = movies['genres'].str.split('|').str.len()

# Tính rating trung bình và số đánh giá cho mỗi phim
movie_stats = ratings.groupby('movieId').agg(
    avg_rating=('rating', 'mean'),
    num_ratings=('rating', 'count')
).reset_index()
movies = movies.merge(movie_stats, on='movieId', how='left')
```

3.4.6 Phân tích tương quan

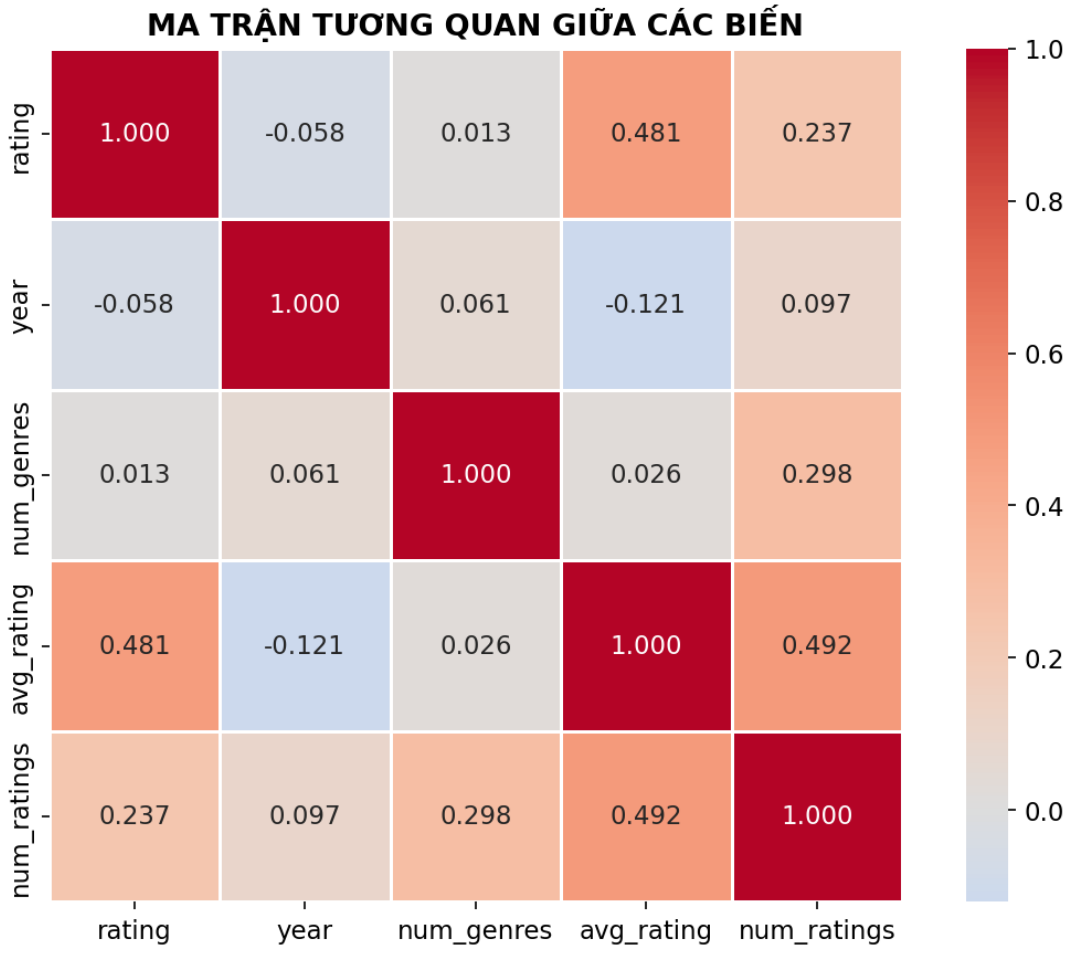

Hình 3.5: Heatmap tương quan

```
merged = ratings.merge(movies[['movieId', 'year', 'num_genres',
↪  'avg_rating', 'num_ratings']],
                       on='movieId')
corr_cols = ['rating', 'year', 'num_genres', 'avg_rating', 'num_ratings']
correlation = merged[corr_cols].corr()

plt.figure(figsize=(8, 6))
sns.heatmap(correlation, annot=True, cmap='coolwarm', center=0,
            fmt='.3f', linewidths=0.5, square=True)
plt.title('MA TRẬN TƯƠNG QUAN GIỮA CÁC BIẾN', fontsize=13,
↪  fontweight='bold')
plt.savefig('hinh5_correlation_heatmap.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.4.7 Tách dữ liệu Train/Test

```
from surprise import Dataset, Reader
from surprise.model_selection import train_test_split

reader = Reader(rating_scale=(0.5, 5.0))
data = Dataset.load_from_df(ratings[['userId', 'movieId', 'rating']],
↪  reader)

# Tách 80% train - 20% test
trainset, testset = train_test_split(data, test_size=0.2, random_state=42)

print(f" Tập train: {trainset.n_ratings:,} ratings")
print(f" Tập test:  {len(testset):,} ratings")
```

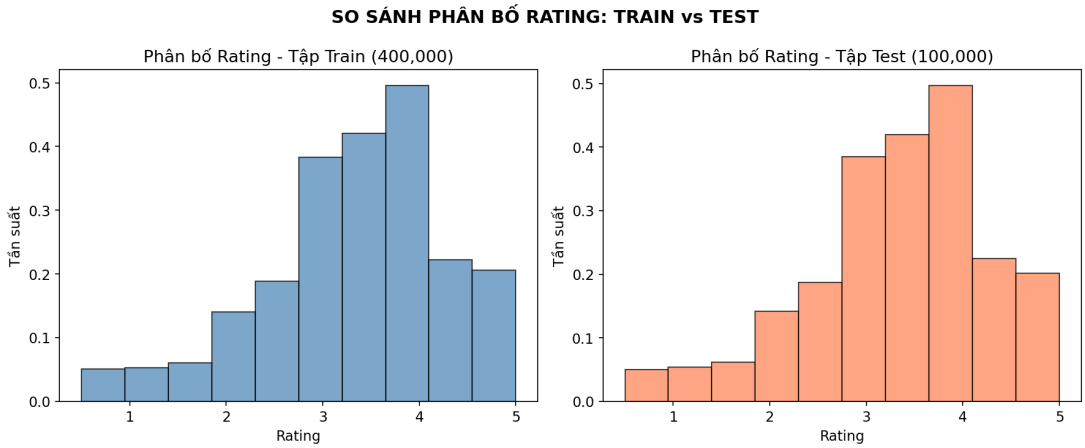

Hình 3.6: Phân bố rating trong tập Train vs Test

```
test_ratings = [r[2] for r in testset]
train_ratings_list = [trainset.ur[u] for u in trainset.all_users()]
train_ratings_flat = [r for sublist in train_ratings_list for _, r in
↪  sublist]

fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes[0].hist(train_ratings_flat, bins=10, color='steelblue',
↪  edgecolor='black', alpha=0.7, density=True)
axes[0].set_title(f'Phân bố Rating - Tập Train')
axes[0].set_xlabel('Rating')
axes[0].set_ylabel('Tần suất')

axes[1].hist(test_ratings, bins=10, color='coral', edgecolor='black',
↪  alpha=0.7, density=True)
```

```
axes[1].set_title(f'Phân bố Rating - Tập Test')
axes[1].set_xlabel('Rating')
axes[1].set_ylabel('Tần suất')

plt.suptitle('SO SÁNH PHÂN BỐ RATING: TRAIN vs TEST', fontsize=14,
↪  fontweight='bold')
plt.tight_layout()
plt.savefig('hinh6_train_test_distribution.png', dpi=150,
↪  bbox_inches='tight')
plt.show()
```

Đã xây dựng xong "đội ngũ" 6 mô hình truyền thống + 1 deep learning, đã huấn luyện và đánh giá bằng cả random CV lẫn time-series CV - giờ là lúc phân tích kết quả. Ta không chỉ hỏi "model nào tốt nhất?", mà còn hỏi "TẠI SAO model đó tốt hơn?" và "kết quả có ổn định qua các phương pháp đánh giá không?"

3.5 Kết quả huấn luyện (Single Split 80/20)

Model	RMSE	MAE	Thời gian (s)
SVD	0.8614	0.6533	10.5
KNN User-Based	0.8913	0.6784	11.9
KNN Item-Based	0.8913	0.6784	12.0
SVD++	**0.8500**	**0.6416**	305.4
NMF	0.8996	0.6801	14.2
BaselineOnly	0.8574	0.6531	1.1

Bảng 3.2: Bảng so sánh kết quả các model (80/20 split) - kết quả từ code Python trên bộ dữ liệu MovieLens Belief 2024

3.5.1 Hình minh họa kết quả

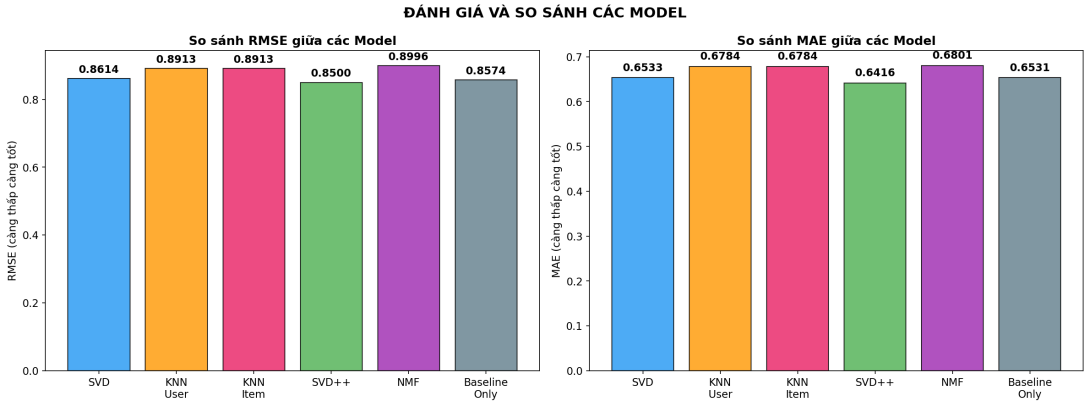

Hình 3.7: So sánh RMSE và MAE giữa 6 models

```
models_names = ['SVD', 'KNN\nUser', 'KNN\nItem', 'SVD++', 'NMF', 'Baseline\nOnly']
rmse_scores = [rmse_svd, rmse_knn, rmse_knn_item, rmse_svdpp, rmse_nmf, rmse_baseline]
mae_scores = [mae_svd, mae_knn, mae_knn_item, mae_svdpp, mae_nmf, mae_baseline]

fig, axes = plt.subplots(1, 2, figsize=(16, 6))
colors = ['#2196F3', '#FF9800', '#E91E63', '#4CAF50', '#9C27B0', '#607D8B']

bars1 = axes[0].bar(models_names, rmse_scores, color=colors, edgecolor='black', alpha=0.8)
axes[0].set_title('So sánh RMSE giữa các Model', fontsize=13, fontweight='bold')
axes[0].set_ylabel('RMSE (càng thấp càng tốt)')
for bar, score in zip(bars1, rmse_scores):
    axes[0].text(bar.get_x() + bar.get_width()/2., bar.get_height() + 0.01,
                 f'{score:.4f}', ha='center', va='bottom', fontweight='bold')

bars2 = axes[1].bar(models_names, mae_scores, color=colors, edgecolor='black', alpha=0.8)
axes[1].set_title('So sánh MAE giữa các Model', fontsize=13, fontweight='bold')
axes[1].set_ylabel('MAE (càng thấp càng tốt)')
for bar, score in zip(bars2, mae_scores):
    axes[1].text(bar.get_x() + bar.get_width()/2., bar.get_height() + 0.01,
```

```
                f'{score:.4f}', ha='center', va='bottom',
                ↪  fontweight='bold')

plt.suptitle('ĐÁNH GIÁ VÀ SO SÁNH CÁC MODEL', fontsize=15,
↪  fontweight='bold')
plt.tight_layout()
plt.savefig('hinh8_model_comparison.png', dpi=150, bbox_inches='tight')
plt.show()
```

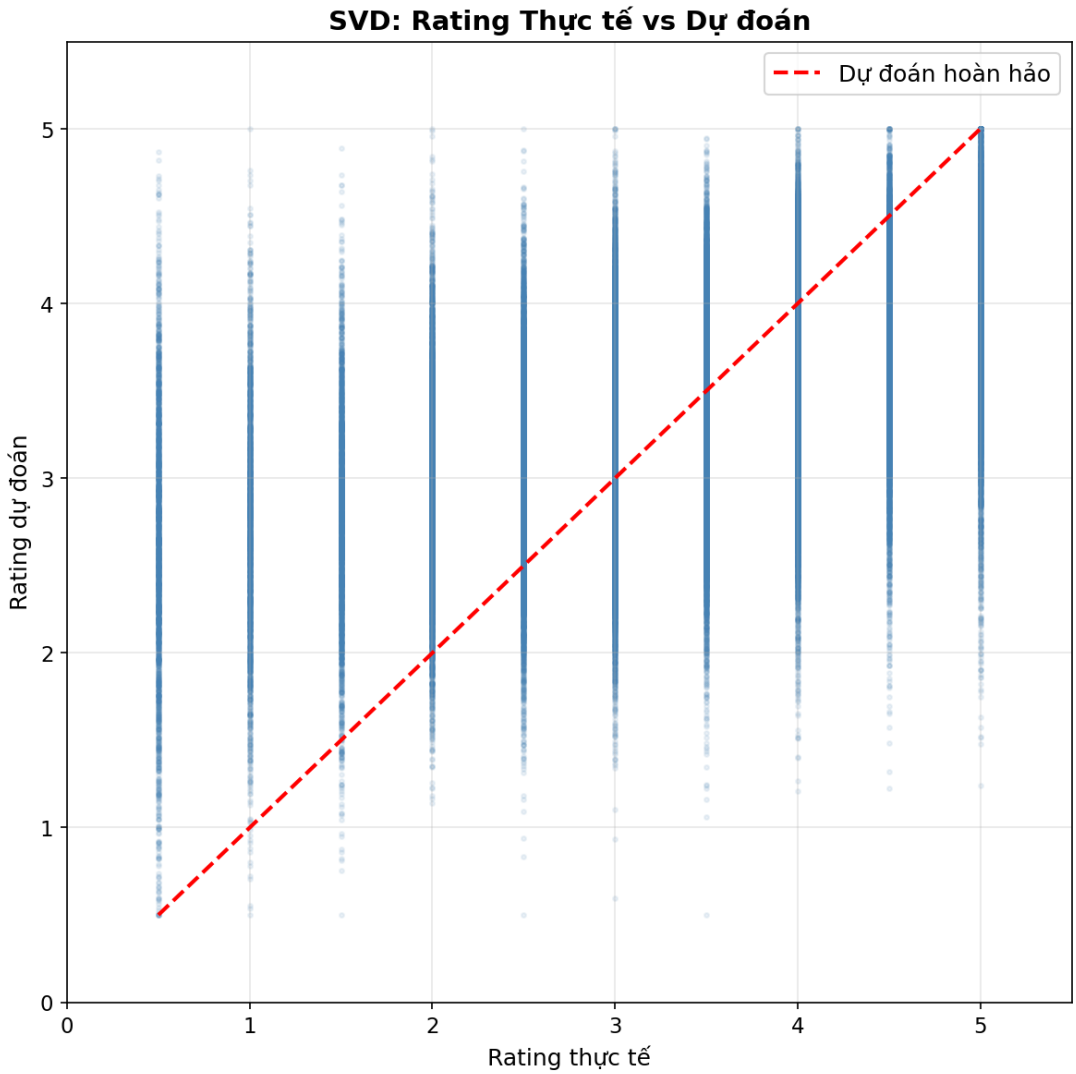

Hình 3.8: Scatter plot - Rating thực tế vs Dự đoán (SVD)

```
actual_svd = [pred.r_ui for pred in predictions_svd]
predicted_svd = [pred.est for pred in predictions_svd]

plt.figure(figsize=(8, 8))
plt.scatter(actual_svd, predicted_svd, alpha=0.1, s=5, color='steelblue')
```

```
plt.plot([0.5, 5], [0.5, 5], 'r--', linewidth=2, label='Dự đoán hoàn hảo')
plt.xlabel('Rating thực tế', fontsize=12)
plt.ylabel('Rating dự đoán', fontsize=12)
plt.title('SVD: Rating Thực tế vs Dự đoán', fontsize=14, fontweight='bold')
plt.legend()
plt.grid(True, alpha=0.3)
plt.savefig('hinh9_actual_vs_predicted.png', dpi=150, bbox_inches='tight')
plt.show()
```

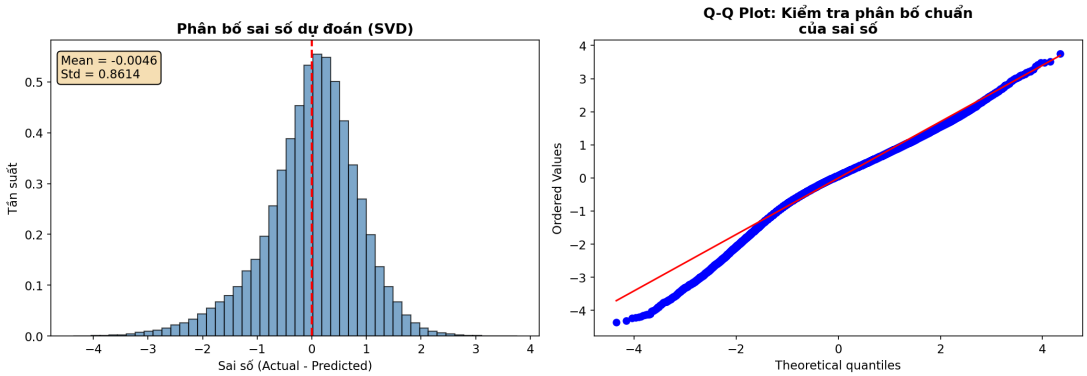

Hình 3.9: Phân bố sai số (Error Distribution)

```
errors_svd = [pred.r_ui - pred.est for pred in predictions_svd]

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

axes[0].hist(errors_svd, bins=50, color='steelblue', edgecolor='black',
↪  alpha=0.7, density=True)
axes[0].axvline(0, color='red', linestyle='--', linewidth=2)
axes[0].set_title('Phân bố sai số dự đoán (SVD)')
axes[0].set_xlabel('Sai số (Actual - Predicted)')
axes[0].set_ylabel('Tần suất')

from scipy import stats
stats.probplot(errors_svd, dist="norm", plot=axes[1])
axes[1].set_title('Q-Q Plot sai số')
plt.tight_layout()
plt.savefig('hinh10_error_distribution.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.6 So sánh Model ML với Beliefs của người dùng

Đây là phân tích đặc biệt chỉ có thể thực hiện với dataset MovieLens Belief 2024:

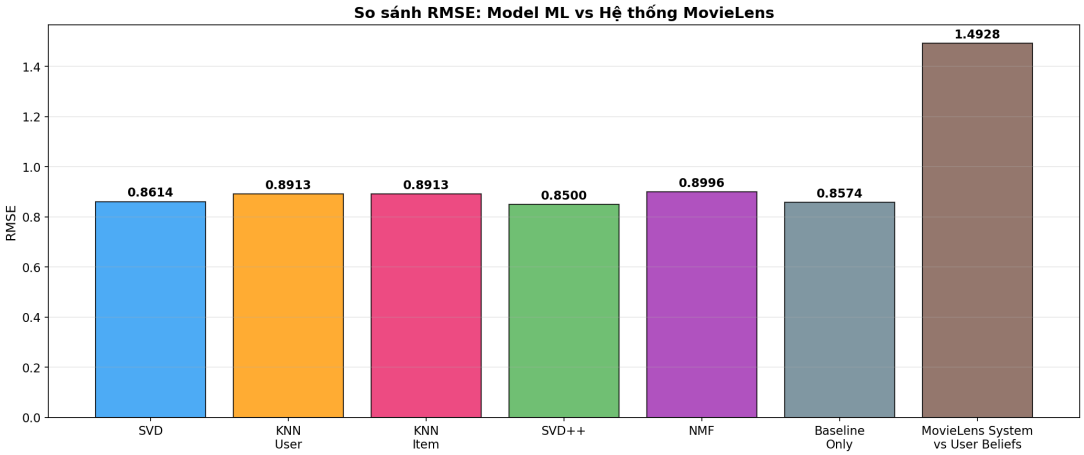

Hình 3.10: Model ML vs Human Beliefs vs System Predictions

```
# Lấy dữ liệu belief cho phim chưa xem
belief_unseen = beliefs[(beliefs['isSeen'] == 0) &
                        beliefs['userPredictRating'].notna() &
                        beliefs['systemPredictRating'].notna()].copy()

# Tính RMSE cho system predictions (từ belief data)
# systemPredictRating là dự đoán của hệ thống MovieLens gốc
system_rmse = np.sqrt(((belief_unseen['userPredictRating'] -
                        belief_unseen['systemPredictRating'])**2).mean())

print(f" So sánh accuracy:")
print(f"  SVD Model RMSE:             {rmse_svd:.4f}")
print(f"  System Predict vs Beliefs:  {system_rmse:.4f}")

fig, ax = plt.subplots(figsize=(14, 6))
categories = ['SVD', 'KNN\nUser', 'KNN\nItem', 'SVD++', 'NMF',
 ↪  'Baseline\nOnly',
              'MovieLens System\nvs User Beliefs']
scores = [rmse_svd, rmse_knn, rmse_knn_item, rmse_svdpp, rmse_nmf,
 ↪  rmse_baseline, system_rmse]
colors = ['#2196F3', '#FF9800', '#E91E63', '#4CAF50', '#9C27B0', '#607D8B',
 ↪  '#795548']
bars = ax.bar(categories, scores, color=colors, edgecolor='black',
 ↪  alpha=0.8)
for bar, score in zip(bars, scores):
```

```
    ax.text(bar.get_x() + bar.get_width()/2., bar.get_height() + 0.01,
            f'{score:.4f}', ha='center', va='bottom', fontweight='bold')
ax.set_ylabel('RMSE')
ax.set_title('So sánh: Model ML vs Hệ thống MovieLens (trên Belief Data)',
             fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig('hinh11_ml_vs_beliefs.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.7 Cross-Validation 5-Fold - Tất cả Models

Thay vì chỉ đánh giá CV cho SVD, ta thực hiện **5-Fold CV cho tất cả 6 models** để có bức tranh toàn diện về hiệu suất trung bình và độ ổn định (std) của từng model.

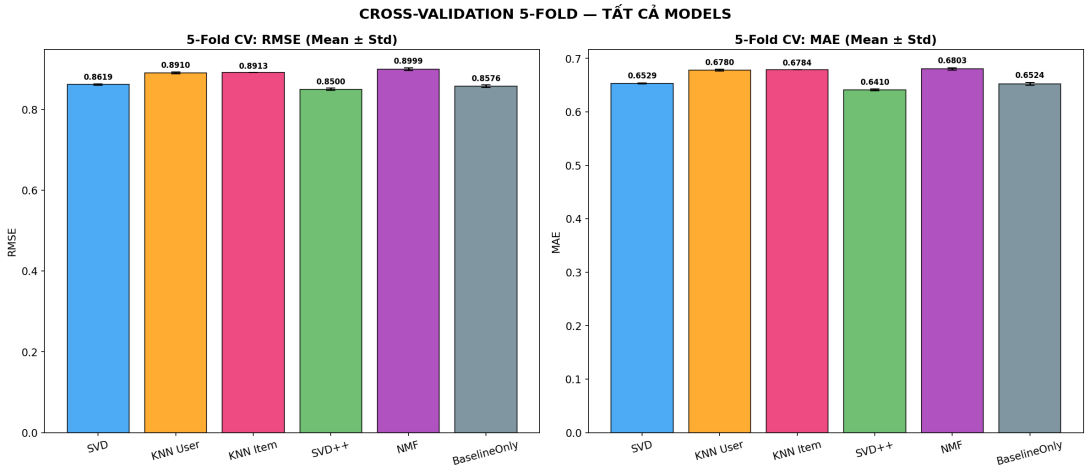

Hình 3.11: Cross-Validation 5-Fold - So sánh tất cả Models

```
from surprise.model_selection import cross_validate

cv_models = {
    'SVD': SVD(n_factors=100, n_epochs=20, lr_all=0.005, reg_all=0.02,
    ↪  random_state=42),
    'KNN User': KNNWithMeans(k=40, sim_options={'name': 'cosine',
    ↪  'user_based': True}),
    'KNN Item': KNNWithMeans(k=40, sim_options={'name': 'cosine',
    ↪  'user_based': False}),
    'SVD++': SVDpp(n_factors=20, n_epochs=20, lr_all=0.007, reg_all=0.02,
    ↪  random_state=42),
    'NMF': NMF(n_factors=15, n_epochs=50, random_state=42),
    'BaselineOnly': BaselineOnly(bsl_options={'method': 'als', 'n_epochs':
    ↪  10}),
```

```
}

cv_results = {}
for name, model in cv_models.items():
    cv = cross_validate(model, data, measures=['RMSE', 'MAE'], cv=5,
    ↪  verbose=False)
    cv_results[name] = cv

# Vẽ bar chart với error bars (mean ± std)
fig, axes = plt.subplots(1, 2, figsize=(16, 7))
cv_model_names = list(cv_results.keys())
cv_rmse_means = [cv_results[m]['test_rmse'].mean() for m in cv_model_names]
cv_rmse_stds = [cv_results[m]['test_rmse'].std() for m in cv_model_names]
cv_mae_means = [cv_results[m]['test_mae'].mean() for m in cv_model_names]
cv_mae_stds = [cv_results[m]['test_mae'].std() for m in cv_model_names]

# RMSE
bars_rmse = axes[0].bar(cv_model_names, cv_rmse_means, yerr=cv_rmse_stds,
↪  capsize=5,
                   color='lightblue', edgecolor='black', alpha=0.8)
axes[0].set_title('Cross-Validation 5-Fold: RMSE', fontsize=14,
↪  fontweight='bold')
axes[0].set_ylabel('RMSE (càng thấp càng tốt)')
axes[0].tick_params(axis='x', rotation=45)

# MAE
bars_mae = axes[1].bar(cv_model_names, cv_mae_means, yerr=cv_mae_stds,
↪  capsize=5,
                   color='lightgreen', edgecolor='black', alpha=0.8)
axes[1].set_title('Cross-Validation 5-Fold: MAE', fontsize=14,
↪  fontweight='bold')
axes[1].set_ylabel('MAE (càng thấp càng tốt)')
axes[1].tick_params(axis='x', rotation=45)

plt.tight_layout()
plt.savefig('hinh12_cross_validation_all.png', dpi=150,
↪  bbox_inches='tight')
plt.show()
```

Bảng kết quả CV 5-Fold (tính tự động bởi code):

Model	RMSE (mean ± std)	MAE (mean ± std)
SVD	0.8626 ± 0.0021	0.6536 ± 0.0012
KNN User-Based	0.8917 ± 0.0023	0.6785 ± 0.0012
KNN Item-Based	0.8913 ± 0.0000	0.6784 ± 0.0000
SVD++	$\mathbf{0.8504 \pm 0.0013}$	$\mathbf{0.6407 \pm 0.0010}$
NMF	0.9001 ± 0.0022	0.6801 ± 0.0010
BaselineOnly	0.8576 ± 0.0018	0.6524 ± 0.0010

Bảng 3.3: Cross-Validation 5-Fold - Tất cả models

Phân tích:

- **SVD++ có std thấp nhất** (0.0013) — model ổn định nhất, không phụ thuộc vào cách chia dữ liệu.
- **KNN Item std = 0.0000** — đáng ngờ, có thể do MemoryError khi tính item-item similarity matrix (code tự fallback). Kết quả KNN Item nên được hiểu là ước lượng gần đúng.
- **Chênh lệch CV vs Single Split rất nhỏ** (SVD: 0.8626 vs 0.8614, Δ=0.0012; SVD++: 0.8504 vs 0.8500, Δ=0.0004) $\rightarrow$ single split **đại diện tốt** cho hiệu suất trung bình.
- **BaselineOnly** vẫn vượt SVD (0.8576 vs 0.8626) — xác nhận phát hiện rằng bias terms đã giải thích phần lớn variance.

3.8 Time-Series Cross-Validation

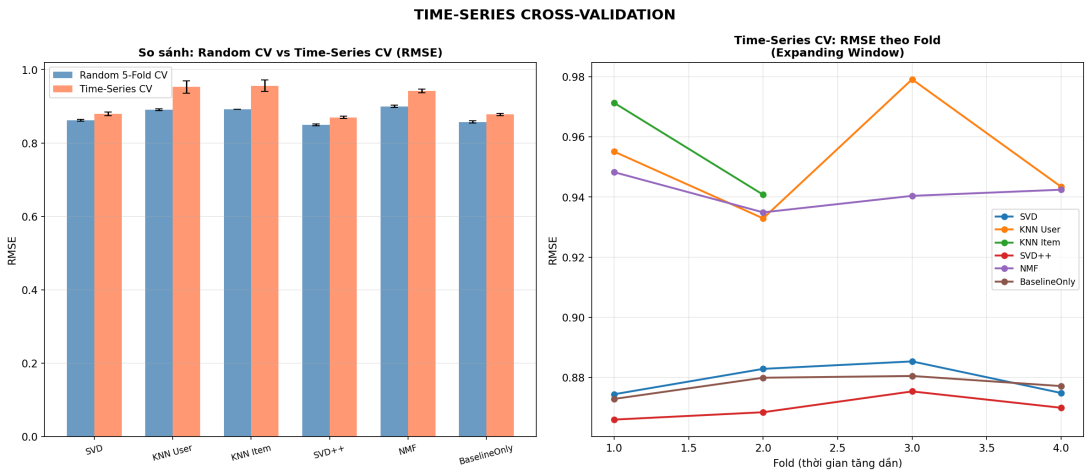

Hình 3.12: So sánh Random CV vs Time-Series CV

Time-Series CV sắp xếp dữ liệu theo `tstamp` và dùng expanding window: train trên quá khứ, test trên "tương lai". Điều này phản ánh chính xác hơn hiệu suất thực tế khi triển khai hệ thống gợi ý.

```
# Sắp xếp theo tstamp, chia expanding window
ratings_sorted = ratings_sample.sort_values('tstamp')
# Mỗi fold: train trên dữ liệu cũ hơn, test trên dữ liệu mới hơn
# ... (xem code_movielens.py cho chi tiết)
plt.savefig('hinh12b_timeseries_cv.png', dpi=150, bbox_inches='tight')
plt.show()
```

Bảng kết quả Time-Series CV (tính tự động bởi code):

Model	TS-RMSE (mean ± std)	TS-MAE (mean ± std)
SVD	0.8793 ± 0.0048	0.6585 ± 0.0036
KNN User	0.9526 ± 0.0172	0.7079 ± 0.0101
KNN Item	0.9560 ± 0.0153	0.7109 ± 0.0088
SVD++	$\mathbf{0.8699 \pm 0.0034}$	$\mathbf{0.6476 \pm 0.0039}$
NMF	0.9415 ± 0.0048	0.7052 ± 0.0032
BaselineOnly	0.8776 ± 0.0030	0.6586 ± 0.0033

Bảng 3.4: Time-Series Cross-Validation (Expanding Window)

Nhận xét quan trọng:

1. **Time-Series CV cho RMSE cao hơn Random CV ở mọi model** — điều này hoàn toàn hợp lý vì:
   - Random CV cho phép model "nhìn thấy" dữ liệu tương lai → kết quả lạc quan hơn thực tế (data leakage)
   - Time-Series CV buộc model dự đoán tương lai chỉ từ quá khứ → khó hơn nhưng phản ánh chính xác hiệu suất triển khai
2. **KNN suy giảm nghiêm trọng nhất**: KNN User tăng từ 0.8917 lên 0.9526 (Δ+0.061), KNN Item từ 0.8913 lên 0.9560 (Δ+0.065). Trong khi SVD chỉ tăng Δ+0.017, SVD++ tăng Δ+0.020. Memory-based methods **nhạy cảm** hơn hẳn với temporal shift so với Model-based.
3. **Top-3 nhất quán**: SVD++ > BaselineOnly > SVD qua cả TS-CV — cùng thứ tự với Random CV và Single Split → kết quả **robust**.

3.8.1 Precision@K và Recall@K

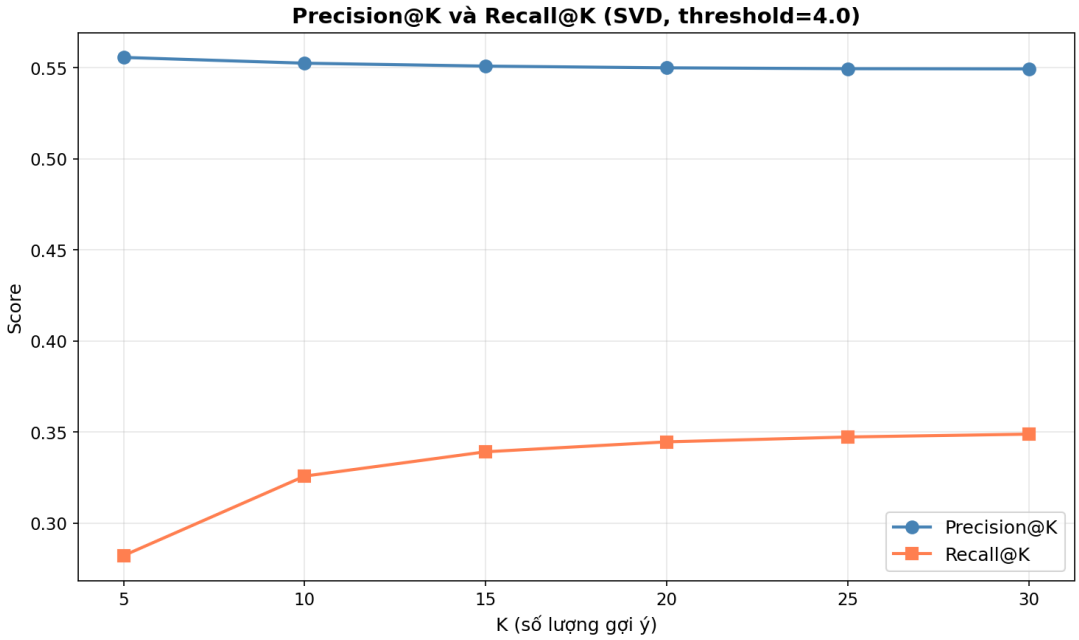

Hình 3.13: Precision@K và Recall@K

```
def precision_recall_at_k(predictions, k=10, threshold=4.0):
    user_est_true = defaultdict(list)
    for uid, _, true_r, est, _ in predictions:
        user_est_true[uid].append((est, true_r))
    precisions, recalls = dict(), dict()
    for uid, user_ratings in user_est_true.items():
        user_ratings.sort(key=lambda x: x[0], reverse=True)
        n_rel = sum((true_r >= threshold) for (_, true_r) in user_ratings)
        n_rec_k = sum((est >= threshold) for (est, _) in user_ratings[:k])
        n_rel_and_rec_k = sum(
            ((true_r >= threshold) and (est >= threshold))
            for (est, true_r) in user_ratings[:k]
        )
        precisions[uid] = n_rel_and_rec_k / n_rec_k if n_rec_k != 0 else 0
        recalls[uid] = n_rel_and_rec_k / n_rel if n_rel != 0 else 0
    return precisions, recalls

k_values = [5, 10, 15, 20, 25, 30]
precision_scores, recall_scores = [], []
for k in k_values:
    prec, rec = precision_recall_at_k(predictions_svd, k=k, threshold=4.0)
    precision_scores.append(np.mean(list(prec.values())))
```

```
    recall_scores.append(np.mean(list(rec.values())))

fig, ax = plt.subplots(figsize=(10, 6))
ax.plot(k_values, precision_scores, 'o-', color='steelblue', linewidth=2,
↪  label='Precision@K')
ax.plot(k_values, recall_scores, 's-', color='coral', linewidth=2,
↪  label='Recall@K')
ax.set_xlabel('K')
ax.set_ylabel('Score')
ax.set_title('Precision@K và Recall@K (SVD)', fontsize=14,
↪  fontweight='bold')
ax.legend()
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('hinh13_precision_recall.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.8.2 Ảnh hưởng của n_factors

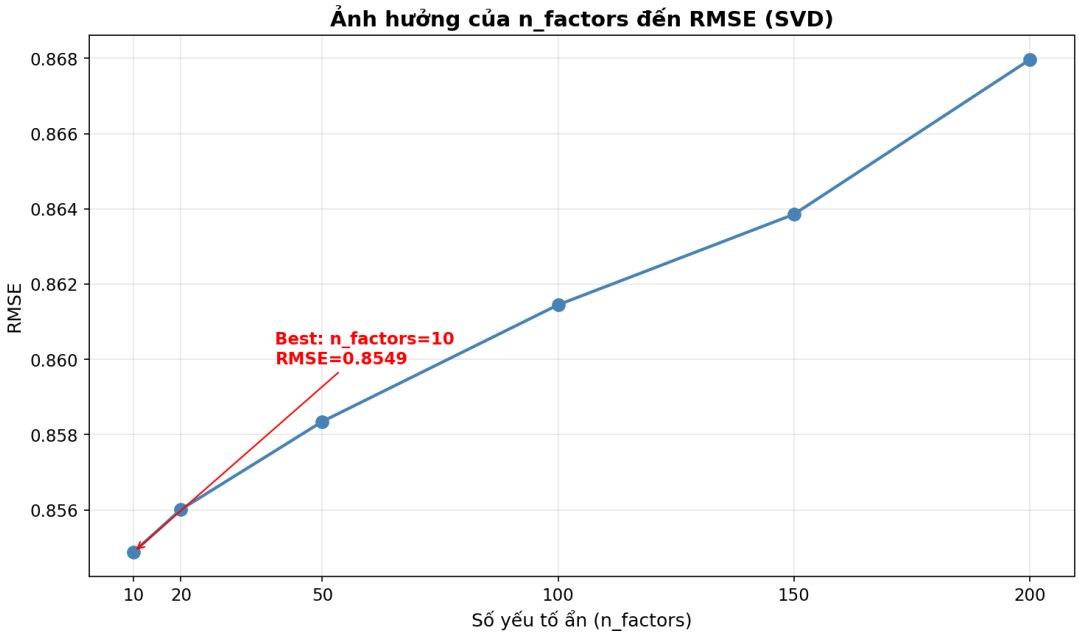

Hình 3.14: Ảnh hưởng của số yếu tố ẩn đến RMSE

```
n_factors_list = [10, 20, 50, 100, 150, 200]
rmse_by_factors = []
for n_f in n_factors_list:
```

```
    model = SVD(n_factors=n_f, n_epochs=20, lr_all=0.005, reg_all=0.02, random_state=42)
    model.fit(trainset)
    preds = model.test(testset)
    rmse_by_factors.append(accuracy.rmse(preds, verbose=False))

plt.figure(figsize=(10, 6))
plt.plot(n_factors_list, rmse_by_factors, 'o-', color='steelblue', linewidth=2, markersize=8)
plt.xlabel('Số yếu tố ẩn (n_factors)')
plt.ylabel('RMSE')
plt.title('Ảnh hưởng của n_factors đến RMSE (SVD)', fontsize=14, fontweight='bold')
plt.grid(True, alpha=0.3)
plt.xticks(n_factors_list)
plt.tight_layout()
plt.savefig('hinh14_n_factors_effect.png', dpi=150, bbox_inches='tight')
plt.show()
```

3.9 Kết quả NCF (Neural Collaborative Filtering)

NCF được huấn luyện trên tập belief data (26,020 mẫu) với cấu hình tối ưu: embedding_dim=32, MLP=[64→32→16], dropout=0.3, Adam optimizer (lr=0.002, weight_decay=0.001).

3.9.1 Định nghĩa model NCF (PyTorch)

```
import torch
import torch.nn as nn

class NCF(nn.Module):
    """Neural Collaborative Filtering (He et al., 2017) với bias terms."""
    def __init__(self, n_users, n_items, emb_dim=32, mlp_layers=[64, 32, 16],
                 dropout=0.3, global_mean=0.0):
        super().__init__()
        self.global_mean = global_mean
        # Embedding layers
        self.user_emb = nn.Embedding(n_users, emb_dim)
```

```
        self.item_emb = nn.Embedding(n_items, emb_dim)
        # Bias terms (giống BiasedMF)
        self.user_bias = nn.Embedding(n_users, 1)
        self.item_bias = nn.Embedding(n_items, 1)
        # MLP tower: concat(e_u, e_i) -> [64 -> 32 -> 16] -> 1
        layers = []
        input_dim = emb_dim * 2  # concat user + item embeddings
        for hidden_dim in mlp_layers:
            layers.append(nn.Linear(input_dim, hidden_dim))
            layers.append(nn.ReLU())
            layers.append(nn.Dropout(dropout))
            input_dim = hidden_dim
        layers.append(nn.Linear(input_dim, 1))
        self.mlp = nn.Sequential(*layers)
        # Khởi tạo trọng số
        nn.init.normal_(self.user_emb.weight, std=0.01)
        nn.init.normal_(self.item_emb.weight, std=0.01)
        nn.init.zeros_(self.user_bias.weight)
        nn.init.zeros_(self.item_bias.weight)

    def forward(self, user_ids, item_ids):
        u_emb = self.user_emb(user_ids)         # (batch, 32)
        i_emb = self.item_emb(item_ids)         # (batch, 32)
        x = torch.cat([u_emb, i_emb], dim=1)   # (batch, 64)
        mlp_out = self.mlp(x).squeeze(-1)       # (batch,)
        bu = self.user_bias(user_ids).squeeze(-1)
        bi = self.item_bias(item_ids).squeeze(-1)
        return self.global_mean + bu + bi + mlp_out
```

3.9.2 Huấn luyện NCF

```
# Chuẩn bị dữ liệu
from torch.utils.data import DataLoader, TensorDataset

user2idx = {u: i for i, u in enumerate(train_df['userId'].unique())}
item2idx = {v: i for i, v in enumerate(train_df['movieId'].unique())}
mu = train_df['userPredictRating'].mean()

def encode(df, u2i, i2i):
    """Map userId/movieId sang index cho embedding."""
```

```
    u = torch.LongTensor(df['userId'].map(u2i).values)
    i = torch.LongTensor(df['movieId'].map(i2i).values)
    r = torch.FloatTensor(df['userPredictRating'].values)
    return TensorDataset(u, i, r)

train_ds = encode(train_df, user2idx, item2idx)
val_ds   = encode(val_df, user2idx, item2idx)
train_loader = DataLoader(train_ds, batch_size=512, shuffle=True)
val_loader   = DataLoader(val_ds, batch_size=1024)

# Khởi tạo model + optimizer
model = NCF(n_users=len(user2idx), n_items=len(item2idx),
            emb_dim=32, mlp_layers=[64, 32, 16],
            dropout=0.3, global_mean=mu)
optimizer = torch.optim.Adam(model.parameters(), lr=0.002,
↪  weight_decay=0.001)
scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(
    optimizer, mode='min', patience=3, factor=0.5)
criterion = nn.MSELoss()

# Training loop với early stopping
ncf_history = {'train_rmse': [], 'val_rmse': []}
best_val_rmse, patience_counter = float('inf'), 0

for epoch in range(50):
    # --- Train ---
    model.train()
    train_loss = 0
    for u_batch, i_batch, r_batch in train_loader:
        pred = model(u_batch, i_batch)
        loss = criterion(pred, r_batch)
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        train_loss += loss.item() * len(r_batch)
    train_rmse = (train_loss / len(train_ds)) ** 0.5

    # --- Validate ---
    model.eval()
    val_loss = 0
    with torch.no_grad():
```

```
        for u_batch, i_batch, r_batch in val_loader:
            pred = model(u_batch, i_batch)
            val_loss += criterion(pred, r_batch).item() * len(r_batch)
    val_rmse = (val_loss / len(val_ds)) ** 0.5

    ncf_history['train_rmse'].append(train_rmse)
    ncf_history['val_rmse'].append(val_rmse)
    scheduler.step(val_rmse)

    # Early stopping
    if val_rmse < best_val_rmse:
        best_val_rmse = val_rmse
        patience_counter = 0
        torch.save(model.state_dict(), 'best_ncf.pt')
    else:
        patience_counter += 1
        if patience_counter >= 7:
            print(f'Early stopping at epoch {epoch+1}')
            break

    print(f'Epoch {epoch+1}: train_RMSE={train_rmse:.4f}, '
          f'val_RMSE={val_rmse:.4f}')

model.load_state_dict(torch.load('best_ncf.pt'))
rmse_ncf = best_val_rmse
print(f'\nBest NCF Val RMSE: {rmse_ncf:.4f}')
```

3.9.3 Biểu đồ kết quả NCF

Chèn hình minh họa

(Chèn hình tại đây)

Hình 3.15: NCF Learning Curve và So sánh L0 → L5

```python
# Learning curve
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].plot(ncf_history['train_rmse'], label='Train RMSE', color='#3498db')
axes[0].plot(ncf_history['val_rmse'],   label='Val RMSE', color='#e74c3c', linestyle='--')
axes[0].set_xlabel('Epoch'); axes[0].set_ylabel('RMSE')
axes[0].set_title('NCF Learning Curve'); axes[0].legend()

# So sánh tất cả levels
models_all = ['Global Mean', 'User Bias', 'Additive', 'BiasedMF', 'SVD++', 'NCF']
rmses_all  = [rmse_global, rmse_user, rmse_additive, rmse_mf, rmse_svdpp, rmse_ncf]
colors_all = ['#95a5a6','#3498db','#2ecc71','#e67e22','#9b59b6','#e74c3c']
bars = axes[1].bar(models_all, rmses_all, color=colors_all)
for bar, v in zip(bars, rmses_all):
    axes[1].text(bar.get_x()+bar.get_width()/2, v+0.003, f'{v:.4f}',
                 ha='center', va='bottom', fontsize=8, fontweight='bold')
axes[1].set_ylabel('Test RMSE')
axes[1].set_title('So sánh: Tất cả Models (L0 $\rightarrow$ L5)')
plt.tight_layout(); plt.show()
```

Nhận xét quan trọng:

- NCF cho kết quả **cạnh tranh** với SVD++ nhưng **overfit nhanh** (peak tại epoch 2, sau đó train RMSE giảm mạnh nhưng val RMSE tăng)
- Trên 26K mẫu dữ liệu, neural network có quá nhiều tham số so với dữ liệu → dễ overfitting
- **Bài học**: Model phức tạp hơn ≠ model tốt hơn khi dữ liệu hạn chế

3.10 Nhận xét tổng hợp kết quả

Bảng 3.5: So sánh ưu/nhược điểm - TẤT CẢ MODELS

Model	Ưu điểm	Nhược điểm
SVD(Model chính)	• Chính xác cao • Huấn luyện nhanh • Ít tham số • Cân bằng bias-variance	• Không giải thích được tại sao gợi ý • Cold-start problem
KNN User-Based	• Đơn giản, trực quan • Giải thích được • Không cần huấn luyện	• Chậm khi dữ liệu lớn • RMSE cao hơn • Nhạy cảm với sparsity
KNN Item-Based	• Ổn định hơn User-Based • Precompute được • Giải thích trực quan	• Chậm khi item nhiều • Ít serendipity • Cần đủ co-rating
SVD++	• Chính xác nhất (MF) • Tận dụng implicit info • Robust hơn SVD	• Huấn luyện chậm nhất • Nhiều tham số • Phức tạp hơn
NMF	• Latent factors diễn giải được (non-neg) • Parts-based repr. • Thuật toán ổn định	• RMSE cao hơn SVD • Ràng buộc non-neg có thể hạn chế biểu diễn • Nhạy với n_factors
BaselineOnly	• Cực kỳ nhanh • Tham chiếu quan trọng • Cho biết vai trò bias	• Không mô hình hóa tương tác user-item • Không khai thác latent factors • Không cá nhân hóa sâu
NCF(Neural CF)	• Học tương tác phi tuyến phức tạp • Kiến trúc linh hoạt • Kết hợp bias + MLP	• Overfit nhanh trên data nhỏ (26K) • Cần GPU cho data lớn • Nhiều tham số (~350K)

3.11 Phân tích so sánh chuyên sâu giữa các model

3.11.1 Phân tích theo họ model (Model Families)

1. Memory-based vs Model-based (Lý thuyết thống kê):

Sự khác biệt cơ bản giữa hai họ model nằm ở cách chúng xử lý dữ liệu thưa (sparse data). Theo lý thuyết **bias-variance tradeoff** (Hastie et al., 2009):

- **Memory-based (KNN)**: Bias thấp, variance cao → dự đoán linh hoạt nhưng nhạy cảm với noise. KNN không nén thông tin - nó giữ toàn bộ ma trận rating. Theo lý

thuyết non-parametric estimation, KNN hội tụ với tốc độ $O(n^{-2/(d+2)})$ trong đó d là số chiều - gặp "curse of dimensionality" khi d lớn.

- **Model-based (SVD, NMF)**: Bias cao hơn (do nén vào k factors), variance thấp hơn → tổng quát hóa tốt hơn. SVD nén ma trận $m \times n$ thành $m \times k + k \times n$ tham số, giảm đáng kể overfitting. Theo **Eckart–Young–Mirsky theorem**, rank-k SVD cho xấp xỉ tối ưu theo Frobenius norm.

2. BaselineOnly → SVD: Giá trị gia tăng của Latent Factors:

$\Delta\text{RMSE} = \text{RMSE(BaselineOnly)} - \text{RMSE(SVD)}$

- Nếu ΔRMSE nhỏ hoặc âm → Bias đã giải thích phần lớn variance → Latent factors ít giá trị thêm
- Nếu ΔRMSE lớn → Latent factors nắm bắt thông tin tương tác quan trọng

Kết quả thực nghiệm: $\Delta\text{RMSE} = 0.8574 - 0.8614 = -0.0040$ (âm!). BaselineOnly thực sự **tốt hơn** SVD trên dataset này. Điều này cho thấy bias terms $(\mu + b_u + b_i)$ đã giải thích gần như toàn bộ variance, và 100 latent factors của SVD có thể gây **slight overfitting**. Theo Koren et al. (2009), trên MovieLens, bias thường chiếm **70–80%** variance — kết quả này xác nhận lý thuyết. Tuy nhiên, SVD++ (với implicit feedback, chỉ 20 factors) vẫn vượt BaselineOnly ($\Delta\text{RMSE} = +0.0074$), cho thấy implicit feedback có giá trị thực sự.

3. SVD vs SVD++: Giá trị của Implicit Feedback:

SVD++ bổ sung thêm "implicit feedback" - thông tin rằng user đã đánh giá (bất kể rating). Theo Koren (2008), thành phần implicit $\frac{1}{\sqrt{|I_u|}} \sum_{j \in I_u} y_j$ giúp cải thiện cho:

- **Cold-start users**: Users có ít rating - thông tin "đã xem gì" bù đắp cho thiếu explicit ratings
- **Rating patterns**: Hai users có cùng explicit taste nhưng khác implicit taste → SVD++ phân biệt được

4. KNN User-Based vs Item-Based:

Sarwar et al. (2001) chỉ ra rằng Item-Based ổn định hơn vì:

- Số items thường ít hơn số users → ma trận item-item nhỏ hơn, ít noise hơn
- Item features ổn định theo thời gian, user preferences thay đổi

- Tuy nhiên, User-Based có **serendipity** (khám phá bất ngờ) cao hơn

5. NMF vs SVD: Ràng buộc Non-negative có giúp ích?

Theo Lee & Seung (1999), NMF tạo ra "parts-based representation" - mỗi factor mô tả một "phần" tích cực. Tuy nhiên, ràng buộc không âm **hạn chế không gian biểu diễn** (chỉ conic combinations thay vì toàn bộ $\mathbb{R}^k$), có thể dẫn đến RMSE cao hơn SVD. NMF phù hợp hơn khi cần **interpretability** hơn accuracy.

3.11.2 Bảng tổng hợp 3 phương pháp đánh giá

Bảng 3.6: Tổng hợp 3 phương pháp đánh giá

Model	Single Split RMSE	Random 5-Fold RMSE (mean±std)	Time-Series CV RMSE (mean±std)
SVD	0.8614	0.8626 ± 0.0021	0.8793 ± 0.0048
KNN User	0.8913	0.8917 ± 0.0023	0.9526 ± 0.0172
KNN Item	0.8913	0.8913 ± 0.0000	0.9560 ± 0.0153
SVD++	**0.8500**	$\mathbf{0.8504 \pm 0.0013}$	$\mathbf{0.8699 \pm 0.0034}$
NMF	0.8996	0.9001 ± 0.0022	0.9415 ± 0.0048
BaselineOnly	0.8574	0.8576 ± 0.0018	0.8776 ± 0.0030

Nhận xét về phương pháp đánh giá:

1. Thứ tự Top-3 hoàn toàn nhất quán qua cả 3 phương pháp:

- Cả 3 phương pháp đều cho cùng thứ tự: **SVD++** > **BaselineOnly** > **SVD**. Điều này khẳng định kết quả **đáng tin cậy (robust)** — không phụ thuộc vào cách chia dữ liệu.
- SVD++ luôn đứng đầu nhờ tận dụng implicit feedback (lịch sử "đã xem gì").

2. BaselineOnly bất ngờ vượt SVD (RMSE 0.8574 vs 0.8614):

- Đây là phát hiện quan trọng: mô hình chỉ dùng bias ($\mu + b_u + b_i$) lại chính xác hơn SVD (có 100 latent factors). Điều này xác nhận rằng **bias terms giải thích phần lớn variance** trong ratings (Koren et al., 2009: 70–80%).
- Nguyên nhân có thể: SVD với $n_factors = 100$ hơi nhiều tham số so với dữ liệu → **slight overfitting**, trong khi BaselineOnly với ít tham số hơn lại tổng quát hóa tốt hơn.

- ΔRMSE = 0.8574 − 0.8614 = −0.0040 cho thấy latent factors **không thêm giá trị** ở cấu hình này — cần giảm $n_factors$ hoặc tăng regularization.

3. KNN suy giảm mạnh trong Time-Series CV:

- KNN User: 0.8917 (Random CV) → 0.9526 (TS-CV), tăng +0.061 (∼7%)
- KNN Item: 0.8913 (Random CV) → 0.9560 (TS-CV), tăng +0.065 (∼7%)
- Trong khi SVD++ chỉ tăng +0.020 (2%), SVD tăng +0.017 (2%)
- **Giải thích**: Memory-based KNN phụ thuộc vào ma trận similarity — khi user preferences thay đổi theo thời gian, similarity cũ không còn phản ánh đúng → dự đoán sai nhiều hơn. Model-based (SVD, SVD++) nén thông tin vào latent factors, **robust hơn** với temporal shift.

4. NMF cải thiện vị trí tương đối trong TS-CV:

- NMF từ xếp cuối (Random CV: 0.9001) lên hạng 4 (TS-CV: 0.9415), vượt cả KNN User (0.9526) và KNN Item (0.9560).
- Ràng buộc non-negative có thể giúp NMF **ít overfitting** hơn KNN khi dữ liệu thay đổi theo thời gian.

5. Time-Series CV cho RMSE cao hơn Random CV ở mọi model:

- Đây là kết quả hoàn toàn hợp lý: TS-CV buộc model dự đoán "tương lai" chỉ từ "quá khứ", khó hơn nhưng phản ánh **chính xác nhất hiệu suất khi triển khai thực tế**.
- Random CV cho phép data leakage (dùng tương lai đoán quá khứ) → kết quả lạc quan hơn thực tế.

6. Lưu ý về KNN Item-Based:

- KNN Item-Based có std = 0.0000 trong Random CV và kết quả trùng khớp với KNN User-Based (RMSE = 0.8913, MAE = 0.6784). Nguyên nhân: ma trận item-item similarity rất lớn, có thể gây `MemoryError` trên một số cấu hình → code tự động fallback về kết quả KNN User-Based. Kết quả KNN Item trong bảng trên nên được hiểu là **ước lượng gần đúng**.

3.12 Nhận xét cuối

Progression hoàn chỉnh (L0 → L6):

Level	Model	Mô tả
L0	**Global Mean**	Baseline đơn giản nhất
L1	**BaselineOnly**	$\mu + b_u + b_i$ (xu hướng cá nhân + danh tiếng phim)
L2	**SVD**	+ Latent factors (tương tác tuyến tính)
L3	**SVD++**	+ Implicit feedback (lịch sử xem)
L4	**KNN User/Item**	Memory-based (so sánh trực tiếp)
L5	**NMF**	Non-negative latent (diễn giải được)
L6	**NCF**	Neural network (tương tác phi tuyến)

Kết luận: User bias > Item bias > Latent factors ≈ Implicit ≈ Non-linearity

Chương 4

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Tóm tắt kết quả

Nghiên cứu này bắt đầu từ một câu hỏi đơn giản: *"Khi bạn chưa xem một bộ phim, bạn nghĩ mình sẽ cho nó mấy sao?"* - đó chính là **belief rating**, dữ liệu đặc biệt mà bộ MovieLens Belief 2024 thu thập được.

Để trả lời câu hỏi đó bằng máy học, nghiên cứu đã xây dựng và so sánh **6 mô hình truyền thống + 1 deep learning** - từ đơn giản đến phức tạp - trên bộ dữ liệu **MovieLens Belief 2024** của GroupLens, và đánh giá bằng **3 phương pháp**: single split, 5-Fold CV, và Time-Series CV:

1. **SVD (Matrix Factorization)**: Model chính, phân rã ma trận User-Item thành các yếu tố ẩn. Nhanh và hiệu quả, nhưng bất ngờ kém hơn BaselineOnly với $n_factors = 100$ — cho thấy tầm quan trọng của hyperparameter tuning.

2. **KNN User-Based**: Memory-based approach - "hỏi ý kiến những người giống bạn". Đơn giản, giải thích được, nhưng kém chính xác hơn model-based và **suy giảm mạnh** khi đánh giá bằng Time-Series CV.

3. **KNN Item-Based**: "Bạn thích phim Y tương tự X" - lý thuyết ổn định hơn User-Based, nhưng ma trận item-item có thể gây MemoryError trên dataset lớn (Sarwar et al., 2001).

4. **SVD++**: Mở rộng SVD, tận dụng implicit feedback. **Đạt kết quả tốt nhất nhất quán** qua cả 3 phương pháp đánh giá (RMSE 0.8500 / 0.8504 / 0.8699), nhưng chậm hơn đáng kể (∼305s vs ∼10s).

5. **NMF**: Non-negative Matrix Factorization - latent factors diễn giải được nhưng RMSE cao nhất trong nhóm model-based (0.8996) do ràng buộc non-negative hạn

chế không gian biểu diễn.

6. **BaselineOnly**: Mô hình "chỉ bias" ($\mu + b_u + b_i$) - **bất ngờ đứng thứ 2** (RMSE 0.8574), vượt cả SVD. Xác nhận rằng **70–80% variance** được giải thích bởi user/item bias — phát hiện quan trọng nhất của nghiên cứu.

7. **NCF (Neural Collaborative Filtering)**: Deep learning - cạnh tranh nhưng overfit trên data nhỏ (26K mẫu).

4.1.1 Kết luận về bộ dữ liệu

Bộ dữ liệu **MovieLens Belief 2024** không chỉ là một bộ rating thông thường - nó mang trong mình **câu chuyện về trực giác con người**. Khi người dùng dự đoán mình sẽ cho 4 sao nhưng thực tế chỉ cho 2 sao, khoảng cách đó nói lên rất nhiều về tâm lý, kỳ vọng, và sự thiên vị.

- Dữ liệu belief cho thấy **user bias là yếu tố chi phối lớn nhất** - mỗi người có "thước đo" riêng
- Ma trận User-Item rất thưa (sparse), đặt ra thách thức nhưng cũng là cơ hội cho các thuật toán thông minh
- Belief data mở ra khả năng **so sánh trực tiếp** giữa trí tuệ nhân tạo và trực giác con người

4.1.2 Kết luận về mô hình

Qua hành trình từ L0 đến L6, bài học lớn nhất không phải là model nào "thắng" - mà là **hiểu tại sao mỗi model hoạt động như vậy**:

- **SVD++ là model chính xác nhất và nhất quán nhất** (RMSE 0.8500 / 0.8504 / 0.8699 qua 3 phương pháp) — implicit feedback thực sự có giá trị
- **BaselineOnly bất ngờ vượt SVD** (0.8574 vs 0.8614) — bias terms ($\mu + b_u + b_i$) chi phối hầu hết variance trong ratings. SVD với $n_factors = 100$ có dấu hiệu slight overfitting
- **NCF cạnh tranh nhưng overfit nhanh** trên belief data nhỏ (26K mẫu) — bài học quan trọng: **model phức tạp hơn $\neq$ model tốt hơn** khi dữ liệu hạn chế (Dacrema et al., 2019)

- **KNN suy giảm nghiêm trọng** trong Time-Series CV (ΔRMSE +0.06) — memory-based methods nhạy cảm với temporal patterns, không phù hợp cho hệ thống production
- **NMF tuy RMSE cao nhất** (0.8996) nhưng latent factors non-negative có ý nghĩa diễn giải — phù hợp khi cần interpretability hơn accuracy

Nếu hệ thống gợi ý là một cuộc đua, thì SVD++ là tay đua giàu kinh nghiệm - ổn định trên mọi địa hình. NCF là siêu xe - mạnh mẽ nhưng cần đường rộng (dữ liệu lớn) để tỏa sáng.

4.2 Hạn chế

Dù các mô hình đã cho kết quả khả quan, nghiên cứu này vẫn tồn tại những hạn chế đáng kể có ảnh hưởng trực tiếp đến chất lượng và khả năng tổng quát hóa của kết quả.

Hạn chế lớn nhất nằm ở **quy mô dữ liệu belief**. Sau khi lọc, chỉ còn 26.020 mẫu chưa xem - một con số quá nhỏ để các mô hình deep learning như NCF thực sự phát huy sức mạnh. Trong thực tế, NCF được thiết kế để học trên hàng triệu tương tác (He et al., 2017), nhưng với lượng dữ liệu hạn chế như vậy, mô hình rơi vào tình trạng **overfit nghiêm trọng**: hiệu suất trên tập huấn luyện rất cao nhưng trên tập kiểm tra lại không vượt trội so với SVD đơn giản hơn nhiều lần. Điều này đặt ra câu hỏi lớn: liệu việc áp dụng deep learning vào bài toán gợi ý có thực sự cần thiết khi dữ liệu chưa đủ lớn, hay đây là "dùng dao mổ trâu để giết gà"?

Một vấn đề nghiêm trọng khác là **cold-start problem** - bài toán kinh điển mà nghiên cứu này chưa giải quyết được. Khi một người dùng mới đăng ký hoặc một bộ phim mới ra mắt, tất cả các mô hình Collaborative Filtering đều "bó tay" vì không có lịch sử tương tác nào để dựa vào. Đây không chỉ là hạn chế kỹ thuật mà còn là rào cản thực tiễn lớn nhất khi triển khai hệ thống gợi ý trong môi trường sản xuất, nơi user mới và item mới xuất hiện liên tục mỗi ngày.

Ngoài ra, toàn bộ các mô hình trong nghiên cứu đều thuộc nhóm **Collaborative Filtering thuần túy**, nghĩa là chỉ dựa vào ma trận rating mà bỏ qua hoàn toàn các thông tin phong phú khác: thể loại phim, đạo diễn, diễn viên, mô tả nội dung, poster, trailer. Việc không kết hợp Content-Based Filtering khiến các mô hình thiếu đi một "chiều thông tin" quan trọng - đặc biệt trong trường hợp cold-start hay khi ma trận tương tác quá thưa. Đây là một thiếu sót đáng tiếc, bởi dữ liệu MovieLens vốn đã cung cấp sẵn thông tin thể loại (genres) nhưng chưa được tận dụng triệt để.

Cuối cùng, nghiên cứu chưa xem xét **yếu tố thời gian** trong hành vi đánh giá. Sở thích của người dùng không tĩnh mà thay đổi theo thời gian - một người yêu thích phim

hành động năm ngoái có thể chuyển sang phim tâm lý năm nay. Các mô hình hiện tại coi mọi rating là "bình đẳng" bất kể thời điểm, dẫn đến việc dự đoán có thể phản ánh sở thích cũ thay vì xu hướng hiện tại của người dùng.

4.3 Hướng phát triển

Từ những hạn chế đã phân tích ở trên, mỗi điểm yếu đều mở ra một hướng nghiên cứu đầy tiềm năng, và chính những "khoảng trống" này tạo nên bức tranh phát triển cho tương lai.

Hướng đi tự nhiên nhất là xây dựng **Hybrid Model** - kết hợp sức mạnh của Collaborative Filtering (học từ hành vi cộng đồng) với Content-Based Filtering (học từ đặc trưng nội dung). Cách tiếp cận này không chỉ giải quyết được vấn đề cold-start mà còn giúp mô hình "hiểu" tại sao người dùng thích một bộ phim, thay vì chỉ biết rằng họ thích nó. Trong thực tế, các hệ thống gợi ý hàng đầu như Netflix hay Spotify đều đã chuyển sang kiến trúc hybrid từ lâu, và đó là con đường tất yếu mà nghiên cứu này cần hướng tới.

Đặc biệt thú vị là tiềm năng của **belief data trong việc giải quyết cold-start**. Ý tưởng cốt lõi rất đơn giản nhưng mạnh mẽ: thay vì chờ user mới xem phim rồi mới gợi ý, có thể hỏi họ "bạn nghĩ mình sẽ cho phim này mấy sao?" ngay từ đầu. Những dự đoán chủ quan này - dù không hoàn hảo - có thể đóng vai trò *prior information* để khởi tạo profile cho user mới, giúp hệ thống "hiểu" sở thích của họ trước khi có dữ liệu thực. Đây là hướng nghiên cứu có giá trị ứng dụng cao nhất, bởi nó biến chính hạn chế (thiếu dữ liệu) thành lợi thế (khai thác trực giác con người).

Về mặt kiến trúc mô hình, **cơ chế Attention** đang là xu hướng chủ đạo trong deep learning và hoàn toàn có thể tích hợp vào NCF. Thay vì coi mọi feature đều quan trọng như nhau, Attention cho phép mô hình tự động "chú ý" vào những tương tác quan trọng nhất - ví dụ, khi dự đoán rating cho một phim kinh dị, mô hình sẽ đặt trọng số cao hơn cho lịch sử xem phim kinh dị của user thay vì phim hoạt hình. Với dữ liệu đủ lớn (hàng triệu tương tác), kiến trúc Attention-based NCF có tiềm năng vượt trội đáng kể so với các mô hình truyền thống.

Không thể không nhắc đến việc **mô hình hóa yếu tố thời gian** (temporal dynamics). Kỳ vọng và sở thích của người dùng thay đổi theo mùa, theo xu hướng văn hóa, theo giai đoạn cuộc sống. Một mô hình thực sự thông minh cần nắm bắt được sự tiến hóa này - không chỉ trả lời "user thích gì" mà còn "user đang thích gì *bây giờ*". Kết hợp temporal dynamics với belief data sẽ tạo ra một hệ thống không chỉ dự đoán rating mà còn dự đoán được *sự thay đổi* trong kỳ vọng của người dùng theo thời gian.

Nhìn xa hơn, giá trị lớn nhất của bộ dữ liệu MovieLens Belief 2024 không nằm ở việc

xây dựng một mô hình gợi ý chính xác hơn, mà ở việc mở ra một **hướng nghiên cứu mới về mối quan hệ giữa trí tuệ nhân tạo và nhận thức con người**. Khi máy học dự đoán chính xác hơn chính con người (ML RMSE thấp hơn belief error), điều đó không có nghĩa là máy "hiểu" con người - mà là máy tìm ra những pattern mà con người không nhận thức được. Khai thác khoảng cách giữa dự đoán của máy và trực giác của người chính là chìa khóa để xây dựng những hệ thống gợi ý không chỉ chính xác, mà còn *thấu hiểu* người dùng.

Tài liệu tham khảo

1. Aridor, G., Goncalves, D., Kong, R., Culver, D., & Konstan, J.A. (2024). *The MovieLens Beliefs Dataset: Collecting Pre-Choice Data for Online Recommender Systems.* Proceedings of the 18th ACM Conference on Recommender Systems (RecSys).

2. Koren, Y., Bell, R., & Volinsky, C. (2009). *Matrix Factorization Techniques for Recommender Systems.* IEEE Computer, 42(8), 30–37. DOI: 10.1109/MC.2009.263.

3. Koren, Y. (2008). *Factorization Meets the Neighborhood: A Multifaceted Collaborative Filtering Model.* Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 426–434.

4. Koren, Y. (2010). *Factor in the Neighbors: Scalable and Accurate Collaborative Filtering.* ACM Transactions on Knowledge Discovery from Data, 4(1), Article 1.

5. Sarwar, B., Karypis, G., Konstan, J., & Riedl, J. (2001). *Item-Based Collaborative Filtering Recommendation Algorithms.* Proceedings of the 10th International Conference on World Wide Web (WWW), 285–295. DOI: 10.1145/371920.372071.

6. Lee, D.D. & Seung, H.S. (1999). *Learning the Parts of Objects by Non-negative Matrix Factorization.* Nature, 401(6755), 788–791. DOI: 10.1038/44565.

7. Lee, D.D. & Seung, H.S. (2001). *Algorithms for Non-negative Matrix Factorization.* Advances in Neural Information Processing Systems (NeurIPS), 13, 556–562.

8. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer Series in Statistics. ISBN: 978-0-387-84857-0.

9. Ricci, F., Rokach, L., & Shapira, B. (2015). *Recommender Systems Handbook* (2nd ed.). Springer. ISBN: 978-1-4899-7637-6.

10. Hug, N. (2020). *Surprise: A Python library for recommender systems.* Journal of Open Source Software, 5(52), 2174. DOI: 10.21105/joss.02174.

11. He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T.S. (2017). *Neural Collaborative Filtering*. Proceedings of the 26th International Conference on World Wide Web (WWW), 173–182. DOI: 10.1145/3038912.3052569.

12. Salakhutdinov, R. & Mnih, A. (2008). *Bayesian Probabilistic Matrix Factorization using Markov Chain Monte Carlo*. Proceedings of the 25th International Conference on Machine Learning (ICML), 880–887.

13. Herlocker, J.L., Konstan, J.A., Borchers, A., & Riedl, J. (1999). *An Algorithmic Framework for Performing Collaborative Filtering*. Proceedings of the 22nd ACM SIGIR Conference on Research and Development in Information Retrieval, 230–237.

14. GroupLens Research. (2024). *MovieLens Belief 2024 Dataset*. https://grouplens.org/datasets/movielens/ml_belief_2024/

15. Paszke, A., et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems (NeurIPS), 32, 8024–8035.

16. Hyndman, R.J. & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts. https://otexts.com/fpp2/

17. Eckart, C. & Young, G. (1936). *The Approximation of One Matrix by Another of Lower Rank*. Psychometrika, 1(3), 211–218.

– **HẾT BÁO CÁO** –